

Etapa 2. Comprensión y preparación de los datos

2026-08-28

Table of contents

1	1. Objetivo del análisis	1
2	2. Técnicas estadísticas utilizadas	2
3	3. Datos y variables de interés	3
4	4. Principales resultados descriptivos	4
4.1	4.1 Tendencia central y dispersión	4
4.2	4.2 Forma de las distribuciones y valores extremos	5
4.3	4.3 Diferencias entre estaciones de monitoreo	6
5	5. Calidad de los datos posterior a la limpieza	6
6	6. Asociación entre meteorología y contaminantes	7
7	7. Conclusiones y siguientes pasos	9
8	8. Documentos de trabajo y base limpia	9
9	9. Declaratoria de uso de IA	10
10	Referencias	10

1 1. Objetivo del análisis

El objetivo general del proyecto se mantiene: **desarrollar y evaluar modelos predictivos que permitan estimar las concentraciones de contaminantes atmosféricos criterio**

en la Zona Metropolitana de Monterrey a partir de variables meteorológicas registradas por SIMA entre 2020 y 2025. En esta segunda etapa todavía no se construyen los modelos; el propósito es comprender con suficiente detalle la información que se utilizará posteriormente y verificar que la base sea adecuada para el análisis predictivo.

En particular, se busca describir la distribución y variabilidad de los contaminantes y de las variables meteorológicas, reconocer diferencias entre estaciones de monitoreo, cuantificar los valores faltantes y revisar la presencia de observaciones extremas. También se estudian asociaciones preliminares entre meteorología y contaminación para identificar qué variables podrían ser especialmente útiles como predictoras. Esta etapa es importante porque permite tomar decisiones posteriores de modelado con base en la calidad y el comportamiento real de los datos, en lugar de seleccionar variables únicamente por criterio teórico.

Las preguntas que orientan esta exploración son: ¿qué variables cuentan con información suficiente para ser modeladas?, ¿qué contaminantes presentan mayores diferencias entre estaciones?, ¿qué variables meteorológicas muestran asociaciones más claras con las concentraciones registradas?, y ¿qué problemas de calidad deben resolverse o considerarse antes de construir los modelos?

2 2. Técnicas estadísticas utilizadas

Para responder estas preguntas se emplearon técnicas descriptivas y exploratorias. Las **medidas de tendencia central** —principalmente media y mediana— permiten conocer el nivel típico de cada variable; la comparación entre ambas también ayuda a detectar asimetrías. Las **medidas de dispersión**, como desviación estándar, rango y cuartiles, permiten evaluar qué tan variables son las mediciones y sirven de base para identificar posibles valores atípicos mediante el rango intercuartílico.

Los **histogramas** se utilizaron para estudiar la forma de las distribuciones, mientras que los **diagramas de caja** del documento de trabajo permitieron comparar medianas, dispersión y observaciones extremas. Para el componente espacial se realizaron comparaciones descriptivas entre NTE, NTE2, NO y NE. Finalmente, se utilizó la **correlación de Spearman** para estudiar asociaciones monotónicas entre contaminantes y variables meteorológicas. Se eligió Spearman debido a que varias variables presentan distribuciones asimétricas y valores extremos, por lo que no resulta conveniente depender únicamente de una medida de correlación lineal sensible a estas características.

Esta estrategia también es consistente con el antecedente de Cifuentes et al. (2021), quienes utilizan información meteorológica para construir modelos de predicción de contaminantes atmosféricos. En nuestro caso, el análisis descriptivo funciona como una etapa previa para identificar variables con suficiente disponibilidad, variación y asociación estadística antes de seleccionar los modelos definitivos.

3 3. Datos y variables de interés

La base limpia utilizada en esta entrega contiene **192,723 registros y 18 columnas**. Cada fila corresponde a una medición horaria asociada a una estación de monitoreo. El análisis se concentra en las estaciones NTE, NTE2, NO y NE, seleccionadas en el documento de trabajo para estudiar una zona espacialmente relacionada sin utilizar simultáneamente toda la red de SIMA.

Las variables se dividen en tres grupos. Los **contaminantes atmosféricos** son las posibles variables objetivo de los modelos; las **variables meteorológicas** constituyen las principales candidatas a predictoras; y las variables **temporales y espaciales** conservan el contexto de cada medición. La estación de monitoreo es particularmente importante porque una misma condición meteorológica puede relacionarse de manera distinta con la contaminación dependiendo de la ubicación.

Table 1: Variables utilizadas y proporción de valores faltantes.

Variable	Grupo / tipo	Descripción / unidad	% nulos
CO	Contaminante / numérica	Monóxido de carbono (ppm)	17.94
NO	Contaminante / numérica	Monóxido de nitrógeno (ppb)	20.43
NO2	Contaminante / numérica	Dióxido de nitrógeno (ppb)	23.66
NOX	Contaminante / numérica	Óxidos de nitrógeno (ppb)	23.38
O3	Contaminante / numérica	Ozono (ppb)	24.30
PM10	Contaminante / numérica	Partículas menores a 10 μm ($\mu\text{g}/\text{m}^3$)	5.51
PM2.5	Contaminante / numérica	Partículas menores a 2.5 μm ($\mu\text{g}/\text{m}^3$)	19.68
SO2	Contaminante / numérica	Dióxido de azufre (ppb)	24.49
BP	Meteorológica / numérica	Presión atmosférica (mm Hg)	8.15
RAINF	Meteorológica / numérica	Precipitación (mm/Hr)	7.47
RH	Meteorológica / numérica	Humedad relativa (%)	18.87
SR	Meteorológica / numérica	Radiación solar (kW/m^2)	4.02

Variable	Grupo / tipo	Descripción / unidad	% nulos
TEMP	Meteorológica / numérica	Temperatura (°C)	14.49
WS	Meteorológica / numérica	Velocidad del viento (Km/hr)	10.26
WD	Meteorológica / circular	Dirección del viento (0-360°)	10.76
Estacion	Espacial / categórica	Estación de monitoreo: NTE, NTE2, NO o NE	0.00
Año	Temporal / discreta	Año de la medición (2020-2025)	0.00
fecha y hora	Temporal / fecha-hora	Momento de la medición horaria	0.00

La tabla muestra que la base conserva tanto información suficiente para caracterizar la meteorología como ocho contaminantes de interés. **WD** requiere un tratamiento especial porque es una variable circular: 0° y 360° representan prácticamente la misma dirección. Por esta razón, para el análisis de correlación se transformó en componentes seno y coseno. **Estacion**, **Año** y **fecha y hora** no son mediciones atmosféricas, pero permitirán evaluar posteriormente patrones espaciales, horarios y estacionales.

4 4. Principales resultados descriptivos

4.1 4.1 Tendencia central y dispersión

El análisis estadístico muestra que varios contaminantes presentan una diferencia importante entre media y mediana. En el documento de trabajo, por ejemplo, **NO** presenta una media cercana a 13.56 frente a una mediana de 5.10; **NOX**, 30.82 frente a 19.40; **PM10**, 59.17 frente a 50.00; y **PM2.5**, 20.03 frente a 17.00. Cuando la media queda por encima de la mediana de esta manera, existe evidencia de asimetría hacia valores altos: la mayoría de las mediciones se concentra en niveles bajos o intermedios, pero algunos episodios elevados desplazan el promedio.

Table 2: Resumen estadístico de variables seleccionadas.

Variable	Media	Mediana	DE	Q1	Q3
CO	1.32	1.17	0.78	0.78	1.70
NO	13.56	5.10	23.48	3.00	12.00
NO2	16.91	13.20	12.59	8.00	22.30
NOX	30.82	19.40	32.53	11.70	35.80
O3	27.10	23.00	18.99	13.00	37.00
PM10	59.17	50.00	40.86	34.00	72.75

Variable	Media	Mediana	DE	Q1	Q3
PM2.5	20.03	17.00	15.72	10.40	26.00
SO2	4.81	3.90	3.57	2.90	5.50
RH	55.92	58.00	22.39	39.00	74.00
TEMP	23.45	24.13	7.25	18.80	28.52
WS	8.16	7.50	4.49	4.90	10.80

Las variables meteorológicas presentan comportamientos diferentes. La presión atmosférica se mantiene relativamente concentrada alrededor de sus valores centrales, mientras que la precipitación presenta una gran acumulación en cero porque la mayoría de las horas no registra lluvia. La radiación solar también contiene muchos valores iguales a cero asociados principalmente con horas nocturnas. La temperatura es más estable que varios contaminantes y la velocidad del viento presenta una cola hacia valores altos. Estas diferencias indican que las variables no deben tratarse como si tuvieran una misma forma de distribución.

4.2 4.2 Forma de las distribuciones y valores extremos

Los histogramas confirman que NO, NOX, PM10, PM2.5 y SO2 presentan distribuciones claramente asimétricas hacia la derecha. Los valores elevados no se eliminaron de forma automática, ya que la limpieza previa ya había convertido a NA las observaciones fuera de los límites operativos definidos para cada año. Por lo tanto, una observación extrema que permanece dentro de los rangos válidos puede corresponder a un episodio real de contaminación y contiene información potencialmente importante para el modelado.




Figure 1: Distribución de los contaminantes atmosféricos en las cuatro estaciones seleccionadas.

El análisis mediante rango intercuartílico realizado en `reporte.qmd` detectó porcentajes relevantes de valores atípicos en algunas variables, llegando hasta aproximadamente 11.82 % en el caso más alto. El equipo decidió conservarlos en esta etapa. Eliminarlos sin analizar su contexto podría reducir artificialmente la variabilidad y hacer que los modelos posteriores aprendan únicamente condiciones ordinarias, perdiendo precisamente los episodios de mayor interés ambiental.

4.3 4.3 Diferencias entre estaciones de monitoreo

La comparación espacial muestra que las cuatro estaciones no se comportan de manera idéntica. NTE2 registra concentraciones típicas mayores de compuestos nitrogenados: en el análisis completo se obtuvieron medianas de 10.00 para NO, 20.20 para NO2 y 32.50 para NOX. También presenta una mediana de PM10 de 57.00, superior a la observada en NO, donde la mediana fue 41.00. Por el contrario, 03 presenta su mediana más alta en NO con 26.00 y la más baja en NTE2 con 20.00.

Table 3: Comparación por estación: medianas, excepto número de registros.

Estación	Registros	PM10	O3	NO2	RH	TEMP	WS
NE	48181	51.00	25	11.3	65	23.41	8.2
NO	48182	41.00	26	11.0	56	24.26	7.3
NTE	48181	50.69	23	10.7	50	24.40	7.0
NTE2	48179	57.00	20	20.2	57	24.35	7.5

También existen diferencias meteorológicas. En el documento de trabajo, NE presenta una mediana de humedad relativa de 65 %, presión atmosférica de 718.80 y velocidad del viento de 8.20 km/h, superiores a las de las demás estaciones en esas variables. La temperatura, en cambio, es relativamente homogénea, con medianas cercanas a 24 °C. Estas diferencias justifican conservar `Estacion` como variable relevante y evaluar posteriormente si conviene incorporar interacciones o construir modelos específicos por ubicación.

5 5. Calidad de los datos posterior a la limpieza

La limpieza realizada previamente homologó los nombres de las variables entre 2020 y 2025, convirtió la bandera -9999 a NA y reemplazó por NA las observaciones que se encontraban fuera de los rangos operativos definidos para cada variable y año. La revisión posterior confirmó **0 observaciones fuera de rango y 0 combinaciones año-estación-fecha duplicadas**. También se verificó que las categorías de la estación correspondieran únicamente a NE, NO, NTE y NTE2 y que las variables esperadas estuvieran presentes después de la homologación.

El principal problema de calidad que permanece son los **valores faltantes**. A nivel general, el análisis completo encontró los mayores porcentajes de ausencia en **SO2** (24.49 %), **O3** (24.30 %), **NO2** (23.66 %) y **NOX** (23.38 %). En contraste, **SR** (4.02 %) y **PM10** (5.51 %) tienen una disponibilidad considerablemente mayor. Además, el porcentaje global oculta diferencias importantes entre estaciones: **RH** alcanza 54.76 % de faltantes en **NTE** y **PM2.5** 41.36 % en **NO**, mientras que **NTE2** presenta una disponibilidad alta en varias variables meteorológicas.

Table 4: Variables de medición con mayor proporción de valores faltantes.

Variable	% de valores faltantes
SO2	24.49
O3	24.30
NO2	23.66
NOX	23.38
NO	20.43
PM2.5	19.68
RH	18.87
CO	17.94

No se eliminaron registros completos únicamente por contener algún valor faltante. La estrategia definitiva dependerá del contaminante que se seleccione como variable objetivo y del modelo empleado. Esta decisión evita perder información útil de otras variables y permite evaluar después alternativas como trabajar con casos completos para un modelo particular, imputar ciertos predictores o aplicar métodos que toleren ausencias.

6 6. Asociación entre meteorología y contaminantes

Para estudiar la relación preliminar entre las variables se calculó la correlación de Spearman. La dirección del viento se representó mediante **WD_sin** y **WD_cos** para respetar su naturaleza circular. Estas correlaciones no prueban causalidad; se utilizan como una herramienta exploratoria para priorizar relaciones que posteriormente deberán verificarse mediante modelos predictivos.




Figure 2: Correlaciones de Spearman entre contaminantes y variables meteorológicas.

El resultado más claro corresponde a **O3**. Su asociación de mayor magnitud es negativa con **RH (-0.549)**, mientras que presenta asociaciones positivas con **TEMP (0.515)**, **WS (0.506)** y **SR (0.475)**. Esto convierte a humedad relativa, temperatura, velocidad del viento y radiación solar en candidatos especialmente relevantes para un modelo de ozono.

Los compuestos nitrogenados presentan un patrón distinto. **WS** se relaciona negativamente con **NO2 (-0.473)**, **NOX (-0.472)** y **NO (-0.350)**. La temperatura también muestra asociaciones negativas con **NOX (-0.335)**, **NO2 (-0.307)** y **NO (-0.250)**. Para **CO**, **SO2** y **PM2.5** las asociaciones meteorológicas son, en general, más débiles, mientras que para **PM10** destaca una correlación de **-0.244** con **RH**.

Table 5: Ocho asociaciones de mayor magnitud absoluta.

Contaminante	Meteorológica	Spearman
O3	RH	-0.549
O3	TEMP	0.515
O3	WS	0.506
O3	SR	0.475
NO2	WS	-0.473
NOX	WS	-0.472
NO	WS	-0.350
NOX	TEMP	-0.335

El análisis por estación incluido en el documento de trabajo muestra que varias de estas relaciones conservan el mismo signo en NTE, NTE2, NO y NE, especialmente las asociaciones de O₃ con RH, TEMP, WS y SR, así como las relaciones negativas de los óxidos de nitrógeno con la velocidad del viento. Sin embargo, la magnitud cambia entre ubicaciones y las componentes de la dirección del viento son más variables. Esto refuerza la necesidad de considerar el componente espacial durante el modelado.

7 7. Conclusiones y siguientes pasos

La Etapa 2 permitió pasar de una base simplemente depurada a una comprensión más clara de la información disponible. Se comprobó que el conjunto conserva una estructura consistente, sin duplicados bajo el criterio año-estación-fecha y sin observaciones fuera de los rangos definidos después de la limpieza. También se identificó que el principal problema pendiente es la cantidad desigual de datos faltantes entre variables y estaciones.

Desde el punto de vista estadístico, varios contaminantes presentan asimetría y valores extremos válidos, por lo que será importante seleccionar modelos y métricas que no dependan de supuestos demasiado restrictivos. Las diferencias observadas entre estaciones demuestran que la ubicación no debe ignorarse. Además, las correlaciones señalan a O₃ como uno de los contaminantes con relación meteorológica más clara, principalmente mediante RH, TEMP, WS y SR; los óxidos de nitrógeno también muestran asociaciones relevantes con velocidad del viento y temperatura.

El siguiente paso será seleccionar los contaminantes objetivo combinando **disponibilidad de información, relevancia ambiental y relación con las variables meteorológicas**. Después se definirá el tratamiento de valores faltantes para cada modelo y se compararán alternativas predictivas. También se deberán incorporar atributos temporales derivados de **fecha y hora** —como hora, mes o estación del año— para responder si las relaciones cambian temporalmente, y evaluar si el desempeño mejora al considerar explícitamente la estación de monitoreo.

Las principales preguntas que permanecen son si las relaciones observadas son suficientemente estables a lo largo del tiempo, si un solo modelo puede representar adecuadamente las cuatro estaciones y cuánto mejora la predicción al incorporar información temporal además de la meteorología. Estas preguntas guiarán las siguientes etapas de CRISP-DM.

8 8. Documentos de trabajo y base limpia

- Repositorio del proyecto: <https://github.com/Reyivan777/Reto-Multivariados>
- Documento de trabajo completo: <https://github.com/Reyivan777/Reto-Multivariados/blob/trunk/quarto/reporte.qmd>

- Base limpia de la Etapa 2: https://github.com/Reyivan777/Reto-Multivariados/blob/trunk/data/datos_etapa2_limpios.csv

9 9. Declaratoria de uso de IA

Opción B. Se utilizó IA.

Herramientas: Claude y ChatGPT (OpenAI).

Uso realizado: apoyo en búsqueda y organización de referencias, estructuración y revisión de borradores, apoyo con sintaxis de R y configuración de la automatización de GitHub para generar los documentos.

Secciones donde se utilizó: comprensión del negocio, comprensión y preparación de los datos, revisión de código y organización del reporte.

Validación realizada por los estudiantes: el equipo revisó, editó y verificó el contenido y los resultados obtenidos, y asume la responsabilidad del contenido final entregado.

10 Referencias

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.