

Etapa 2. Comprensión y preparación de los datos

Equipo 4

2026-09-02

Integrantes del equipo

Rey Iván de la Fuente Chávez, A01709445
Jannette Cristina Flores Rodríguez, A01255711
Matías Romero Mariné, A01708802
Emilio Alonso Sánchez, A00841853
Dulce Alejandra Sánchez López, A01412307

1 1. Objetivo y enfoque del análisis

El objetivo general del proyecto es **desarrollar y evaluar modelos predictivos que permitan estimar las concentraciones de contaminantes atmosféricos criterio en la Zona Metropolitana de Monterrey a partir de variables meteorológicas registradas por SIMA entre 2020 y 2025**. En esta etapa se busca comprender y preparar la información antes del modelado, identificando su estructura, calidad, distribución, diferencias entre estaciones y asociaciones preliminares entre meteorología y contaminación.

Se utilizaron medidas de tendencia central y dispersión, histogramas y diagramas de caja para estudiar distribuciones y valores extremos, comparaciones descriptivas entre estaciones y correlaciones de **Spearman** para evaluar asociaciones entre contaminantes y variables meteorológicas. Spearman se eligió porque varias variables presentan asimetría y valores extremos. Este enfoque es consistente con Cifuentes et al. (2021), quienes utilizan variables meteorológicas para predecir concentraciones de contaminantes atmosféricos.

2 2. Datos y variables de interés

La base limpia utilizada contiene **192,723 registros y 18 columnas** correspondientes a las estaciones NTE, NTE2, NO y NE. Cada fila representa una medición horaria asociada a una estación.

Grupo	Variables	Función en el análisis
Contaminantes	CO, NO, NO2, NOX, O3, PM10, PM2.5, SO2	Posibles variables objetivo.
Meteorológicas	BP, RAINF, RH, SR, TEMP, WS, WD	Principales variables predictoras.
Temporales/espaciales	Estacion, Año, fecha y hora	Conservan el contexto espacial y temporal.

Los contaminantes y las variables meteorológicas son cuantitativos continuos, excepto WD, que es una variable circular entre 0° y 360°. Para las correlaciones, la dirección del viento se transformó en componentes seno y coseno porque 0° y 360° representan prácticamente la misma dirección. **Estacion** es categórica nominal, **Año** es temporal discreta y **fecha y hora** identifica el momento de cada observación. Estas variables temporales y espaciales se conservarán para evaluar si las relaciones cambian según ubicación, hora o estacionalidad.

La distribución de registros entre las cuatro estaciones es suficientemente equilibrada para compararlas sin que una sola ubicación domine el análisis:

Table 1: Distribución de registros por estación.

Estación	Registros	% del total
NE	48181	25
NO	48182	25
NTE	48181	25
NTE2	48179	25

3.3. Resultados descriptivos principales

Los contaminantes no presentan distribuciones homogéneas. NO, NOX, PM10, PM2.5 y SO2 muestran asimetría hacia valores altos. Por ejemplo, NO presenta una media claramente mayor que su mediana, al igual que NOX, PM10 y PM2.5. Esto indica que la mayoría de las observaciones se concentra en niveles bajos o intermedios, pero existen episodios elevados que desplazan el promedio.

Table 2: Medidas descriptivas de variables representativas.

Variable	Media	Mediana	Desv. estándar
NO	13.56	5.10	23.48
NOX	30.82	19.40	32.53
O3	27.10	23.00	18.99
PM10	59.17	50.00	40.86
PM2.5	20.03	17.00	15.72
SO2	4.81	3.90	3.57
RH	55.92	58.00	22.39
TEMP	23.45	24.13	7.25
WS	8.16	7.50	4.49

Las variables meteorológicas presentan comportamientos distintos: la presión atmosférica es relativamente estable; la precipitación se concentra principalmente en cero; la radiación solar también registra numerosos ceros durante horas nocturnas; y la velocidad del viento presenta mayor asimetría. La temperatura tiene una distribución más concentrada que varios contaminantes. Estas diferencias de forma y escala serán relevantes al seleccionar y preparar los modelos.

Los valores extremos que permanecen después de la limpieza no se eliminaron automáticamente, porque pueden corresponder a episodios reales. El análisis mediante rango intercuartílico realizado en el documento de trabajo detectó hasta aproximadamente **11.82 % de valores atípicos** en la variable con mayor proporción. Eliminarlos de forma general podría reducir artificialmente la variabilidad y hacer que los modelos ignoren episodios de contaminación poco frecuentes pero ambientalmente relevantes.

3.1.1 Diferencias entre estaciones

Las estaciones muestran diferencias espaciales claras. NTE2 presenta concentraciones típicas mayores de compuestos nitrogenados y también una mediana elevada de PM10, mientras que NO registra una mediana mayor de O3. En meteorología, NE destaca por mayor humedad relativa y velocidad del viento. Estas diferencias justifican mantener **Estacion** como variable relevante en los modelos posteriores.

Table 3: Resumen por estación: medianas, excepto número de registros.

Estación	Registros	PM10	O3	NO2	RH	WS
NE	48181	51.00	25	11.3	65	8.2
NO	48182	41.00	26	11.0	56	7.3
NTE	48181	50.69	23	10.7	50	7.0
NTE2	48179	57.00	20	20.2	57	7.5

4 4. Calidad y preparación de los datos

Durante la preparación se homologaron los nombres de las variables de 2020 a 2025, se convirtieron las banderas -9999 a NA y se reemplazaron por NA los valores que estaban fuera de los rangos operativos definidos para cada variable y año. La verificación posterior confirmó **0 observaciones fuera de rango y 0 combinaciones año-estación-fecha duplicadas**. También se comprobó que las categorías de *Estacion* fueran únicamente NE, NO, NTE y NTE2, sin errores de escritura pendientes.

El principal problema de calidad que permanece son los valores faltantes. Las mayores proporciones generales se concentran en SO2, O3, NO2 y NOX, mientras que variables como SR y PM10 presentan mayor disponibilidad. Además, existen diferencias por estación; por ejemplo, el análisis completo encontró porcentajes especialmente altos de ausencia para RH en NTE y PM2.5 en NO.

Table 4: Variables con mayor proporción general de valores faltantes.

Variable	% de valores faltantes
SO2	24.49
O3	24.30
NO2	23.66
NOX	23.38
NO	20.43
PM2.5	19.68

No se eliminaron filas completas por tener un dato faltante. El tratamiento definitivo dependerá del contaminante objetivo y del modelo seleccionado. Asimismo, se conservaron los valores extremos válidos y se generaron atributos temporales como hora, día, mes y día de la semana en la versión preparada para modelado. Las variables meteorológicas también cuentan con una versión estandarizada para métodos sensibles a la escala.

Debe considerarse además que **2025 corresponde a un año parcial**, por lo que las comparaciones temporales entre años no deben interpretarse únicamente a partir del número de registros. En las siguientes etapas será necesario controlar este aspecto al estudiar estacionalidad o realizar divisiones de entrenamiento y prueba.

5 5. Asociación entre meteorología y contaminantes

El análisis de Spearman muestra que O3 es el contaminante con asociaciones meteorológicas más claras. Presenta una relación negativa con la humedad relativa (RH, **-0.549**) y relaciones positivas con temperatura (TEMP, **0.515**), velocidad del viento (WS, **0.506**) y radiación solar (SR, **0.475**). Estas variables son candidatas importantes para un modelo predictivo de ozono.

Los compuestos nitrogenados muestran un patrón diferente: WS se relaciona negativamente con NO2 (**-0.473**), NOX (**-0.472**) y NO (**-0.350**). La temperatura también presenta asociaciones negativas con estos contaminantes. Para CO, SO2 y PM2.5 las correlaciones meteorológicas son generalmente menores. Estas asociaciones no implican causalidad, pero ayudan a priorizar variables para el modelado.




Figure 1: Correlaciones de Spearman entre contaminantes y variables meteorológicas.

Table 5: Seis asociaciones de mayor magnitud absoluta.

Contaminante	Meteorológica	Spearman
O3	RH	-0.549
O3	TEMP	0.515
O3	WS	0.506
O3	SR	0.475
NO2	WS	-0.473
NOX	WS	-0.472

5.1.1 Prioridad preliminar para el modelado

Además de revisar correlaciones individuales, se comparó para cada contaminante la asociación meteorológica de mayor magnitud. Esto permite visualizar cuáles variables objetivo parecen contener una señal meteorológica más clara antes de construir los modelos.




Figure 2: Mayor correlación meteorológica absoluta observada para cada contaminante.

La comparación refuerza que O3 y los compuestos nitrogenados son candidatos naturales para las primeras pruebas de modelado, mientras que contaminantes con asociaciones meteorológicas más débiles podrían requerir información temporal, espacial o variables adicionales para alcanzar un desempeño comparable. Sin embargo, la selección final no se basará solo

en la correlación: también se considerará la proporción de datos disponibles, la estabilidad de las relaciones entre estaciones y la relevancia ambiental de cada contaminante.

El análisis por estación realizado en `reporte.qmd` indica que varias de estas relaciones mantienen el mismo signo en NTE, NTE2, NO y NE, especialmente para O3 y los óxidos de nitrógeno, aunque su magnitud cambia entre ubicaciones. Esto confirma que existe un patrón general, pero también un componente espacial que deberá incorporarse en los modelos.

6 6. Conclusiones y siguientes pasos

La Etapa 2 permitió consolidar un conjunto de datos limpio y comprender sus principales características antes del modelado. Se identificaron distribuciones asimétricas y valores extremos válidos, diferencias entre estaciones y una disponibilidad desigual de información. Los datos faltantes constituyen el principal aspecto pendiente de tratamiento.

Los resultados preliminares muestran que O3 tiene una relación especialmente clara con RH, TEMP, WS y SR, mientras que NO, NO2 y NOX presentan asociaciones relevantes con velocidad del viento y temperatura. El siguiente paso será seleccionar los contaminantes objetivo combinando **disponibilidad de datos, relevancia ambiental y relación meteorológica**, definir el tratamiento de valores faltantes y comparar modelos predictivos. También se evaluará si incorporar hora, mes, estacionalidad y estación de monitoreo mejora el desempeño.

A partir de esta exploración surgen tres preguntas para las siguientes etapas: **¿las asociaciones meteorológicas se mantienen estables a lo largo del año?**, **¿un modelo general puede representar adecuadamente las cuatro estaciones o se requieren modelos específicos?**, y **¿qué tratamiento de datos faltantes conserva mejor la información sin introducir sesgo?** Estas preguntas orientarán la construcción y evaluación de los modelos.

7 7. Repositorio, base limpia y uso de IA

- Repositorio: <https://github.com/Reyivan777/Reto-Multivariados>
- Documento de trabajo completo: <https://github.com/Reyivan777/Reto-Multivariados/blob/trunk/quarto/reporte.qmd>
- Base limpia: https://github.com/Reyivan777/Reto-Multivariados/blob/trunk/data/datos_etapa2_limpios.csv

Declaratoria de uso de IA — Opción B. Se utilizaron Claude y ChatGPT (OpenAI) como apoyo para organizar referencias, revisar borradores, apoyar con sintaxis de R y configurar la automatización de GitHub. El equipo revisó y validó el contenido y los resultados obtenidos y asume la responsabilidad del entregable final.

8 Referencias

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM2.5 Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021—Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.