



Aplicación de métodos multivariados en ciencia de datos (Gpo 101)

Predicción de ozono a 24 horas en la Zona Metropolitana de Monterrey

Equipo 4

Profesores

Blanca Rosa Ruiz Hernandez

Raúl Gómez Muñoz

Integrantes

Rey Iván de la Fuente Chávez, A01709445

Jannette Cristina Flores Rodríguez, A01255711

Matías Romero Maríné, A01708802

Emilio Alonso Sánchez, A00841853

Dulce Alejandra Sánchez López, A01412307

Monterrey, Nuevo León

12 de septiembre de 2026

Resumen

Este proyecto evalúa la posibilidad de **predecir la concentración horaria de ozono troposférico (O3) con 24 horas de anticipación** en las estaciones NTE, NTE2, NO y NE del Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León. El análisis se concentra en horas objetivo entre las 10:00 y las 20:00, periodo en el que el O3 presenta sus concentraciones diurnas más relevantes. Las bases originales abarcan 2020-2025; sin embargo, 2020 se excluyó del modelado debido a que más de 93 % de las mediciones de O3 estaban ausentes en las cuatro estaciones consideradas. El periodo útil quedó definido entre 2021 y junio de 2025.

La preparación de datos incluyó homologación de variables, revisión de duplicados, transformación de mediciones físicamente inválidas a valores faltantes, construcción de variables temporales y representación vectorial del viento. El O3 no se imputó cuando funcionó como respuesta o como rezago, ya que existían interrupciones prolongadas cuya sustitución habría introducido grandes bloques de información sintética. La separación temporal utilizó 2021-2023 para desarrollo inicial, 2024 para validación y selección de especificaciones, 2021-2024 para reentrenamiento final y 2025 exclusivamente como prueba fuera de muestra.

Como técnica de **interdependencia** se utilizó Análisis de Componentes Principales (PCA). Con 48,240 casos completos de 2021-2024, cinco componentes fueron necesarios para superar 80 % de varianza acumulada. El primer componente relacionó principalmente O3 actual, O3 rezagado 24 horas, temperatura y radiación solar, en contraste con humedad relativa; el segundo estuvo dominado por las componentes vectoriales del viento. Estos resultados muestran que la persistencia del O3 y la meteorología contienen información compartida, mientras el viento aporta una dimensión adicional.

Como técnica de **dependencia** se ajustó un Modelo Aditivo Generalizado (GAM) con familia Gamma y enlace logarítmico. También se entrenó XGBoost como modelo predictivo flexible. Ambos se compararon contra una referencia de persistencia diaria. Sobre una muestra común de 3,435 observaciones de 2025, la persistencia obtuvo MAE de 14.144 y RMSE de 19.561; el GAM obtuvo MAE de 12.270 y RMSE de 16.620; y XGBoost obtuvo MAE de 12.110 y RMSE de 16.579. XGBoost presentó la menor pérdida, aunque la diferencia frente al GAM fue pequeña. Su ventaja más clara fue la cobertura: pudo evaluarse sobre 7,333 observaciones en su muestra natural, frente a 3,435 casos completos del GAM.

En conclusión, la información histórica de O3, meteorología, temporalidad y estación permite mejorar de forma consistente un pronóstico de persistencia a 24 horas. XGBoost resulta el candidato más conveniente cuando se prioriza disponibilidad ante datos faltantes, mientras que GAM conserva un desempeño prácticamente equivalente con mayor interpretabilidad. Las principales limitaciones son la cobertura desigual entre estaciones y que 2025 solo contiene datos hasta junio. Como trabajo futuro se propone incorporar pronósticos meteorológicos, evaluar modelos espacio-temporales y analizar específicamente episodios de O3 elevado.

1. Introducción y justificación

La contaminación atmosférica constituye un problema relevante de salud y gestión ambiental. Las guías globales de calidad del aire de la Organización Mundial de la Salud incluyen al ozono, material particulado, dióxido de nitrógeno, dióxido de azufre y monóxido de carbono entre los contaminantes para los que existe evidencia suficiente para establecer niveles guía basados en efectos sobre la salud (World Health Organization, 2021). En el norte de México también se han documentado asociaciones de corto plazo entre contaminación atmosférica, temperatura y mortalidad, lo que refuerza la importancia de disponer de mediciones confiables y herramientas que permitan anticipar episodios de contaminación (Cerón Bretón et al., 2020).

En la Zona Metropolitana de Monterrey (ZMM), el Sistema Integral de Monitoreo Ambiental (SIMA) registra de forma horaria contaminantes y variables meteorológicas mediante una red de estaciones. Estas series permiten estudiar no solo el estado actual de la calidad del aire, sino también si la combinación de historia reciente, meteorología y temporalidad contiene suficiente información para generar pronósticos. Para el O₃ este problema es particularmente relevante porque se trata de un contaminante secundario cuya concentración responde a procesos fotoquímicos y condiciones atmosféricas. En estudios previos de predicción horaria, variables como radiación solar y temperatura han resultado especialmente informativas para anticipar O₃ (Cifuentes et al., 2021).

El reto se desarrolló inicialmente con un alcance amplio que incluía varios contaminantes, estaciones y horizontes. Sin embargo, conforme avanzó la comprensión de los datos, se delimitó a una tarea más concreta: **predecir O₃ con 24 horas de anticipación**. La elección responde a dos razones. Primero, el análisis exploratorio mostró un patrón diario claro y una correlación elevada entre el O₃ de una hora y el observado a la misma hora del día anterior. Segundo, un horizonte de 24 horas es suficientemente exigente para evaluar si meteorología, historia adicional del contaminante y estructura temporal mejoran una referencia simple de persistencia.

El proyecto no busca sustituir los procedimientos oficiales de pronóstico de SIMA ni establecer relaciones causales. Su objetivo es evaluar, dentro del alcance académico del reto, qué tan bien puede anticiparse el O₃ utilizando únicamente información disponible antes de la hora objetivo. Para ello se combinan una técnica de interdependencia, PCA, con una técnica de dependencia vista en clase, GAM, y un modelo adicional de aprendizaje automático, XGBoost. La evaluación se realiza cronológicamente para evitar fuga de información y se reserva 2025 como prueba final.

2. Problemática y objetivo

2.1. Delimitación final

El análisis considera las estaciones NTE, NTE2, NO y NE, y horas objetivo entre las **10:00 y 20:00**. Aunque las bases originales abarcan 2020-2025, **2020 se excluye del modelado final** debido a la insuficiente disponibilidad de O₃. El periodo útil para modelado es **2021-2025**.

La pregunta de investigación final es:

¿Con qué precisión puede predecirse la concentración horaria diurna de O₃ con 24 horas de anticipación, entre las 10:00 y 20:00, en las estaciones NTE, NTE2, NO y NE de la Zona Metropolitana de Monterrey, utilizando información histórica disponible

de O₃, variables meteorológicas, variables temporales y estación de monitoreo durante 2021-2025?

El objetivo general es desarrollar, comparar y evaluar modelos capaces de predecir la concentración horaria de O₃ con 24 horas de anticipación en dichas estaciones y ventana horaria, utilizando únicamente información disponible hasta el instante de origen del pronóstico.

Para cada observación de origen en el instante t , la respuesta del problema es:

$$Y = O_{3,t+24}$$

La referencia mínima es la persistencia diaria:

$$\widehat{O_{3,t+24}}^{\text{persistencia}} = O_{3,t}$$

2.2. Contexto espacial de las estaciones

Las cuatro estaciones representan sectores distintos de la ZMM. La Tabla 1 resume sus ubicaciones de acuerdo con el reporte mensual de SIMA de julio de 2024 (Secretaría de Medio Ambiente de Nuevo León, 2024).

Tabla 1: Ubicación de las estaciones analizadas.

Sigla	Estación	Ubicación	Municipio
NTE	Norte	Parque Los Olivos II sección	General Escobedo
NTE2	Norte 2	Unidad Postgrado CEDEEM UANL	San Nicolás de los Garza
NO	Noroeste	Prepa Militarizada San Bernabé	Monterrey
NE	Noreste	Parque Los Naranjos	San Nicolás de los Garza

La localización es relevante porque las concentraciones registradas dependen tanto de las emisiones como del transporte y dispersión atmosférica. La ZMM se encuentra además condicionada por un relieve montañoso que puede limitar la ventilación regional. Para el O₃, las condiciones meteorológicas resultan especialmente importantes: la Secretaría de Medio Ambiente de Nuevo León ha señalado que combinaciones de alta temperatura, alta radiación y estabilidad atmosférica favorecen su formación durante las horas centrales del día (Secretaría de Medio Ambiente de Nuevo León, 2026). Esto respalda tanto la ventana 10:00-20:00 como la inclusión de radiación, temperatura, humedad y viento en los modelos.

3. Preparación de la base de datos

3.1. Integración y control de calidad

Los datos originales provienen de seis archivos de Excel, uno por año entre 2020 y 2025, con registros horarios por estación. Para el problema final se integraron únicamente NTE, NTE2, NO y NE. La base inicial de estas cuatro estaciones contiene **192,723 registros**.

La preparación incluyó homologación de nombres y tipos de variables, conversión de banderas de ausencia, verificación de duplicados y control de rangos físicos. No se detectaron duplicados para una misma estación y fecha-hora. Los valores fuera de los límites de validación no provocaron la eliminación del registro completo: únicamente la medición inválida fue convertida a NA.

Después de excluir 2020, la base conserva **157,616 registros entre 2021 y 2025**. En este periodo se transformaron **1,062 mediciones fuera de rango a NA** y la verificación posterior confirmó que no permanecen valores fuera de los límites definidos. Los valores extremos dentro de rangos físicamente válidos se conservaron porque pueden representar episodios reales.

3.2. Disponibilidad de O3 y exclusión de 2020

La principal decisión de calidad se relaciona con la variable objetivo. En 2020 el porcentaje de O3 faltante fue de **99.90 % en NE, 98.44 % en NO, 99.99 % en NTE y 93.33 % en NTE2**. Esta ausencia impide utilizar ese año de manera razonable en un modelo supervisado, por lo que 2020 se conserva únicamente como parte de la fuente histórica.

Desde 2021 la cobertura mejora de forma considerable, aunque permanecen interrupciones prolongadas. Debido a ello, **el O3 no se imputa cuando funciona como respuesta ni cuando se utiliza como rezago**. Imputar semanas completas podría alterar la dinámica temporal que los modelos intentan aprender. Entre 2021 y junio de 2025 permanecen **145,151 mediciones válidas de O3** después de la limpieza.

3.3. Ventana horaria y variables derivadas

El análisis exploratorio mostró un ciclo diario estable: el O3 disminuye durante la madrugada, aumenta durante la mañana, alcanza sus valores más altos en la tarde y desciende posteriormente. Con base en este patrón se definió **10:00-20:00** como ventana de evaluación. Las horas fuera de ese intervalo permanecen disponibles para construir historia y rezagos; la restricción se aplica únicamente a las horas objetivo.

La estructura temporal se representa mediante fecha, hora, mes, estación y transformaciones cíclicas seno-coseno. La dirección y rapidez del viento se combinan mediante **WS_sin** y **WS_cos**, evitando tratar los grados como una variable lineal. El análisis de rezagos realizado con 2021-2023 mostró dependencia fuerte en las horas inmediatamente anteriores y una recuperación clara de la correlación a las 24 horas, lo que justifica utilizar el O3 de la misma hora del día anterior como referencia y predictor.

4. Modelación y validación

4.1. Estrategia temporal

La separación de datos fue estrictamente cronológica:

- **2021-2023:** entrenamiento y desarrollo inicial.
- **2024:** validación y selección de especificaciones o hiperparámetros.
- **2021-2024:** reentrenamiento de los modelos definitivos.
- **2025:** prueba final fuera de muestra.

La evaluación se basa en **MAE** y **RMSE**. MAE resume el tamaño promedio del error absoluto y RMSE penaliza con mayor intensidad los errores grandes. Ambos modelos se comparan contra persistencia diaria.

4.2. Técnicas utilizadas

La entrega final utiliza **PCA** como técnica de interdependencia y **GAM** como técnica de dependencia vista en clase. XGBoost se incorpora como modelo predictivo adicional. La regresión lineal desarrollada en etapas previas se conserva en el repositorio como trabajo exploratorio, pero no forma parte de la comparación final porque el análisis definitivo se concentró en GAM y XGBoost.

El **PCA** se aplica sobre 2021-2024 a **O3_t**, **O3_{lag_24}**, radiación solar, temperatura, humedad relativa y las componentes vectoriales del viento. Las variables se estandarizan y los componentes se utilizan únicamente para interpretar la estructura multivariada; no se incorporan como predictores de los modelos finales.

El **GAM Gamma** modela **O3(t+24)** mediante relaciones suaves de O3 histórico, radiación, temperatura, humedad, viento, hora, mes y estación. La familia Gamma con enlace logarítmico se fijó durante el desarrollo después de que la alternativa gaussiana mostrara heterocedasticidad. El GAM requiere casos completos para producir predicciones.

XGBoost utiliza una representación más amplia de la historia del O3, con valores alineados de uno a cuatro días, rezagos recientes, meteorología, temporalidad cíclica y estación. Los hiperparámetros se seleccionan con 2024 y *early stopping*. A diferencia del GAM, XGBoost puede trabajar directamente con valores faltantes en los predictores.

Para comparar precisión de forma justa se utilizan dos perspectivas. La primera reporta la cobertura natural de cada modelo. La segunda, y principal, utiliza una **muestra común de 2025** donde GAM, XGBoost y persistencia se calculan sobre exactamente las mismas observaciones.

4.3. Validación y diagnóstico

La evaluación no se limitó a comparar errores promedio. En el GAM se revisó la adecuación de la familia Gamma con enlace logarítmico, la concurvatura entre términos suaves, el comportamiento de los residuos y su dependencia temporal. Estas comprobaciones son relevantes porque un modelo

puede obtener un MAE bajo y, aun así, conservar patrones sistemáticos en los errores. La especificación final se fijó antes de observar 2025, por lo que los diagnósticos de la prueba final se utilizan para interpretar limitaciones y no para reajustar el modelo después de conocer sus resultados.

En XGBoost no se requieren supuestos distribucionales sobre los residuos, pero sí se controla el sobreajuste mediante validación temporal y *early stopping*. Esto permite que la comparación entre ambos enfoques se apoye principalmente en desempeño fuera de muestra, manteniendo 2025 separado de las decisiones de desarrollo.

4.4. Papel de las variables en el pronóstico

La información utilizada por los modelos puede resumirse en cuatro grupos. Cada grupo representa un mecanismo distinto dentro del problema y ayuda a interpretar por qué los modelos mejoran a la persistencia diaria.

Tabla 2: Papel de los principales grupos de variables en el pronóstico de O3.

Grupo	Variables representativas	Papel en el análisis
Historia del O3	O3 actual, rezagos horarios y valores alineados de días previos	Capturar persistencia, memoria reciente y periodicidad diaria
Meteorología	Radiación solar, temperatura y humedad relativa	Representar condiciones atmosféricas asociadas con la formación y variación del O3
Viento	WS_sin y WS_cos	Incorporar conjuntamente rapidez y dirección para representar transporte y dispersión
Contexto temporal y espacial	Hora, mes y estación	Capturar ciclos diarios y estacionales y diferencias entre ubicaciones

La historia del O3 constituye la señal temporal más directa: el análisis de rezagos mostró dependencia fuerte en las horas cercanas y una recuperación de la correlación a 24 horas, razón por la que la persistencia diaria es una referencia competitiva. Sin embargo, el PCA muestra que esta señal no resume toda la estructura de los datos. Temperatura y radiación aparecen asociadas con el eje principal junto con O3, mientras que la humedad relativa se orienta en sentido contrario y el viento domina un componente distinto. Por ello, mantener variables meteorológicas y de viento permite que GAM y XGBoost incorporen información que no está contenida únicamente en el valor del día anterior.

La estación y las variables cíclicas de hora y mes cumplen un papel diferente: no describen una medición atmosférica puntual, sino el contexto en el que ocurre. Su inclusión permite representar diferencias sistemáticas entre ubicaciones y patrones diarios o estacionales sin asumir que dos horas o meses consecutivos sean independientes entre sí.

4.5. Técnicas exploradas y decisiones finales

Durante el desarrollo se consideraron alternativas que finalmente no forman parte de la comparación principal. La **regresión lineal múltiple** se mantuvo como ejercicio exploratorio y como referencia metodológica, pero la entrega final se concentró en GAM y XGBoost porque el problema presenta relaciones no lineales y efectos temporales que resultan más naturales de representar mediante funciones suaves o árboles potenciados. Esto no implica que la regresión lineal sea inválida; simplemente dejó de ser el enfoque central una vez que el objetivo se fijó en el horizonte de 24 horas y se priorizó la comparación de dos modelos no lineales.

También se evaluó una formulación **gaussiana del GAM** durante el desarrollo. Los diagnósticos mostraron heterocedasticidad, por lo que se adoptó finalmente una familia Gamma con enlace logarítmico, más coherente con una respuesta positiva y con variabilidad que cambia con el nivel de la respuesta. La decisión se tomó durante el desarrollo y no después de observar la prueba de 2025. Esta secuencia es importante porque evita seleccionar la especificación final utilizando el mismo conjunto reservado para evaluar su desempeño.

5. Resultados

5.1. Estructura multivariada mediante PCA

El PCA utiliza **48,240 casos completos de 64,284 observaciones candidatas**, equivalentes a una cobertura de **75.0 %** durante 2021-2024. La Tabla 3 muestra que se requieren cinco componentes para superar 80 % de varianza acumulada.

Tabla 3: Varianza explicada por los primeros cinco componentes principales.

Componente	Varianza explicada (%)	Varianza acumulada (%)
PC1	39.41	39.41
PC2	16.05	55.45
PC3	12.45	67.90
PC4	11.43	79.33
PC5	8.95	88.28

La figura permite observar que PC1 concentra la mayor proporción individual de variabilidad, pero los componentes posteriores siguen aportando información relevante. La varianza acumulada supera 80 % hasta el quinto componente, por lo que la estructura multivariada no puede resumirse adecuadamente en una o dos dimensiones.

En PC1, las cargas de mayor magnitud corresponden a O3_t (0.507), O3_lag_24 (0.458), TEMP (0.445), RH (-0.390) y SR (0.351). Este componente representa principalmente un contraste entre mayor O3, temperatura y radiación frente a mayor humedad relativa. La proximidad entre las cargas de O3 actual y su rezago diario respalda la importancia de la persistencia temporal.

PC2 está dominado por WS_cos (-0.735) y WS_sin (0.599), por lo que captura principalmente la estructura vectorial del viento. En PC3 destacan radiación solar (-0.639), ambas componentes del viento (aproximadamente 0.44) y humedad (-0.373). En conjunto, el PCA indica que la meteorología




Figura 1: Varianza explicada y acumulada por los primeros componentes del PCA.

no puede resumirse únicamente mediante el nivel previo de O₃ y que el viento aporta una dimensión adicional de variabilidad.

5.2. Desempeño en cobertura natural

La Tabla 4 compara cada modelo con persistencia sobre su propia cobertura de 2025. XGBoost reduce el error de persistencia en aproximadamente **14.4 % en MAE y 15.1 % en RMSE**. El GAM reduce aproximadamente **13.2 % en MAE y 15.0 % en RMSE** sobre sus casos completos.

Tabla 4: Desempeño natural de GAM y XGBoost en la prueba de 2025.

Muestra	Modelo	Observaciones	MAE	RMSE
Cobertura XGBoost	Persistencia diaria	7,333	13.787	18.975
Cobertura XGBoost	XGBoost	7,333	11.797	16.111
Casos completos GAM	Persistencia diaria	3,435	14.144	19.561
Casos completos GAM	GAM Gamma	3,435	12.270	16.620

La diferencia de cobertura es importante: XGBoost mantiene 7,333 observaciones, mientras el GAM puede utilizar 3,435 debido a su requerimiento de casos completos. Estas métricas describen disponibilidad operativa, pero no deben usarse por sí solas para decidir qué modelo es más preciso porque se calculan sobre muestras distintas.

5.3. Comparación directa GAM vs. XGBoost

La comparación principal utiliza exactamente las mismas 3,435 observaciones. Como muestra la Tabla 5, XGBoost obtiene el menor error, pero la diferencia frente al GAM es pequeña.

Tabla 5: Comparación final sobre la misma muestra de 2025.

Modelo	Observaciones	MAE	RMSE
Persistencia diaria	3,435	14.144	19.561
GAM Gamma	3,435	12.270	16.620
XGBoost	3,435	12.110	16.579




Figura 2: Comparación de MAE y RMSE entre persistencia, GAM y XGBoost sobre la muestra común de 2025.

La figura muestra que GAM y XGBoost reducen de forma clara ambos errores respecto a persistencia diaria. La diferencia visual entre GAM y XGBoost es pequeña, consistente con la conclusión de que la ventaja de XGBoost en precisión existe, pero es marginal frente al GAM.

XGBoost reduce el MAE del GAM en aproximadamente **1.3 %** y el RMSE en **0.25 %**. Por tanto, los resultados no muestran una superioridad amplia de XGBoost en precisión pura. Ambos modelos ofrecen un desempeño muy similar cuando reciben la misma muestra; la ventaja más clara de XGBoost aparece en la cantidad de observaciones que puede conservar.

5.4. Resultados por estación

La Tabla 6 muestra la comparación sobre la muestra común. NTE2 y NO concentran prácticamente todos los registros comparables. NE aporta solo 13 observaciones y NTE ninguna, por lo que no es posible sostener una comparación estable para esas dos estaciones.

Tabla 6: Desempeño de GAM y XGBoost por estación sobre la muestra común de 2025.

Estación	Observaciones	MAE GAM	MAE	RMSE GAM	RMSE
			XGBoost		XGBoost
NTE2	1,888	11.658	11.541	15.947	15.893
NO	1,534	12.971	12.756	17.264	17.255
NE	13	18.559	18.523	29.765	28.463

5.5. Diagnóstico de errores en la muestra común

MAE y RMSE resumen el tamaño del error, pero no muestran si los modelos presentan **sesgo sistemático** o si una parte importante del error se concentra en observaciones difíciles. Para complementar la comparación se analizan los residuos de la muestra común de 2025, definidos como:

$$\text{Residuo} = O3_{\text{observado}} - O3_{\text{predicho}}.$$

Un residuo positivo indica subestimación y uno negativo indica sobreestimación. Esta revisión utiliza exactamente las mismas observaciones empleadas en la comparación directa, por lo que las diferencias no se deben a cambios en la muestra.

Tabla 7: Diagnóstico descriptivo de residuos en la muestra común de 2025

Modelo	Observaciones	Sesgo_me-	Desv_residuo	Media-	P90_error_abs
		dio		na_error_abs	
GAM	3435	0.91	16.60	9.01	27.01
XG-Boost	3435	1.08	16.56	8.98	27.34

En la muestra común, el residuo medio es de **0.91** para GAM y **1.08** para XGBoost. Como el residuo se definió como observado menos predicho, valores positivos reflejan tendencia a subestimar y valores negativos a sobreestimar. El percentil 90 del error absoluto es **27.01** para GAM y **27.34** para XGBoost; esta medida complementa al RMSE porque muestra el tamaño de error por debajo del cual se encuentra 90 % de las predicciones.

La forma de las dos distribuciones permite comprobar si la ligera ventaja global de XGBoost proviene de un desplazamiento general de los errores o de una reducción de su dispersión. Este diagnóstico debe interpretarse de manera descriptiva: la prueba final sirve para evaluar el comportamiento fuera de muestra, no para volver a modificar la especificación de los modelos.

5.5.1. Error en concentraciones relativamente altas de O3

Una métrica global puede ocultar diferencias precisamente en las observaciones de mayor concentración. Por ello se separa la muestra común usando el tercer cuartil del O3 observado en 2025. Este umbral es descriptivo y **no representa un límite normativo**; únicamente permite comparar el desempeño en la parte superior de la distribución.




Figura 3: Distribución de los residuos de GAM y XGBoost en la muestra común de 2025.

Tabla 8: Error según nivel observado de O3 en la muestra común (P75 = 56)

Modelo	Grupo	Observaciones	MAE	RMSE
GAM	O3 alto ($\geq$ P75)	874	19.13	24.27
GAM	Resto de observaciones	2561	9.93	13.02
XGBoost	O3 alto ($\geq$ P75)	874	19.42	24.73
XGBoost	Resto de observaciones	2561	9.58	12.67

Esta separación permite valorar si el buen desempeño promedio se mantiene en las concentraciones relativamente altas, que son particularmente relevantes desde la perspectiva del problema ambiental. Si los errores aumentan en ese grupo, la métrica global debe complementarse con evaluaciones enfocadas en episodios elevados antes de considerar un uso operativo.

6. Discusión y conclusiones

6.1. Discusión

Los resultados muestran que el O3 diurno puede anticiparse a 24 horas con una mejora consistente respecto a persistencia diaria. La diferencia entre ambos modelos y la referencia es considerablemente mayor que la diferencia entre GAM y XGBoost. Esto indica que el principal avance no proviene de elegir un algoritmo claramente dominante, sino de incorporar historia adicional del contaminante, meteorología, temporalidad y estación.

El PCA ayuda a interpretar este resultado. El primer componente agrupa O3 actual, O3 rezagado 24 horas, temperatura y radiación en una misma estructura, mientras la humedad se comporta en sentido contrario. Esto confirma que la persistencia diaria es una referencia exigente, porque

ya resume una parte importante del comportamiento futuro. Para superarla, los modelos deben aprovechar señal adicional. La reducción cercana a 15 % de RMSE respecto a persistencia muestra que esa señal sí existe.

6.1.1. Dinámica atmosférica observada en los modelos

El ozono troposférico (O₃) es un contaminante secundario que se forma mediante reacciones fotoquímicas en las que intervienen óxidos de nitrógeno (NO_x), compuestos orgánicos volátiles (COV) y luz solar. Esta dependencia fotoquímica es coherente con el ciclo diario observado en los datos del proyecto: concentraciones bajas durante la mañana, incremento conforme avanza el día y máximos vespertinos. También ayuda a explicar por qué la radiación solar aparece como una variable relevante dentro del GAM y dentro de la estructura multivariada identificada por el PCA (Cifuentes et al., 2021).

La formación y acumulación de O₃ también está regulada por las condiciones meteorológicas. Temperaturas elevadas favorecen la velocidad de las reacciones fotoquímicas, mientras que aumentos de humedad relativa suelen relacionarse con menor disponibilidad de radiación o con condiciones que favorecen la remoción y dispersión. Los modelos reflejan esta dinámica: la temperatura requirió una relación flexible dentro del GAM, mientras que la humedad relativa mostró un comportamiento inverso respecto a las concentraciones de O₃. El viento, por su parte, aparece en una dimensión distinta del PCA, consistente con su papel en transporte y dispersión.

Finalmente, la persistencia atmosférica de un día a otro también aparece en los resultados. En el análisis de importancia de variables documentado durante la Etapa 3, el historial de O₃ alineado a 24 horas concentró aproximadamente **75.6 % de la ganancia predictiva total de XGBoost**. Esta concentración de importancia es coherente con la fuerte periodicidad diaria observada y con la idea de que condiciones atmosféricas relativamente persistentes pueden mantenerse entre días consecutivos. Debe interpretarse como evidencia predictiva y no causal: el modelo identifica que la historia del sistema es la señal dominante para anticipar O₃ a 24 horas, mientras la meteorología aporta información adicional (Liu et al., 2026).

El diagnóstico de residuos agrega una segunda lectura del desempeño. MAE y RMSE permiten comparar el tamaño global de los errores, mientras que el sesgo medio, la dispersión residual y el percentil 90 del error absoluto ayudan a identificar si el error se encuentra centrado o si permanecen colas de predicciones difíciles. La revisión específica de concentraciones por encima del tercer cuartil es especialmente útil porque un modelo aceptable en promedio puede deteriorarse en las observaciones de O₃ relativamente alto.

La principal diferencia práctica entre GAM y XGBoost es la cobertura. El GAM ofrece un desempeño prácticamente equivalente con una estructura estadística interpretable, pero requiere casos completos. XGBoost puede generar predicciones ante faltantes en algunos predictores y conserva más del doble de observaciones en la evaluación natural de 2025. Para una aplicación operativa esta diferencia puede ser tan importante como una pequeña mejora en error.

Las conclusiones deben interpretarse con cautela. La muestra común está fuertemente concentrada en NTE2 y NO; NE aporta muy pocas observaciones y NTE ninguna. Además, 2025 contiene datos únicamente hasta junio. El análisis tampoco establece causalidad entre meteorología y O₃: PCA, GAM

y XGBoost describen asociaciones y capacidad predictiva. Finalmente, los modelos utilizan meteorología observada en el instante de origen; un pronóstico operativo a 24 horas podría beneficiarse de pronósticos meteorológicos futuros.

6.2. Conclusiones y recomendaciones

Sobre la muestra común de 2025, **XGBoost obtuvo MAE = 12.110 y RMSE = 16.579**, mientras que **GAM obtuvo MAE = 12.270 y RMSE = 16.620**. Ambos superaron a la persistencia diaria, con MAE = 14.144 y RMSE = 19.561. Por lo tanto, la información histórica de O₃, meteorología, temporalidad y estación mejora de manera medible un pronóstico basado únicamente en la misma hora del día anterior.

XGBoost presenta la mejor precisión, pero solo por un margen pequeño. Su principal ventaja es la cobertura: pudo evaluarse sobre 7,333 observaciones frente a 3,435 casos completos del GAM. Por ello, **XGBoost es el candidato preferible cuando la prioridad es mantener disponibilidad ante datos faltantes**, mientras que **GAM debe conservarse como modelo interpretable de referencia**, ya que alcanza un error prácticamente equivalente.

El PCA mostró que la estructura multivariada no depende de una sola señal. El O₃ actual y su rezago diario comparten información con temperatura y radiación, mientras la humedad actúa en sentido contrario y el viento aporta una dimensión adicional. Se requieren cinco componentes para superar 80 % de varianza acumulada, por lo que existe redundancia, pero también información distribuida entre distintos factores.

Antes de considerar un uso operativo se recomienda mejorar la continuidad de mediciones y repetir la prueba con un año completo y una representación más equilibrada de estaciones. También conviene evaluar explícitamente el comportamiento en concentraciones elevadas y no depender únicamente de métricas globales. Como nuevas preguntas quedan evaluar si los pronósticos meteorológicos futuros mejoran el desempeño, si modelos específicos por estación o espacio-temporales aprovechan mejor la red SIMA y si el comportamiento relativo de los modelos cambia al enfocarse específicamente en episodios de O₃ elevado.

Referencias

- Cerón Bretón, R. M., Cerón Bretón, J. G., Kahl, J. W. D., Espinosa Fuentes, M. de la L., Ramírez Lara, E., Rangel Marrón, M., Lara Severino, R. del C., & Uc Chi, M. P. (2020). Short-term effects of atmospheric pollution on daily mortality and their modification by increased temperatures associated with a climatic change scenario in Northern Mexico. *International Journal of Environmental Research and Public Health*, 17(24), 9219. <https://doi.org/10.3390/ijerph17249219>
- Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., & Aristizábal, B. H. (2021). Hourly ozone and PM_{2.5} prediction using meteorological data: Alternatives for cities with limited pollutant information. *Aerosol and Air Quality Research*, 21, 200471. <https://doi.org/10.4209/aaqr.200471>
- Liu, H., Wang, H., Wang, B., Wang, H., Bai, L., Xue, C., Zhao, L., Bai, J., & Yu, S. (2026). Ozone pollution in a heavy-industrial city with complex terrain: VOC reactivity, source apportionment, and meteorological drivers. *Atmosphere*, 17(9), 812.

Secretaría de Medio Ambiente de Nuevo León. (2024). *Reporte de la meteorología y calidad del aire de la Zona Metropolitana de Monterrey: Julio de 2024*. https://aire.nl.gob.mx/docs/reportes/mensuales/2024/07_Reporte_Julio_2024.pdf

Secretaría de Medio Ambiente de Nuevo León. (2026, 6 de mayo). *Aviso de condiciones actuales de la calidad del aire en la zona metropolitana de Monterrey*. <https://www.nl.gob.mx/es/boletines/aviso-de-condiciones-actuales-de-la-calidad-del-aire-en-la-zona-metropolitana-de-2>

World Health Organization. (2021). *WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. <https://www.who.int/publications/i/item/9789240034228>

Declaratoria de uso de IA

Opción B. Se utilizó IA de la siguiente forma:

Herramientas: ChatGPT (OpenAI) y Claude (Anthropic).

Uso realizado: apoyo para organizar el reporte, revisar redacción, discutir decisiones metodológicas, apoyar la depuración y sintaxis de código, y proponer interpretaciones preliminares de tablas y resultados.

Secciones donde se utilizó: preparación y exploración de datos, construcción y revisión de modelos, PCA, GAM, XGBoost, comparación final, discusión, conclusiones y revisión de estructura y estilo del reporte.

Validación realizada por los estudiantes: el equipo revisó los datos, ejecutó el código, verificó las salidas y contrastó las interpretaciones con los resultados obtenidos. El contenido final fue revisado y editado por los integrantes del equipo, quienes asumen la responsabilidad de la entrega.

Código y reproducibilidad

El análisis se desarrolló en **R** y los archivos de trabajo, datos utilizados y documentos reproducibles se encuentran en el repositorio del proyecto:

GitHub: <https://github.com/Reyivan777/Reto-Multivariados>

Los archivos principales de la etapa final son `PCA_etapa_4.qmd`, `GAM_h24_final.qmd`, `xgboost.qmd`, `comparacion_final_modelos.qmd` y `entrega_etapa_4.qmd`.

Para reproducir esta versión del reporte final, primero debe generarse `data/base_modelado_o3.rds` desde `quarto/reporte.qmd` y después renderizar `quarto/comparacion_final_modelos.qmd`, que crea `output/predicciones_comunes_2025.csv`. Finalmente se renderiza `quarto/entrega_etapa_4.qmd`.