

Reporte de la Situación Problema

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-08-21

Table of contents

1	Etapa 1. Conociendo el negocio	1
1.1	PARTE I. Conociendo el Negocio	1
1.1.1	Presentación general del proyecto (resumen del proyecto).	1
1.1.2	Revisión de bibliografía	2
1.1.3	Descripción del problema específico	3
1.1.4	Objetivos de este proyecto	3
1.1.5	Justificación de los objetivos	4
1.1.6	Descripción de las fuentes de información	4
1.1.7	Referencias bibliográficas	5
1.2	Parte 2	6
1.2.1	Informe preparación de los datos	25
1.2.2	Link Github:	27
1.2.3	Declaratoria de uso IA	27

1 Etapa 1. Conociendo el negocio

1.1 PARTE I. Conociendo el Negocio

1.1.1 Presentación general del proyecto (resumen del proyecto).

La contaminación atmosférica representa un problema importante de salud pública debido a los efectos que contaminantes como PM2.5, PM10, O₃, NO_x, SO_x y CO pueden generar en

la población. En zonas urbanas como el Área Metropolitana de Monterrey, su monitoreo resulta especialmente relevante debido a la actividad industrial, vehicular y a las condiciones meteorológicas que pueden favorecer la acumulación o dispersión de contaminantes.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) registra información sobre la calidad del aire mediante una red de estaciones que miden concentraciones de contaminantes y variables meteorológicas. Estas mediciones permiten conocer las condiciones ambientales de distintas zonas y proporcionan información útil para analizar el comportamiento de la contaminación atmosférica.

Las condiciones meteorológicas influyen directamente en la dinámica de los contaminantes. Variables como temperatura, humedad, velocidad y dirección del viento, presión, precipitación y radiación solar pueden modificar su formación, transporte y dispersión. Dado esto, en este proyecto ha surgido la pregunta: ¿Es posible aprovechar los registros históricos de SIMA para entender y anticipar el comportamiento de la contaminación atmosférica a partir de las variables meteorológicas? A continuación se presenta la revisión bibliográfica que sustenta esta pregunta, como también la descripción del problema, objetivos del proyecto y las fuentes de información utilizadas.

1.1.2 Revisión de bibliografía

Sobre la medición de la calidad del aire, su impacto social e importancia.

La contaminación atmosférica es reconocida como uno de los principales riesgos ambientales para la salud pública. En el área Metropolitana de Monterrey, Cerón Bretón (2020) encontraron asociaciones entre mayores concentraciones de contaminantes atmosféricos y un incremento en el riesgo de mortalidad diaria, efecto que se agrava con temperaturas elevadas y que resulta especialmente relevante en adultos mayores. En un nivel internacional, las Guías de Calidad del Aire 2021 de la Organización Mundial de la Salud (Hoffmann, 2021) refuerzan la relevancia. En zonas donde la contaminación ya es relativamente baja, al reducir las concentraciones de contaminantes criterio (PM_{2.5}, PM₁₀, O₃, NO₂, SO₂ y CO) se generan beneficios medibles para la salud de la población.

En México, estas guías se traducen en las Normas Oficiales Mexicanas de salud ambiental (NOM-020, 021, 022, 023, y 025-SSA1). Estas establecen los límites permisibles para cada contaminante y sirven como referencia para evaluar el cumplimiento y poder diseñar políticas de mitigación de los mismos. La medición de la calidad de aire impacta a la protección a la salud, como también rendición de cuentas hacia la ciudadanía.

Centrado en el objetivo de trabajo (Modelado predictivo con variables meteorológicas)

Con respecto al uso de variables meteorológicas para predecir contaminantes, Cifuentes et al. (2021) desarrollaron modelos de regresión lineal múltiple, Support Vector Regression y redes neuronales para predecir concentraciones horarias de O₃ y PM_{2.5}, encontrando que variables como la radiación solar y temperatura resultan mayormente útiles cuando no se cuenta

con suficiente información directa de contaminantes. Esto ayuda a confirmar en este proyecto la viabilidad de construir modelos predictivos de calidad del aire a partir de datos meteorológicos, y provee sugerencias para la priorización de variables para el momento de modelado.

1.1.3 Descripción del problema específico

El Sistema Integral de Monitoreo Ambiental (SIMA) cuenta con una red de estaciones que registra de forma continua contaminantes atmosféricos, como también variables meteorológicas en la Zona Metropolitana de Monterrey. Sin embargo, esta información histórica no se ha explotado de forma sistemática para anticipar concentraciones de contaminantes a partir de las condiciones meteorológicas, lo cual limita correcta comunicación de los riesgos que conlleva una crítica calidad del aire en la población.

A partir de esta problemática, este proyecto busca responder las siguientes preguntas de investigación:

- ¿Cuáles son las variables meteorológicas (como humedad, temperatura, dirección del viento, radiación solar, etc) que muestran mayor relación con las concentraciones de cada contaminante criterio registradas por SIMA?
- ¿Es posible desarrollar modelos estadísticos y/o de aprendizaje automático que, a partir de variables meteorológicas históricas (proporcionadas), puedan predecir de manera confiable las concentraciones de estos contaminantes en las estaciones de monitoreo?
- ¿Esta relación entre meteorología y contaminantes varía según la estación del año, hora del día o estación de monitoreo específica?

1.1.4 Objetivos de este proyecto

Objetivo general

El objetivo general de este proyecto es desarrollar y evaluar modelos predictivos que permitan estimar las concentraciones de contaminantes atmosféricos criterio en la Zona Metropolitana de Monterrey a partir de variables meteorológicas registradas por SIMA en el periodo 2020-2025, con el fin de aportar herramientas que apoyen a la comunicación de riesgos de calidad del aire.

Objetivos específicos

1. Identificar las variables meteorológicas con mayor relación estadística con respecto a las concentraciones de cada contaminante criterio registrado por SIMA.
2. Construir y comparar modelos estadísticos que predigan las concentraciones de contaminantes a partir de variables meteorológicas, seleccionando los contaminantes objetivo con base en la calidad y disponibilidad de datos.
3. Evaluar si la relación entre las variables meteorológicas y contaminantes varían según la

estacionalidad temporal o la estación de monitoreo, con el fin de identificar patrones temporales y especiales de relevancia.

1.1.5 Justificación de los objetivos

La revisión bibliográfica mencionada en un punto superior confirma que existe evidencia sólida de que las concentraciones de contaminantes atmosféricos están asociadas a riesgos de salud significativos, incluso en niveles relativamente bajos (Hoffmann et al., 2021) y que esta relación se ha documentado específicamente en la Zona metropolitana de Monterrey (abreviada como “ZMM”). Con esto se lleva a justificar la relevancia social del objetivo general, ya que cualquier elemento que ayude a anticipar concentraciones de contaminantes tiene un impacto en la protección de la salud pública local.

Igualmente, se ha demostrado que metodológicamente es muy viable predecir contaminantes como O₃ y PM_{2.5} basándose de variables meteorológicas mediante técnicas estadísticas y de aprendizaje automático, especialmente en contextos donde no se cuenta con un monitoreo continuo de todos los contaminantes (Cifuentes, 2021). Existe un área de oportunidad con este tipo de modelado a los datos históricos que genera SIMA porque, aparentemente, no se ha explorado si la relación meteorología-contaminante varía según estacionalidad o ubicación de las estaciones de esta zona en Monterrey.

Con este proyecto se busca contribuir aprovechando la infraestructura de datos ya existente de SIMA (de 2020 a 2025) para construir modelos predictivos adaptados a las condiciones específicas de Monterrey, aplicando la metodología con un contexto geográfico y temporal.

1.1.6 Descripción de las fuentes de información

La fuente de información utilizada en este proyecto proviene del Sistema Integral de Monitoreo Ambiental (SIMA), organismo encargado de operar la red de estaciones de monitoreo de calidad del aire en el estado de Nuevo León. SIMA aporta de manera pública bases de datos históricas que contienen registros de las distintas estaciones de monitoreo en la ZMM. Cada registro corresponde a una medición cada hora (por estación). Este registro incluye variables de contaminantes atmosféricos criterio [monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 micrómetros (PM₁₀), partículas menores a 2.5 micrómetros (PM_{2.5}) y dióxido de azufre (SO₂), entre otros], e igualmente contienen variables meteorológicas, como precipitación (RAIN), humedad relativa (RH), radiación solar (SR), temperatura (TEMP), velocidad del viento (WS) y su dirección (WD), entre otras.

La combinación de estas variables permite estudiar la relación entre condiciones atmosféricas y concentraciones de contaminantes en el tiempo y en distintos puntos de ZMM. Como el objetivo del proyecto es uno predictivo, se eligió integrar los 6 años proporcionados en una sola base. Las variables meteorológicas se consideran como variables predictoras (independientes),

mientras que los contaminantes se tratan como variables objetivo, modelando cada uno de forma independiente.

La selección final de los contaminantes a modelar dependerá de los datos disponibles y de su fuerza en su relación con las variables meteorológicas. Esto se desarrolla en la sección de preparación de datos, ubicada unos puntos más abajo de este mismo entregable.

1.1.7 Referencias bibliográficas

A) **Sobre la medición de la calidad del aire, impacto social y su importancia.**

Cerón Bretón et al. (2020) analizaron en el Área Metropolitana de Monterrey la relación entre contaminantes atmosféricos, temperatura y mortalidad. El estudio encontró asociaciones entre mayores concentraciones de contaminantes y un incremento en el riesgo de mortalidad, especialmente en adultos mayores, lo que resalta la importancia del monitoreo de la calidad del aire.

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

A.2) **Sobre normas y guías internacionales de calidad del aire.**

Hoffmann et al. (2021), en representación de sociedades médicas y de salud pública resumieron las Guías de Calidad del Aire 2021 de la OMS, llegando a la conclusión de que cualquier reducción en concentraciones de contaminantes es beneficioso para la salud poblacional, contemplando también zonas donde la contaminación inicialmente es relativamente baja. Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.

B) **Centrado en el objetivo del proyecto.** Cifuentes et al. (2021) utilizaron variables meteorológicas para predecir concentraciones horarias de O₃ y PM_{2.5} mediante regresión lineal múltiple, Support Vector Regression y redes neuronales. Sus resultados mostraron que variables como la radiación solar y la temperatura pueden ser útiles para construir modelos predictivos de calidad del aire.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

1.2 Parte 2

Para esta primera etapa, empezaremos por cargar las librerías que necesitamos y establecemos algunas opciones de configuración:

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr       1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(here)
```

here() starts at /Users/jannette/Documents/GitHub/Reto-Multivariados

```
library(readxl)
library(maps)
```

Attaching package: 'maps'

The following object is masked from 'package:purrr':

map

```
library(stringr)
library(readr)
library(purrr)

options(scipen = 999)
```

Ahora cargamos los datos que nos proporcionó el Socio Formador:

```

leer_base <- function(archivo, año) {

  hojas <- excel_sheets(archivo)

  map_dfr(
    hojas,
    function(hoja) {

      datos <- read_excel(
        archivo,
        sheet = hoja,
        col_types = "text"
      )

      nombres <- names(datos)

      nombres <- nombres |>
        str_replace_all("[\r\n]", " ") |>
        str_replace("\\s*\\([^\)]*\\).*", "") |>
        str_squish()

      nombres[tolower(nombres) == "fecha y hora"] <- "Fecha y hora"

      nombres[toupper(nombres) == "PRS"] <- "BP"
      nombres[toupper(nombres) == "TOUT"] <- "TEMP"
      nombres[toupper(nombres) == "WSR"] <- "WS"
      nombres[toupper(nombres) == "WDR"] <- "WD"

      nombres[toupper(nombres) == "CO"] <- "CO"
      nombres[toupper(nombres) == "NO"] <- "NO"
      nombres[toupper(nombres) == "NO2"] <- "NO2"
      nombres[toupper(nombres) == "NOX"] <- "NOX"
      nombres[toupper(nombres) == "O3"] <- "O3"
      nombres[toupper(nombres) == "PM10"] <- "PM10"
      nombres[toupper(nombres) == "PM2.5"] <- "PM2.5"
      nombres[toupper(nombres) == "RAINF"] <- "RAINF"
      nombres[toupper(nombres) == "RH"] <- "RH"
      nombres[toupper(nombres) == "SO2"] <- "SO2"
      nombres[toupper(nombres) == "SR"] <- "SR"

      names(datos) <- nombres
    }
  )
}

```

```

datos |>
  mutate(
    across(
      any_of(c(
        "CO", "NO", "NO2", "NOX", "O3",
        "PM10", "PM2.5", "BP", "RAINF",
        "RH", "SO2", "SR", "TEMP", "WS", "WD"
      )),
      ~ suppressWarnings(parse_number(as.character(.x)))
    ),
    Año = año,
    Estacion = hoja
  )
}
)
}

calidad_aire_2020_tbl <- leer_base(
  here("data", "BD 2020.xlsx"),
  2020
)

calidad_aire_2021_tbl <- leer_base(
  here("data", "BD 2021.xlsx"),
  2021
)

calidad_aire_2022_tbl <- leer_base(
  here("data", "BD 2022.xlsx"),
  2022
)

calidad_aire_2023_tbl <- leer_base(
  here("data", "BD 2023.xlsx"),
  2023
)

calidad_aire_2024_tbl <- leer_base(
  here("data", "BD 2024.xlsx"),
  2024
)

```



```
calidad_aire_2025_tbl <- leer_base(
  here("data", "BD 2025.xlsx"),
  2025
)
```

```
glimpse(calidad_aire_2020_tbl)
```

Rows: 114,102

Columns: 18

```
$ `Fecha y hora` <chr> "43831", "43831.0416666666664", "43831.0833333333336", "4~
$ CO <dbl> NA, 2.11, 2.06, 1.96, 1.98, 2.06, 1.94, 2.06, 1.94, 2.0~
$ NO <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NO2 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NOX <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ O3 <dbl> NA, 19, 19, 19, 16, 13, 15, 10, 12, 7, 8, 9, 10, 8, 16,~
$ PM10 <dbl> 66, 57, 68, 68, 48, 42, 38, 33, 36, 21, 35, 37, 31, 28,~
$ PM2.5 <dbl> 54.23, NA, 53.84, 36.47, 33.59, 33.42, 20.20, 23.84, 15~
$ BP <dbl> NA, 735.7, 734.8, 734.2, 733.9, 733.8, 733.8, 733.6, 73~
$ RAINF <dbl> NA, 0.00, 0.00, 0.00, 0.00, 0.02, 0.10, 0.06, 0.02, 0.0~
$ RH <dbl> NA, 96, 96, 96, 96, 96, 96, 96, NA, NA, NA, NA, 95, 95,~
$ SO2 <dbl> NA, 5.4, 5.5, 5.4, 5.5, 5.4, 5.4, NA, NA, NA, NA, NA, N~
$ SR <dbl> 0.000, 0.010, 0.010, 0.010, 0.010, 0.010, 0.010, 0.010,~
$ TEMP <dbl> NA, 11.20, 11.26, 11.35, 11.47, 11.69, 11.71, 11.84, 11~
$ WS <dbl> NA, 8.1, 5.5, 3.8, 3.3, 3.5, 2.9, 3.8, 3.0, 11.2, 13.0,~
$ WD <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ Año <dbl> 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2~
$ Estacion <chr> "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "~
```

```
glimpse(calidad_aire_2021_tbl)
```

Rows: 122,629

Columns: 18

```
$ `Fecha y hora` <chr> "44197", "44197.0416666666664", "44197.0833333333336", "4~
$ CO <dbl> NA, 4.73, 4.72, 4.82, 5.02, 4.79, 4.77, 4.73, 4.76, 4.6~
$ NO <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NO2 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NOX <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ O3 <dbl> NA, 27, 23, 25, 25, 19, 20, 17, 13, 15, 20, 20, 20, 24,~
$ PM10 <dbl> NA, 68, 55, 57, 65, 71, 60, 57, 47, 45, 30, 39, 41, 37,~
$ PM2.5 <dbl> NA, 46.00, 47.64, 52.07, 61.62, 49.13, 48.03, 37.10, 29~
```

```

$ BP      <dbl> NA, 709.7, 710.1, 710.4, 710.6, 710.6, 710.8, 711.3, 71~
$ RAINF   <dbl> NA, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
$ RH      <dbl> NA, 67, 70, 73, 74, 76, 78, 77, 78, 76, 69, 63, 61, 57,~
$ SO2     <dbl> NA, 3.3, 3.3, 3.6, 3.5, 3.6, 3.4, 3.5, 3.3, 3.3, 3.9, 4~
$ SR      <dbl> NA, 0.167, 0.165, 0.164, 0.164, 0.163, 0.163, 0.163, 0.~
$ TEMP    <dbl> NA, 8.26, 7.15, 6.20, 5.64, 5.08, 4.73, 4.68, 4.39, 4.6~
$ WS      <dbl> NA, 7.9, 4.8, 5.2, 3.2, 3.0, 2.4, 3.0, 4.7, 4.5, 4.7, 6~
$ WD      <dbl> NA, 78, 47, 349, 358, 19, 8, 16, 14, 10, 36, 43, 42, 61~
$ Año     <dbl> 2021, 2021, 2021, 2021, 2021, 2021, 2021, 2021, 2021, 2~
$ Estacion <chr> "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "~

```

```
glimpse(calidad_aire_2022_tbl)
```

Rows: 123,383

Columns: 18

```

$ `Fecha y hora` <chr> "44562", "44562.041666666664", "44562.083333333336", "4~
$ CO            <dbl> 2.60, 2.23, 1.99, 2.03, 1.86, 1.76, 1.55, 1.41, 1.31, 1~
$ NO            <dbl> 3.5, 2.9, 2.9, NA, NA, NA, 2.8, 2.9, 3.0, 6.6, 17.1, 5.~
$ NO2           <dbl> 44.9, 32.9, 27.6, NA, NA, NA, 16.4, 13.5, 13.1, 16.5, 2~
$ NOX           <dbl> 48.5, 36.0, 30.7, NA, NA, NA, 19.4, 16.5, 16.3, 23.4, 4~
$ O3            <dbl> 15, 19, 21, 18, 20, 20, 22, 21, 17, 13, 12, 26, 30, 39,~
$ PM10          <dbl> 134, 141, 117, 108, 106, 81, 71, 59, 57, 52, 54, 68, 62~
$ PM2.5         <dbl> 91.00, 112.61, 92.46, 69.20, 68.03, 49.64, 39.01, 26.40~
$ BP            <dbl> 705.5, 705.2, 705.1, 704.8, 704.8, 704.7, 704.9, 705.3,~
$ RAINF         <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ RH            <dbl> 46, 48, 46, 46, 46, 42, 37, 31, 26, 27, 23, 18, 17, 16,~
$ SO2           <dbl> 5.3, 6.1, 5.8, 6.0, 5.6, 5.3, 4.9, 4.6, 4.1, 3.9, 4.1, ~
$ SR            <dbl> 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000,~
$ TEMP          <dbl> 21.37, 20.83, 20.52, 20.12, 19.85, 19.80, 20.05, 21.15,~
$ WS            <dbl> 3.4, 3.3, 5.9, 5.1, 4.7, 4.2, 4.3, 5.1, 5.9, 4.2, 4.5, ~
$ WD            <dbl> 267, 259, 233, 220, 244, 132, 235, 222, 209, 97, 148, 1~
$ Año           <dbl> 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2~
$ Estacion      <chr> "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "~

```

```
glimpse(calidad_aire_2023_tbl)
```

Rows: 131,370

Columns: 18

```

$ `Fecha y hora` <chr> "44927", "44927.041666666664", "44927.083333333336", "4~
$ CO            <dbl> 1.67, 1.70, 1.51, 1.30, 1.28, 2.12, 1.54, 1.04, 0.98, 1~
$ NO            <dbl> 4.1, 5.0, 4.3, 3.8, 4.6, 19.8, 7.0, 3.8, 3.7, 6.5, 6.2,~

```

```

$ NO2          <dbl> 30.3, 28.9, 23.2, 20.9, 20.7, 30.6, 23.7, 13.6, 12.3, 1~
$ NOX          <dbl> 34.5, 34.1, 27.7, 24.9, 25.5, 50.6, 30.8, 17.6, 16.3, 2~
$ O3           <dbl> 9, 9, 11, 11, 9, 4, 7, 16, 19, 19, 25, 28, 34, 33, 47, ~
$ PM10         <dbl> 118, 97, 103, 83, 65, 67, 147, 84, 43, 36, 41, 44, 33, ~
$ PM2.5        <dbl> 94.12, 96.79, 81.23, 49.83, 40.19, NA, 108.13, 35.00, 1~
$ BP           <dbl> 718.4, 710.7, 710.4, 710.1, 710.2, 710.2, 710.2, 710.2,~
$ RAINF        <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ RH           <dbl> 45, 47, 46, 48, 55, 61, 55, 43, 39, 33, 27, 21, 18, 17,~
$ SO2          <dbl> 3.3, 3.4, 3.4, 3.2, 3.0, 3.1, 3.0, 3.3, 3.2, 3.1, 3.1, ~
$ SR           <dbl> 0.000, 0.001, 0.001, 0.001, 0.001, 0.001, 0.001, 0.001,~
$ TEMP        <dbl> 17.65, 17.12, 16.69, 15.99, 14.74, 14.53, 14.55, 16.08,~
$ WS           <dbl> 4.9, 3.4, 3.4, 2.6, 3.9, 3.4, 3.4, 7.1, 6.3, 3.5, 4.1, ~
$ WD           <dbl> 236, 336, 3, 315, 270, 242, 307, 232, 222, 18, 294, 94,~
$ Año          <dbl> 2023, 2023, 2023, 2023, 2023, 2023, 2023, 2023, 2023, 2~
$ Estacion     <chr> "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "CE", "~

```

```
glimpse(calidad_aire_2024_tbl)
```

Rows: 131,741

Columns: 18

```

$ `Fecha y hora` <chr> "45292", "45292.041666666664", "45292.0833333333336", "4~
$ CO             <dbl> 2.08, 2.07, 2.36, 2.11, 1.94, 1.79, 1.59, 1.53, 1.65, 1~
$ NO             <dbl> 10.5, 10.5, 16.9, 13.6, 8.5, 7.4, 7.4, 7.0, 8.4, 6.1, 5~
$ NO2           <dbl> 23.3, 23.4, 30.0, 26.6, 20.6, 16.3, 14.2, 12.3, 19.8, 1~
$ NOX           <dbl> 33.8, 33.9, 46.9, 40.1, 29.2, 23.6, 21.5, 19.2, 28.2, 1~
$ O3            <dbl> 13, 13, 7, 7, 13, 15, 21, 22, 18, 37, 42, 45, 45, 48, 4~
$ PM10          <dbl> 81, 81, 84, 132, 93, 62, 42, 26, 29, 40, 28, 28, 30, 25~
$ PM2.5         <dbl> 60.00, 60.52, NA, 64.69, 44.13, 28.90, 16.64, 12.57, 17~
$ BP            <dbl> 724.5, 724.5, 724.6, 724.7, 724.7, 724.7, 724.7, 725.4,~
$ RAINF         <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
$ RH            <dbl> 58, 58, 61, 62, 53, 55, 42, 43, 48, 43, 35, 33, 36, 37,~
$ SO2           <dbl> 2.9, 2.9, 3.2, 3.2, 3.2, 2.9, 3.2, 2.9, 3.7, 6.2, 6.4, ~
$ SR            <dbl> 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000,~
$ TEMP          <dbl> 14.26, 14.28, 13.50, 13.18, 14.62, 13.96, 16.39, 15.95,~
$ WS            <dbl> 5.8, 5.9, 3.7, 7.1, 8.4, 7.6, 9.7, 9.6, 5.8, 5.2, 6.3, ~
$ WD            <dbl> 290, 289, 291, 291, 297, 292, 283, 291, 223, 164, 163, ~
$ Año           <dbl> 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2~
$ Estacion      <chr> "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "~

```

```
glimpse(calidad_aire_2025_tbl)
```

Rows: 64,974

Columns: 19

```
$ date      <chr> NA, "45658", "45658.0416666666664", "45658.0833333333336"~
$ CO        <dbl> NA, NA, 0.18, 0.18, 0.19, 0.18, 0.17, 0.17, 0.17, 0.17,~
$ NO        <dbl> NA, NA, 2.6, 2.8, 3.1, 2.8, 2.6, 2.6, 3.0, 8.1, 12.0, 5~
$ NO2       <dbl> NA, NA, 7.5, 13.5, 15.1, 12.8, 4.8, 4.2, 9.8, 16.4, 18.~
$ NOX       <dbl> NA, NA, 10.1, 16.2, 18.1, 15.6, 7.4, 6.8, 12.7, 24.4, 3~
$ O3        <dbl> NA, 36, 37, 26, 22, 24, 33, 36, 21, 9, 9, 22, 37, 44, 4~
$ PM10      <dbl> NA, 104, 58, 79, 66, 48, 46, 35, 41, 42, 43, 43, 80, 51~
$ PM2.5     <dbl> NA, 31.00, 30.84, 49.92, 45.87, 35.65, 31.14, 27.43, 25~
$ BP        <dbl> NA, NA, 725.1, 725.1, 725.1, 725.1, 725.5, 725.9, 726.4~
$ RAINF     <dbl> NA, NA, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,~
$ RH        <dbl> NA, NA, 66, 66, 74, 76, 86, 87, 85, 86, 84, 79, 71, 64,~
$ SO2       <dbl> NA, NA, 4.1, 4.3, 4.1, 4.0, 3.6, 3.9, 3.9, 3.9, 3.9, 4.~
$ SR        <dbl> 2.000, NA, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.~
$ TEMP      <dbl> NA, NA, 17.62, 16.58, 15.50, 15.03, 14.32, 14.29, 13.80~
$ WS        <dbl> NA, NA, 10.7, 5.3, 5.3, 5.0, 8.7, 7.3, 2.5, 1.9, 2.4, 7~
$ WD        <dbl> NA, NA, 136, 255, 250, 181, 91, 104, 263, 243, 297, 38,~
$ Año       <dbl> 2025, 2025, 2025, 2025, 2025, 2025, 2025, 2025, 2025, 2~
$ Estacion  <chr> "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "SE", "~
$ `Fecha y hora` <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
```

```
bases <- list(
  "2020" = calidad_aire_2020_tbl,
  "2021" = calidad_aire_2021_tbl,
  "2022" = calidad_aire_2022_tbl,
  "2023" = calidad_aire_2023_tbl,
  "2024" = calidad_aire_2024_tbl,
  "2025" = calidad_aire_2025_tbl
)

datos_limpios <- bind_rows(bases)
```

En esta sección se trabaja con las bases de datos para abrirlas y poder manipularlas con mayor facilidad.

```
dimensiones <- purrr::imap_dfr(
  bases,
  ~ tibble(
    Año = .y,
    Registros = nrow(.x),
    Columnas = ncol(.x)
  )
)
```

```
)

variables_por_año <- purrr::imap_dfr(
  bases,
  ~ tibble(
    Año = .y,
    Variable = names(.x)
  )
)

tabla_variabales <- variables_por_año |>
  mutate(Presente = "Sí") |>
  tidyr::pivot_wider(
    names_from = Año,
    values_from = Presente,
    values_fill = "No"
  )

dimensiones
```

```
# A tibble: 6 x 3
  Año   Registros Columnas
  <chr>   <int>     <int>
1 2020     114102         18
2 2021     122629         18
3 2022     123383         18
4 2023     131370         18
5 2024     131741         18
6 2025      64974         19
```

```
tabla_variabales
```

```
# A tibble: 19 x 7
  Variable   `2020` `2021` `2022` `2023` `2024` `2025`
  <chr>     <chr>  <chr>  <chr>  <chr>  <chr>  <chr>
1 Fecha y hora Sí     Sí     Sí     Sí     Sí     Sí
2 CO        Sí     Sí     Sí     Sí     Sí     Sí
3 NO        Sí     Sí     Sí     Sí     Sí     Sí
4 NO2       Sí     Sí     Sí     Sí     Sí     Sí
5 NOX       Sí     Sí     Sí     Sí     Sí     Sí
6 O3        Sí     Sí     Sí     Sí     Sí     Sí
```

7	PM10	Sí	Sí	Sí	Sí	Sí	Sí
8	PM2.5	Sí	Sí	Sí	Sí	Sí	Sí
9	BP	Sí	Sí	Sí	Sí	Sí	Sí
10	RAINF	Sí	Sí	Sí	Sí	Sí	Sí
11	RH	Sí	Sí	Sí	Sí	Sí	Sí
12	SO2	Sí	Sí	Sí	Sí	Sí	Sí
13	SR	Sí	Sí	Sí	Sí	Sí	Sí
14	TEMP	Sí	Sí	Sí	Sí	Sí	Sí
15	WS	Sí	Sí	Sí	Sí	Sí	Sí
16	WD	Sí	Sí	Sí	Sí	Sí	Sí
17	Año	Sí	Sí	Sí	Sí	Sí	Sí
18	Estacion	Sí	Sí	Sí	Sí	Sí	Sí
19	date	No	No	No	No	No	Sí

```

diccionario <- tibble(
  Variable = c(
    "Fecha y hora", "CO", "NO", "NO2", "NOX", "O3",
    "PM10", "PM2.5", "BP", "RAINF", "RH", "SO2",
    "SR", "TEMP", "WS", "WD"
  ),

  Descripcion = c(
    "Fecha y hora de la medición",
    "Monóxido de carbono (ppm)",
    "Monóxido de nitrógeno (ppb)",
    "Dióxido de nitrógeno (ppb)",
    "Óxidos de nitrógeno, suma de NO + NO2 (ppb)",
    "Ozono (ppb)",
    "Material particulado menor a 10 micrómetros (µg/m3)",
    "Material particulado menor a 2.5 micrómetros (µg/m3)",
    "Presión atmosférica (mm Hg)",
    "Precipitación (mm/Hr)",
    "Humedad relativa (%)",
    "Dióxido de azufre (ppb)",
    "Radiación solar (kW/m2)",
    "Temperatura (°C)",
    "Velocidad del viento (Km/hr)",
    "Dirección del viento (°)"
  ),

  Tipo = c(
    "Fecha-hora",

```

```

    rep("Numérico", 15)
  )
)

rangos <- tribble(
  ~Año, ~PM10, ~PM2.5, ~O3, ~NO, ~NO2, ~NOX, ~SO2, ~CO, ~RH, ~WS, ~TEMP, ~SR, ~BP, ~WD, ~RAINF,
  2020, "0-800", "0-205.94", "0-153", "0-500", "0-200", "0-500", "0-200", "0-20", "0-100", "0-40",
  2021, "0-800", "0-325", "0-175", "0-350", "0-100", "0-400", "0-300", "0-10", "0-100", "0-40",
  2022, "0-999", "0-450", "0-160", "0-400", "0-175", "0-420", "0-200", "0-8", "0-100", "0-35",
  2023, "0-900", "0-800", "0-175", "0-500", "0-175", "0-500", "0-250", "0-14", "0-100", "0-40",
  2024, "0-999", "0-999", "0-180", "0-400", "0-130", "0-500", "0-150", "0-18", "0-100", "0-38",
  2025, "0-820", "0-350", "0-185", "0-350", "0-175", "0-400", "0-405", "0-10", "0-100", "0-40",
)

diccionario

```

```

# A tibble: 16 x 3
  Variable      Descripcion      Tipo
  <chr>         <chr>              <chr>
1 Fecha y hora Fecha y hora de la medición Fecha-
hora
2 CO           Monóxido de carbono (ppm)      Numérico
3 NO           Monóxido de nitrógeno (ppb)    Numérico
4 NO2          Dióxido de nitrógeno (ppb)    Numérico
5 NOX          Óxidos de nitrógeno, suma de NO + NO2 (ppb) Numérico
6 O3          Ozono (ppb)                  Numérico
7 PM10         Material particulado menor a 10 micrómetros (µg/m3) Numérico
8 PM2.5        Material particulado menor a 2.5 micrómetros (µg/m3) Numérico
9 BP          Presión atmosférica (mm Hg)    Numérico
10 RAINF       Precipitación (mm/Hr)         Numérico
11 RH          Humedad relativa (%)          Numérico
12 SO2         Dióxido de azufre (ppb)       Numérico
13 SR          Radiación solar (kW/m2)       Numérico
14 TEMP        Temperatura (°C)              Numérico
15 WS          Velocidad del viento (Km/hr)   Numérico
16 WD          Dirección del viento (°)       Numérico

```

```

rangos

```

```

# A tibble: 6 x 16

```

	Año	PM10	PM2.5	O3	NO	NO2	NOX	SO2	CO	RH	WS	TEMP	SR
	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>
1	2020	0-800	0-205~	0-153	0-500	0-200	0-500	0-200	0-20	0-100	0-75	0-41	0-
1													
2	2021	0-800	0-325	0-175	0-350	0-100	0-400	0-300	0-10	0-100	0-40	-6.5~	0-
1													
3	2022	0-999	0-450	0-160	0-400	0-175	0-420	0-200	0-8	0-100	0-35	-5-45	0-
1.													
4	2023	0-900	0-800	0-175	0-500	0-175	0-500	0-250	0-14	0-100	0-40	0-45	0-
1													
5	2024	0-999	0-999	0-180	0-400	0-130	0-500	0-150	0-18	0-100	0-38	-4-4~	0-
1.													
6	2025	0-820	0-350	0-185	0-350	0-175	0-400	0-405	0-10	0-100	0-40	-4.5~	0-
1.2													

i 3 more variables: BP <chr>, WD <chr>, RAINF <chr>

```

tabla_faltantes <- purrr::imap_dfr(
  bases,
  ~ .x |>
    summarise(
      across(
        everything(),
        list(
          Nulos = ~ sum(is.na(.)),
          Porcentaje = ~ round(mean(is.na(.)) * 100, 2)
        )
      )
    ) |>
  pivot_longer(
    everything(),
    names_to = c("Variable", ".value"),
    names_pattern = "(.*)_(Nulos|Porcentaje)"
  ) |>
  mutate(Año = .y)
)

```

```

tabla_valores <- purrr::imap_dfr(
  bases,
  ~ .x |>
    select(where(is.numeric)) |>
    summarise(
      across(

```



```

    everything(),
    list(
      Min = ~ ifelse(all(is.na(.)), NA, min(., na.rm = TRUE)),
      Max = ~ ifelse(all(is.na(.)), NA, max(., na.rm = TRUE)),
      Media = ~ ifelse(all(is.na(.)), NA, mean(., na.rm = TRUE))
    )
  ) |>
  pivot_longer(
    everything(),
    names_to = c("Variable", ".value"),
    names_pattern = "(.*)_(Min|Max|Media)"
  ) |>
  mutate(Año = .y)
)

limites <- tribble(
  ~Año, ~Variable, ~Min, ~Max,
  2020, "PM10", 0, 800,
  2020, "PM2.5", 0, 205.94,
  2020, "O3", 0, 153,
  2020, "NO", 0, 500,
  2020, "NO2", 0, 200,
  2020, "NOX", 0, 500,
  2020, "SO2", 0, 200,
  2020, "CO", 0, 20,
  2020, "RH", 0, 100,
  2020, "WS", 0, 75,
  2020, "TEMP", 0, 41,
  2020, "SR", 0, 1,
  2020, "BP", 690, 750,
  2020, "WD", 0, 360,
  2020, "RAINF", 0, 30,

  2021, "PM10", 0, 800,
  2021, "PM2.5", 0, 325,
  2021, "O3", 0, 175,
  2021, "NO", 0, 350,
  2021, "NO2", 0, 100,
  2021, "NOX", 0, 400,
  2021, "SO2", 0, 300,
  2021, "CO", 0, 10,

```

```
2021, "RH", 0, 100,
2021, "WS", 0, 40,
2021, "TEMP", -6.5, 45,
2021, "SR", 0, 1,
2021, "BP", 690, 740,
2021, "WD", 0, 360,
2021, "RAINF", 0, 80,

2022, "PM10", 0, 999,
2022, "PM2.5", 0, 450,
2022, "O3", 0, 160,
2022, "NO", 0, 400,
2022, "NO2", 0, 175,
2022, "NOX", 0, 420,
2022, "SO2", 0, 200,
2022, "CO", 0, 8,
2022, "RH", 0, 100,
2022, "WS", 0, 35,
2022, "TEMP", -5, 45,
2022, "SR", 0, 1.25,
2022, "BP", 700, 740,
2022, "WD", 0, 360,
2022, "RAINF", 0, 25,

2023, "PM10", 0, 900,
2023, "PM2.5", 0, 800,
2023, "O3", 0, 175,
2023, "NO", 0, 500,
2023, "NO2", 0, 175,
2023, "NOX", 0, 500,
2023, "SO2", 0, 250,
2023, "CO", 0, 14,
2023, "RH", 0, 100,
2023, "WS", 0, 40,
2023, "TEMP", 0, 45,
2023, "SR", 0, 1,
2023, "BP", 690, 740,
2023, "WD", 0, 360,
2023, "RAINF", 0, 70,

2024, "PM10", 0, 999,
2024, "PM2.5", 0, 999,
```

```

2024, "O3", 0, 180,
2024, "NO", 0, 400,
2024, "NO2", 0, 130,
2024, "NOX", 0, 500,
2024, "SO2", 0, 150,
2024, "CO", 0, 18,
2024, "RH", 0, 100,
2024, "WS", 0, 38,
2024, "TEMP", -4, 45.5,
2024, "SR", 0, 1.26,
2024, "BP", 687.5, 740,
2024, "WD", 0, 360,
2024, "RAINF", 0, 50,

2025, "PM10", 0, 820,
2025, "PM2.5", 0, 350,
2025, "O3", 0, 185,
2025, "NO", 0, 350,
2025, "NO2", 0, 175,
2025, "NOX", 0, 400,
2025, "SO2", 0, 405,
2025, "CO", 0, 10,
2025, "RH", 0, 100,
2025, "WS", 0, 40,
2025, "TEMP", -4.5, 45,
2025, "SR", 0, 1.2,
2025, "BP", 688, 740,
2025, "WD", 0, 360,
2025, "RAINF", 0, 25
)

tabla_fdr <- purrr::imap_dfr(
  bases,
  function(datos, año) {

    limites_año <- limites |>
      filter(Año == as.numeric(año))

    purrr::pmap_dfr(
      limites_año,
      function(Año, Variable, Min, Max) {

```

```

    x <- datos[[Variable]]

    tibble(
      Año = Año,
      Variable = Variable,
      Min_permitido = Min,
      Max_permitido = Max,
      Fuera_de_rango = sum(x < Min | x > Max, na.rm = TRUE)
    )
  }
)
}
)

tabla_faltantes

```

```

# A tibble: 109 x 4
  Variable      Nulos Porcentaje Año
  <chr>         <int>      <dbl> <chr>
1 Fecha y hora     0         0    2020
2 CO              49801      43.6  2020
3 NO              69722      61.1  2020
4 NO2             79349      69.5  2020
5 NOX             74897      65.6  2020
6 O3              69107      60.6  2020
7 PM10            8615       7.55  2020
8 PM2.5          27224      23.9  2020
9 BP             14673      12.9  2020
10 RAINF         16483      14.4  2020
# i 99 more rows

```

```
tabla_valores
```

```

# A tibble: 96 x 5
  Variable    Min    Max   Media Año
  <chr>    <dbl> <dbl>   <dbl> <chr>
1 CO      0.05  17.7   1.56  2020
2 NO      0.5   500   15.6  2020
3 NO2     0    189.   8.82  2020
4 NOX     0.5   500   25.2  2020
5 O3      1    159   26.7  2020

```

```

6 PM10      2      763      53.2      2020
7 PM2.5     2      206.      20.9      2020
8 BP        0      748.      715.      2020
9 RAINF     0       26       0.0100  2020
10 RH       0       98       58.3      2020
# i 86 more rows

```

```
tabla_fdr
```

```

# A tibble: 90 x 5
  Año Variable Min_permitido Max_permitido Fuera_de_rango
  <dbl> <chr>      <dbl>      <dbl>      <int>
1  2020 PM10          0          800          0
2  2020 PM2.5        0          206.          0
3  2020 O3           0          153          1
4  2020 NO           0          500          0
5  2020 NO2          0          200          0
6  2020 NOX          0          500          0
7  2020 SO2          0          200          0
8  2020 CO           0           20          0
9  2020 RH           0          100          0
10 2020 WS           0           75          6
# i 80 more rows

```

Se utilizarán los registros de las estaciones de monitoreo desde 2020 a 2025. Esto es porque al trabajar con un modelo predictivo, se necesitarán la mayor cantidad de variables posibles. Las variables meteorológicas de presión barométrica, precipitación, humedad relativa, radiación solar, temperatura, velocidad y dirección del viento se utilizarán como variables independientes, ya que el objetivo es estudiar su relación con la contaminación atmosférica. Las variables de contaminantes serán consideradas como variables objetivo y de esta manera se modelará cada contaminante independientemente. La selección final de las variables objetivo dependerá de la practicidad y qué tanto nos proporcionen un resultado relevante, excluyendo aquellas que contengan demasiados valores faltantes o una correlación muy baja como para construir y validar un modelo predictivo confiable.

```

datos_unidos <- bind_rows(bases)

duplicados <- datos_unidos |>
  count(Año, Estacion, `Fecha y hora`) |>
  filter(n > 1)

duplicados

```

```
# A tibble: 14 x 4
  Año Estacion `Fecha y hora`      n
  <dbl> <chr>    <chr>          <int>
1  2025 NE      <NA>            4344
2  2025 NE2     <NA>            4343
3  2025 NE3     <NA>            4321
4  2025 NO      <NA>            4344
5  2025 NO2     <NA>            4344
6  2025 NO3     <NA>            4321
7  2025 NTE     <NA>            4345
8  2025 NTE2    <NA>            4344
9  2025 SE      <NA>            4344
10 2025 SE2     <NA>            4344
11 2025 SE3     <NA>            4344
12 2025 SO      <NA>            4203
13 2025 SO2     <NA>            4344
14 2025 SUR     <NA>            4344
```

Así verificamos que no hay valores duplicados.

Los valores faltantes los vamos a dejar igual, ya que como son considerados NA, fácilmente pueden ser reemplazados en un futuro por una media o mediana si se considera necesario. De la misma manera, se van a usar datos de entrenamiento y de test, por eso se necesita la mayor cantidad posible.

```
variables_numericas <- c(
  "CO", "NO", "NO2", "NOX", "O3",
  "PM10", "PM2.5", "BP", "RAINF",
  "RH", "SO2", "SR", "TEMP", "WS", "WD"
)

detectar_outliers <- function(datos, variable) {

  datos |>
    group_by(Estacion) |>
    mutate(
      Q1 = quantile(.data[[variable]], 0.25, na.rm = TRUE),
      Q3 = quantile(.data[[variable]], 0.75, na.rm = TRUE),
      IQR = Q3 - Q1,
      Lim_inf = Q1 - 1.5 * IQR,
      Lim_sup = Q3 + 1.5 * IQR,
      Outlier = .data[[variable]] < Lim_inf |
                .data[[variable]] > Lim_sup
    )
}
```

```

) |>
filter(Outlier == TRUE) |>
ungroup() |>
select(
  Año,
  Estacion,
  `Fecha y hora`,
  all_of(variable),
  Q1,
  Q3,
  Lim_inf,
  Lim_sup
)
}

tabla_outliers <- map_dfr(
  variables_numericas,
  function(var) {

    resultado <- detectar_outliers(datos_limpios, var)

    total_validos <- sum(!is.na(datos_limpios[[var]]))
    total_outliers <- nrow(resultado)

    tibble(
      Variable = var,
      Datos_validos = total_validos,
      Outliers = total_outliers,
      Porcentaje = round(
        total_outliers / total_validos * 100,
        3
      )
    )
  }
)

```

Como podemos observar en nuestra tabla de valores atípicos, usando el rango intercuartílico, algunos valores llegan a ser hasta el 11.82% de los datos. Claramente esto es una cantidad significativa y relevante que no se puede eliminar de la base de datos.

```

datos_modelo <- datos_limpios

datos_escalados <- datos_limpios |>
  mutate(
    across(
      c(BP, RAINF, RH, SR, TEMP, WS, WD),
      ~ as.numeric(scale(.x))
    )
  )

```

En esta sección normalizamos ciertas variables continuas para que se aproximen en una media 0 y desviación estándar 1. Esto por si queremos hacer un PCA, KNN, SVM, etc. Si no, mantenemos los valores continuos (“datos_modelo”).

```

datos_modelo <- datos_limpios |>
  mutate(
    `Fecha y hora` = case_when(
      grepl("^[0-9]+\\.?.*[0-9]*$", `Fecha y hora`) ~
        as.POSIXct(
          as.numeric(`Fecha y hora`) * 86400,
          origin = "1899-12-30",
          tz = "UTC"
        ),

    TRUE ~ lubridate::parse_date_time(
      `Fecha y hora`,
      orders = c(
        "dmy HM",
        "dmy HMS",
        "ymd HM",
        "ymd HMS",
        "mdy HM",
        "mdy HMS"
      )
    )
  ),

  Hora = lubridate::hour(`Fecha y hora`),
  Dia = lubridate::day(`Fecha y hora`),
  Mes = lubridate::month(`Fecha y hora`),
  Dia_semana = lubridate::wday(
    `Fecha y hora`,

```



```

    label = TRUE
  )
)

```

Warning: There was 1 warning in `mutate()`.
 i In argument: `Fecha y hora = case\_when(...)`.
 Caused by warning:
 ! All formats failed to parse. No formats found.

Se construyeron atributos de tiempo para poder encontrar patrones estacionales en los contaminantes.

```

datos_modelo <- datos_modelo |>
  mutate(
    Estacion = as.factor(Estacion),
    Dia_semana = as.factor(Dia_semana)
  )

levels(datos_modelo$Estacion)

```

```

[1] "CE"  "NE"  "NE2" "NE3" "NO"  "NO2" "NO3" "NTE" "NTE2" "SE"
[11] "SE2" "SE3" "SO"  "SO2" "SUR"

```

```

levels(datos_modelo$Dia_semana)

```

```

[1] "Sun" "Mon" "Tue" "Wed" "Thu" "Fri" "Sat"

```

1.2.1 Informe preparación de los datos

La base de datos consolidada integra los 6 años de registros proporcionados por SIMA (2020-2025), sumando un total de 688,199 registros horarios distribuidos en distintas estaciones de monitoreo de la Zona Metropolitana de Monterrey. Cada año contribuyó así:

- 2020 - 114,102 registros
- 2021 - 122,629 registros
- 2022 - 123,383 registros
- 2023 - 131,370 registros
- 2024 - 131,741 registros
- 2025 - 64,974 registros (año parcial)

La base contiene 18 variables por registro en la mayoría de los años. Una variable de fecha y hora, 8 variables de contaminantes atmosféricos criterio (CO, NO, NO₂, NO_x, O₃, PM₁₀, PM_{2.5}, SO₂), 7 variables meteorológicas (BP, RAINF, RH, SR, TEMP, WS, WD) y 2 variables identificadoras (Año, Estación).

*Algo importante a mencionar es que la base de 2025 presenta 19 columnas en vez de 18, ya que el archivo tiene una columna adicional llamada “date” junto con la columna de Fecha y hora. Esto, junto con la corrección de valores erróneos, se documentará y resolverá en la siguiente entrega.

Datos faltantes

El porcentaje de valores faltantes varía considerablemente por variable, año y estación, como se documenta en la tabla “tabla_faltantes” generada en el código. Se observó que algunas variables (como NO, NO₂ y NO_x) presentan proporciones muy altas de valores nulos en ciertos años y estaciones. Esto tiene sentido al leer la “NOTA” de color rojo en el archivo Excel de Etiquetas de las bases de datos, también proporcionado para realizar este proyecto, donde se menciona que “Todos los valores que salgan con esta bandera debe hacer 0 a excepción de los que están en SE2 que en vez de 0, será 0.36”. Esta nota aplica para NO y Nox.

Datos duplicados

Se verificó la existencia de registros duplicados a nivel de Año, Estación y Fecha y hora con un conteo de combinaciones repetidas (“duplicados”). El resultado confirmó que, conceptualmente, no existen registros duplicados en la base. Se destaca que “conceptualmente”, ya que, en 2025, no se pudo evaluar el criterio debido a que la columna de fecha (date) presenta un formato distinto al encontrado en las otras bases de datos. Esta verificación se completará en la siguiente entrega junto con la corrección de esa inconsistencia estructural.

Datos atípicos (outliers)

Se aplicó el método de rango intercuartílico por estación para cada uno de las variables numéricas. Los resultados, en “tabla_outliers” muestran que el porcentaje de valores atípicos varía por variable, llegando hasta un 11.82% en el caso más alto. Debido a esta magnitud, se decidió no eliminar los outliers de esta entrega, ya que, en el caso de los contaminantes, probablemente representan episodios reales de contaminación crítica. En futuras entregas se considerará generar variables “bandera” que ayuden a marcar cada registro atípico sin eliminarlo, preservando toda la información para su uso posterior en análisis de sensibilidad de los modelos.

Variables categóricas

Se identificaron “Estacion” y “Dia_semana” como variables categóricas relevantes para el análisis, las cuales fueron convertidas a tipo factor. Se decidió no generar variables dummy en esta etapa, ya que la transformación depende del tipo de modelo predictivo que se seleccione finalmente.

Binning

No se consideró necesario discretizar las variables de contaminantes ni meteorológicas en esta

etapa, ya que el objetivo del proyecto es predecir concentraciones continuas utilizando modelos de regresión, y discretizar podría implicar una pérdida de información para este fin.

Transformación y escalamiento

Se generó una versión escalada y normalizada de las variables meteorológicas continuas (datos_escalados), disponible en caso de aplicar técnicas sensibles a la escala de datos. Para el resto de los modelos, se puede conservar la versión con los valores en su escala original (datos_modelo).

Por otra parte, a partir de la variable Fecha y hora, se derivaron las variables Hora, Día, Mes y Día de la semana, con el fin de identificar patrones temporales y estacionales en la relación entre meteorología y contaminantes.

Además de la unión de los datos de los 6 años, no fue necesario reestructurar la base de datos, ya que el formato largo por observación de horario y estación es correcto para las técnicas de modelado predictivo contempladas.

Otros planes a futuro

Se contempla la posibilidad de agrupar de forma estacional (invierno, verano, otoño, primavera) o mensual los datos, con el objetivo de responder de manera más completa la pregunta de investigación 3 (si la relación meteorología-contaminante varía por estacionalidad). Esto, en caso de realizarse, crearía variables nuevas.

1.2.2 Link Github:

<https://github.com/Reyivan777/Reto-Multivariados>

1.2.3 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: Claude.

Uso realizado: Apoyo en la búsqueda de referencias bibliográficas complementarias, así como en la estructuración de borradores de las secciones del informe de la Parte I. Igualmente, apoyo con sintaxis del código de la Parte 2.

Secciones donde se utilizó: Parte I. Conociendo el Negocio y Parte II. Comprensión y Preparación de los Datos.

Validación realizada por los estudiantes: Hemos revisado, editado y validado el contenido generado, verificando la veracidad de las referencias y asegurar coherencia con el objetivo del proyecto. Como equipo asumimos la responsabilidad del contenido final entregado.