

Reporte de la Situación Problema

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-08-28

Table of contents

1	Etapa 1. Conociendo el negocio	2
1.1	PARTE I. Conociendo el Negocio	2
1.1.1	Presentación general del proyecto (resumen del proyecto).	2
1.1.2	Revisión de bibliografía	2
1.1.3	Descripción del problema específico	3
1.1.4	Objetivos de este proyecto	4
1.1.5	Justificación de los objetivos	4
1.1.6	Descripción de las fuentes de información	5
1.2	PARTE II. Comprensión y preparación de los datos	5
1.2.1	1. Carga y homologación de los datos	5
1.2.2	2. Exploración inicial de estructura y calidad	6
1.2.3	3. Limpieza de los datos	9
1.2.4	4. Preparación para el análisis y modelado	9
1.2.5	5. Transformaciones y atributos derivados	10
1.2.6	Informe preparación de los datos	11
2	Etapa 2. Comprensión y preparación de los datos	13
2.1	1. Comprensión descriptiva de los datos	13
2.1.1	1.1 Objetivo del análisis	13
2.1.2	1.2 Variables de interés	13
2.1.3	1.3 Dimensión y estructura del conjunto de datos	15
2.1.4	1.4 Estadística descriptiva de variables cuantitativas	16
2.1.5	1.5 Distribución de las variables	17

2.1.6	1.6 Análisis por estación de monitoreo	21
2.1.7	1.7 Análisis de correlación	25
2.1.8	1.8 Calidad de los datos posterior a la limpieza	30
2.1.9	1.9 Dificultades de medición de la calidad del aire	34
2.1.10	1.10 Conclusiones y siguientes pasos	34
3	Declaratoria y referencias	35
3.1	Link GitHub:	35
3.2	Declaratoria de uso IA	35
3.3	Referencias bibliográficas	35

1 Etapa 1. Conociendo el negocio

1.1 PARTE I. Conociendo el Negocio

1.1.1 Presentación general del proyecto (resumen del proyecto).

La contaminación atmosférica representa un problema importante de salud pública debido a los efectos que contaminantes como PM2.5, PM10, O₃, NO_x, SO₂ y CO pueden generar en la población. En zonas urbanas como el Área Metropolitana de Monterrey, su monitoreo resulta especialmente relevante debido a la actividad industrial, vehicular y a las condiciones meteorológicas que pueden favorecer la acumulación o dispersión de contaminantes.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) registra información sobre la calidad del aire mediante una red de estaciones que miden concentraciones de contaminantes y variables meteorológicas. Estas mediciones permiten conocer las condiciones ambientales de distintas zonas y proporcionan información útil para analizar el comportamiento de la contaminación atmosférica.

Las condiciones meteorológicas influyen directamente en la dinámica de los contaminantes. Variables como temperatura, humedad, velocidad y dirección del viento, presión, precipitación y radiación solar pueden modificar su formación, transporte y dispersión. Dado esto, en este proyecto ha surgido la pregunta: ¿Es posible aprovechar los registros históricos de SIMA para entender y anticipar el comportamiento de la contaminación atmosférica a partir de las variables meteorológicas? A continuación se presenta la revisión bibliográfica que sustenta esta pregunta, así como la descripción del problema, los objetivos del proyecto y las fuentes de información utilizadas.

1.1.2 Revisión de bibliografía

Sobre la medición de la calidad del aire, su impacto social e importancia.

La contaminación atmosférica es reconocida como uno de los principales riesgos ambientales

para la salud pública. En el Área Metropolitana de Monterrey, Cerón Bretón et al. (2020) encontraron asociaciones entre mayores concentraciones de contaminantes atmosféricos y un incremento en el riesgo de mortalidad diaria, efecto que se agrava con temperaturas elevadas y que resulta especialmente relevante en adultos mayores. A nivel internacional, las Guías de Calidad del Aire 2021 de la Organización Mundial de la Salud (Hoffmann et al., 2021) refuerzan esta relevancia. En zonas donde la contaminación ya es relativamente baja, reducir las concentraciones de contaminantes criterio (PM2.5, PM10, O3, NO2, SO2 y CO) genera beneficios medibles para la salud de la población.

En México, estas guías se traducen en las Normas Oficiales Mexicanas de salud ambiental (NOM-020, 021, 022, 023 y 025-SSA1). Estas establecen los límites permisibles para cada contaminante y sirven como referencia para evaluar el cumplimiento y diseñar políticas de mitigación. La medición de la calidad del aire contribuye a la protección de la salud y a la rendición de cuentas hacia la ciudadanía.

Centrado en el objetivo de trabajo (Modelado predictivo con variables meteorológicas)

Con respecto al uso de variables meteorológicas para predecir contaminantes, Cifuentes et al. (2021) desarrollaron modelos de regresión lineal múltiple, Support Vector Regression y redes neuronales para predecir concentraciones horarias de O3 y PM2.5, encontrando que variables como la radiación solar y la temperatura resultan especialmente útiles cuando no se cuenta con suficiente información directa de contaminantes. Esto ayuda a confirmar la viabilidad de construir modelos predictivos de calidad del aire a partir de datos meteorológicos y provee sugerencias para la priorización de variables durante el modelado.

1.1.3 Descripción del problema específico

El Sistema Integral de Monitoreo Ambiental (SIMA) cuenta con una red de estaciones que registra de forma continua contaminantes atmosféricos, así como variables meteorológicas en la Zona Metropolitana de Monterrey. Sin embargo, esta información histórica no se ha explotado de forma sistemática para anticipar concentraciones de contaminantes a partir de las condiciones meteorológicas, lo cual limita la correcta comunicación de los riesgos que conlleva una calidad del aire crítica para la población.

A partir de esta problemática, este proyecto busca responder las siguientes preguntas de investigación:

- ¿Cuáles son las variables meteorológicas (como humedad, temperatura, dirección del viento, radiación solar, etc.) que muestran mayor relación con las concentraciones de cada contaminante criterio registradas por SIMA?
- ¿Es posible desarrollar modelos estadísticos y/o de aprendizaje automático que, a partir de variables meteorológicas históricas proporcionadas, puedan predecir de manera confiable las concentraciones de estos contaminantes en las estaciones de monitoreo?

- ¿Esta relación entre meteorología y contaminantes varía según la estación del año, la hora del día o la estación de monitoreo específica?

1.1.4 Objetivos de este proyecto

Objetivo general

El objetivo general de este proyecto es desarrollar y evaluar modelos predictivos que permitan estimar las concentraciones de contaminantes atmosféricos criterio en la Zona Metropolitana de Monterrey a partir de variables meteorológicas registradas por SIMA en el periodo 2020-2025, con el fin de aportar herramientas que apoyen la comunicación de riesgos de calidad del aire.

Objetivos específicos

1. Identificar las variables meteorológicas con mayor relación estadística con respecto a las concentraciones de cada contaminante criterio registrado por SIMA.
2. Construir y comparar modelos estadísticos que predigan las concentraciones de contaminantes a partir de variables meteorológicas, seleccionando los contaminantes objetivo con base en la calidad y disponibilidad de datos.
3. Evaluar si la relación entre las variables meteorológicas y los contaminantes varía según la estacionalidad temporal o la estación de monitoreo, con el fin de identificar patrones temporales y espaciales de relevancia.

1.1.5 Justificación de los objetivos

La revisión bibliográfica mencionada anteriormente confirma que existe evidencia sólida de que las concentraciones de contaminantes atmosféricos están asociadas a riesgos de salud significativos, incluso en niveles relativamente bajos (Hoffmann et al., 2021), y que esta relación se ha documentado específicamente en la Zona Metropolitana de Monterrey (abreviada como “ZMM”). Esto justifica la relevancia social del objetivo general, ya que cualquier elemento que ayude a anticipar concentraciones de contaminantes tiene un impacto en la protección de la salud pública local.

Igualmente, se ha demostrado que metodológicamente es viable predecir contaminantes como O₃ y PM_{2.5} basándose en variables meteorológicas mediante técnicas estadísticas y de aprendizaje automático, especialmente en contextos donde no se cuenta con un monitoreo continuo de todos los contaminantes (Cifuentes et al., 2021). Existe un área de oportunidad para aplicar este tipo de modelado a los datos históricos que genera SIMA y explorar si la relación meteorología-contaminante varía según la estacionalidad o la ubicación de las estaciones de esta zona en Monterrey.

Con este proyecto se busca contribuir aprovechando la infraestructura de datos ya existente de SIMA (de 2020 a 2025) para construir modelos predictivos adaptados a las condiciones específicas de Monterrey, aplicando la metodología en un contexto geográfico y temporal.

1.1.6 Descripción de las fuentes de información

La fuente de información utilizada en este proyecto proviene del Sistema Integral de Monitoreo Ambiental (SIMA), organismo encargado de operar la red de estaciones de monitoreo de calidad del aire en el estado de Nuevo León. SIMA aporta de manera pública bases de datos históricas que contienen registros de las distintas estaciones de monitoreo en la ZMM. Cada registro corresponde a una medición por hora y estación. Este registro incluye variables de contaminantes atmosféricos criterio [monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 micrómetros (PM₁₀), partículas menores a 2.5 micrómetros (PM_{2.5}) y dióxido de azufre (SO₂), entre otros], e igualmente contiene variables meteorológicas, como precipitación (RAINF), humedad relativa (RH), radiación solar (SR), temperatura (TEMP), velocidad del viento (WS) y su dirección (WD), entre otras.

La combinación de estas variables permite estudiar la relación entre condiciones atmosféricas y concentraciones de contaminantes en el tiempo y en distintos puntos de la ZMM. Como el objetivo del proyecto es predictivo, se eligió integrar los seis años proporcionados en una sola base. Las variables meteorológicas se consideran como variables predictoras (independientes), mientras que los contaminantes se tratan como variables objetivo, modelando cada uno de forma independiente.

La selección final de los contaminantes a modelar dependerá de los datos disponibles y de la fuerza de su relación con las variables meteorológicas. Esto se desarrolla en la sección de preparación de datos, ubicada más adelante en este mismo entregable.

1.2 PARTE II. Comprensión y preparación de los datos

1.2.1 1. Carga y homologación de los datos

Primero se cargan las librerías necesarias y se integran las bases de 2020 a 2025. Durante la lectura se homologan los nombres de las variables para que todos los años tengan una estructura consistente antes de realizar la revisión de calidad.

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

here() starts at /home/runner/work/Reto-Multivariados/Reto-Multivariados

Attaching package: 'maps'

The following object is masked from 'package:purrr':

map

El objeto `datos_limpios` concentra los registros de los seis años y será la base sobre la que se aplicarán las decisiones de limpieza y preparación de esta etapa.

1.2.2 2. Exploración inicial de estructura y calidad

Antes de modificar los datos se revisan las dimensiones de cada año, la disponibilidad de variables, sus descripciones, los valores faltantes y los rangos esperados. Esta revisión permite detectar inconsistencias y definir qué observaciones requieren corrección.

```
# A tibble: 6 x 3
  Año   Registros Columnas
<chr>   <int>   <int>
1 2020     114102      18
2 2021     122629      18
3 2022     123383      18
4 2023     131370      18
5 2024     131741      18
6 2025      64974      18
```

```
# A tibble: 18 x 7
  Variable `2020` `2021` `2022` `2023` `2024` `2025`
<chr>     <chr> <chr> <chr> <chr> <chr> <chr>
1 fecha y hora Sí     Sí     Sí     Sí     Sí     Sí
2 CO       Sí     Sí     Sí     Sí     Sí     Sí
3 NO       Sí     Sí     Sí     Sí     Sí     Sí
4 NO2      Sí     Sí     Sí     Sí     Sí     Sí
5 NOX      Sí     Sí     Sí     Sí     Sí     Sí
6 O3       Sí     Sí     Sí     Sí     Sí     Sí
7 PM10     Sí     Sí     Sí     Sí     Sí     Sí
8 PM2.5    Sí     Sí     Sí     Sí     Sí     Sí
9 BP       Sí     Sí     Sí     Sí     Sí     Sí
```

10	RAINF	Sí	Sí	Sí	Sí	Sí	Sí
11	RH	Sí	Sí	Sí	Sí	Sí	Sí
12	SO2	Sí	Sí	Sí	Sí	Sí	Sí
13	SR	Sí	Sí	Sí	Sí	Sí	Sí
14	TEMP	Sí	Sí	Sí	Sí	Sí	Sí
15	WS	Sí	Sí	Sí	Sí	Sí	Sí
16	WD	Sí	Sí	Sí	Sí	Sí	Sí
17	Año	Sí	Sí	Sí	Sí	Sí	Sí
18	Estacion	Sí	Sí	Sí	Sí	Sí	Sí

A tibble: 16 x 3

Variable <chr>	Descripcion <chr>	Tipo <chr>
1 fecha y hora hora	Fecha y hora de la medición	Fecha-
2 CO	Monóxido de carbono (ppm)	Numérico
3 NO	Monóxido de nitrógeno (ppb)	Numérico
4 NO2	Dióxido de nitrógeno (ppb)	Numérico
5 NOX	Óxidos de nitrógeno, suma de NO + NO2 (ppb)	Numérico
6 O3	Ozono (ppb)	Numérico
7 PM10	Material particulado menor a 10 micrómetros (µg/m3)	Numérico
8 PM2.5	Material particulado menor a 2.5 micrómetros (µg/m3)	Numérico
9 BP	Presión atmosférica (mm Hg)	Numérico
10 RAINF	Precipitación (mm/Hr)	Numérico
11 RH	Humedad relativa (%)	Numérico
12 SO2	Dióxido de azufre (ppb)	Numérico
13 SR	Radiación solar (kW/m2)	Numérico
14 TEMP	Temperatura (°C)	Numérico
15 WS	Velocidad del viento (Km/hr)	Numérico
16 WD	Dirección del viento (°)	Numérico

A tibble: 6 x 16

	Año	PM10	PM2.5	O3	NO	NO2	NOX	SO2	CO	RH	WS	TEMP	SR
	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>
1	2020	0-800	0-205~	0-153	0-500	0-200	0-500	0-200	0-20	0-100	0-75	0-41	0-
1													
2	2021	0-800	0-325	0-175	0-350	0-100	0-400	0-300	0-10	0-100	0-40	-6.5~	0-
1													
3	2022	0-999	0-450	0-160	0-400	0-175	0-420	0-200	0-8	0-100	0-35	-5-45	0-
1.													
4	2023	0-900	0-800	0-175	0-500	0-175	0-500	0-250	0-14	0-100	0-40	0-45	0-
1													

```

5 2024 0-999 0-999 0-180 0-400 0-130 0-500 0-150 0-18 0-100 0-38 -4-4~ 0-
1.~
6 2025 0-820 0-350 0-185 0-350 0-175 0-400 0-405 0-10 0-100 0-40 -4.5~ 0-
1.2
# i 3 more variables: BP <chr>, WD <chr>, RAINF <chr>

```

```

# A tibble: 108 x 4
  Variable      Nulos Porcentaje Año
  <chr>         <int>      <dbl> <chr>
1 fecha y hora      0          0 2020
2 CO              49801      43.6 2020
3 NO              69722      61.1 2020
4 NO2             79349      69.5 2020
5 NOX             74897      65.6 2020
6 O3              69107      60.6 2020
7 PM10            8615       7.55 2020
8 PM2.5          27224      23.9 2020
9 BP             14673      12.9 2020
10 RAINF         16483      14.4 2020
# i 98 more rows

```

```

# A tibble: 96 x 5
  Variable    Min    Max    Media Año
  <chr>      <dbl> <dbl>   <dbl> <chr>
1 CO        0.05  17.7    1.56 2020
2 NO        0.5   500    15.6 2020
3 NO2       0    189.    8.82 2020
4 NOX       0.5   500    25.2 2020
5 O3        1    159    26.7 2020
6 PM10      2    763    53.2 2020
7 PM2.5     2   206.    20.9 2020
8 BP        0   748.   715. 2020
9 RAINF     0    26     0.0100 2020
10 RH       0    98    58.3 2020
# i 86 more rows

```

```

# A tibble: 90 x 5
  Año Variable Min_permitido Max_permitido Fuera_de_rango
  <dbl> <chr>         <dbl>         <dbl>         <int>
1 2020 PM10              0             800             0
2 2020 PM2.5            0            206.             0
3 2020 O3                0            153             1

```



```

4  2020 NO          0          500          0
5  2020 NO2         0          200          0
6  2020 NOX         0          500          0
7  2020 SO2         0          200          0
8  2020 CO          0           20          0
9  2020 RH          0          100          0
10 2020 WS          0           75          6
# i 80 more rows

```

1.2.3 3. Limpieza de los datos

A partir de los límites revisados se identifican los registros fuera de rango y se corrigen los casos detectados previamente. Los valores -9999 utilizados como banderas de ausencia en algunas variables meteorológicas también se convierten a NA, de modo que la Etapa 2 reciba directamente la versión ya depurada del conjunto.

```

# A tibble: 11,777 x 7
  Año Estacion `fecha y hora` Variable Valor Min_permitido Max_permitido
  <dbl> <chr>    <chr>          <chr>    <dbl>      <dbl>      <dbl>
1  2020 NTE2    43879.791666666664 O3        159         0         153
2  2020 NE      43936.458333333336 WS         126.        0          75
3  2020 NE      43936.5          WS         128.        0          75
4  2020 NE      43936.541666666664 WS         126.        0          75
5  2020 NE      43936.583333333336 WS         127.        0          75
6  2020 NE      43936.625        WS         127.        0          75
7  2020 NE      43936.666666666664 WS         126.        0          75
8  2020 SE      44155.083333333336 TEMP        -4.43        0          41
9  2020 SE      44155.625        TEMP        -6.61        0          41
10 2020 SE      44163.625        TEMP        -8.81        0          41
# i 11,767 more rows

```

```

# A tibble: 0 x 3
# i 3 variables: Año <dbl>, Variable <chr>, Fuera_de_rango <int>

```

1.2.4 4. Preparación para el análisis y modelado

Se conservarán los registros de 2020 a 2025 porque el objetivo predictivo requiere una cantidad amplia de observaciones. Las variables meteorológicas se consideran variables independientes y los contaminantes posibles variables objetivo. La selección final de contaminantes dependerá de la disponibilidad de información y de la relación que presenten con las variables meteorológicas.

También se verifica que no existan registros duplicados y se revisan los valores atípicos por estación mediante el rango intercuartílico. Los datos faltantes se conservan como NA para decidir posteriormente si requieren imputación según el modelo seleccionado.

```
# A tibble: 0 x 4
# i 4 variables: Año <dbl>, Estacion <chr>, fecha y hora <chr>, n <int>

# A tibble: 15 x 4
  Variable Datos_validos Outliers Porcentaje
  <chr>          <int>      <int>      <dbl>
1 CO             597299      10136       1.70
2 NO             567456      67104      11.8
3 NO2            561853      24811       4.42
4 NOX            567235      46343       8.17
5 O3             582079      13957       2.40
6 PM10           657082      31620       4.81
7 PM2.5          518607      19130       3.69
8 BP             645473      13153       2.04
9 RAINF          654703       9947       1.52
10 RH            616399         0         0
11 SO2           580283      43700       7.53
12 SR            661699      32577       4.92
13 TEMP          642659       4845       0.754
14 WS            636728       8245       1.30
15 WD            626993      40885       6.52
```

Como podemos observar en nuestra tabla de valores atípicos, utilizando el rango intercuartílico, algunos valores llegan a representar hasta el 11.82% de los datos. Esta es una cantidad significativa que no se puede eliminar de la base de datos sin un análisis adicional.

1.2.5 5. Transformaciones y atributos derivados

Se prepara una versión escalada de las variables meteorológicas para técnicas sensibles a la escala y, por separado, una versión de modelado que incorpora atributos temporales derivados de la fecha y hora. De esta forma se preserva `datos_limpios` como la versión base depurada que utilizará la siguiente etapa.

```
[1] "CE"  "NE"  "NE2" "NE3" "NO"  "NO2" "NO3" "NTE" "NTE2" "SE"
[11] "SE2" "SE3" "SO"  "SO2" "SUR"

[1] "Sun" "Mon" "Tue" "Wed" "Thu" "Fri" "Sat"
```

1.2.6 Informe preparación de los datos

La base de datos consolidada integra los seis años de registros proporcionados por SIMA (2020-2025), sumando un total de 688,199 registros horarios distribuidos en distintas estaciones de monitoreo de la Zona Metropolitana de Monterrey. Cada año contribuyó así:

- 2020 - 114,102 registros
- 2021 - 122,629 registros
- 2022 - 123,383 registros
- 2023 - 131,370 registros
- 2024 - 131,741 registros
- 2025 - 64,974 registros (año parcial)

La base contiene 18 variables por registro en la mayoría de los años: una variable de fecha y hora, 8 variables de contaminantes atmosféricos criterio (CO, NO, NO₂, NO_x, O₃, PM₁₀, PM_{2.5}, SO₂), 7 variables meteorológicas (BP, RAINF, RH, SR, TEMP, WS, WD) y 2 variables identificadoras (Año, Estación).

La inconsistencia de nombres de la variable temporal en 2025 se homogeneizó durante la carga de los datos, de modo que tanto **date** como **fecha y hora** se estandarizan bajo el nombre **fecha y hora** para su procesamiento posterior.

Datos faltantes

El porcentaje de valores faltantes varía considerablemente por variable, año y estación, como se documenta en la tabla **tabla_faltantes** generada en el código. Se observó que algunas variables (como NO, NO₂ y NO_x) presentan proporciones muy altas de valores nulos en ciertos años y estaciones. Esto tiene sentido al leer la “NOTA” de color rojo en el archivo Excel de Etiquetas de las bases de datos, también proporcionado para realizar este proyecto, donde se menciona que “Todos los valores que salgan con esta bandera debe hacer 0 a excepción de los que están en SE2 que en vez de 0, será 0.36”. Esta nota aplica para NO y NO_x.

Para el tratamiento de los valores faltantes se establecieron varios puntos. Los valores registrados con la bandera -9999 en las variables meteorológicas se convirtieron a NA en la etapa de limpieza, ya que representan una ausencia de medición y no un valor real. De manera similar, los registros fuera de los rangos operativos definidos por año (documentados en la tabla de límites) se convirtieron a NA, en lugar de eliminarse por completo, para conservar la estructura horaria estándar del conjunto de datos. Los valores faltantes originados por vacíos naturales de la red de monitoreo se mantienen como NA en esta etapa, ya que su tratamiento (imputación por media, mediana, o interpolación temporal) dependerá del modelo predictivo final y del contaminante objetivo seleccionado, decisión que se tomará en la siguiente entrega. No se excluyen registros completos por la presencia de valores faltantes en variables individuales, menos en los casos de inconsistencia estructural ya documentados (como la columna de fecha de 2025). Esta política se aplicó de manera consistente en las cuatro estaciones seleccionadas (NTE, NTE2, NO, NE) y quedó reflejada en la base de datos limpia final (**datos_etapa2_limpio.csv**), disponible en el repositorio de GitHub del equipo.

Datos duplicados

Se verificó que no hay valores duplicados.

Datos atípicos (outliers)

Se aplicó el método del rango intercuartílico por estación para cada una de las variables numéricas. Los resultados en `tabla_outliers` muestran que el porcentaje de valores atípicos varía por variable, llegando hasta un 11.82% en el caso más alto. Debido a esta magnitud, se decidió no eliminar los outliers en esta entrega, ya que, en el caso de los contaminantes, probablemente representan episodios reales de contaminación crítica. En futuras entregas se considerará generar variables “bandera” que ayuden a marcar cada registro atípico sin eliminarlo, preservando toda la información para su uso posterior en análisis de sensibilidad de los modelos.

Variables categóricas

Se identificaron `Estacion` y `Dia_semana` como variables categóricas relevantes para el análisis, las cuales fueron convertidas a tipo factor en `datos_modelo`. Se decidió no generar variables dummy en esta etapa, ya que la transformación depende del tipo de modelo predictivo que se seleccione finalmente.

Binning

No se consideró necesario discretizar las variables de contaminantes ni meteorológicas en esta etapa, ya que el objetivo del proyecto es predecir concentraciones continuas utilizando modelos de regresión y discretizar podría implicar una pérdida de información para este fin.

Transformación y escalamiento

Se generó una versión escalada y estandarizada de las variables meteorológicas continuas (`datos_escalados`), disponible en caso de aplicar técnicas sensibles a la escala de los datos. Para el resto de los modelos, se puede conservar la versión con los valores en su escala original.

Por otra parte, a partir de la variable fecha y hora, se derivaron las variables Hora, Día, Mes y Día de la semana en `datos_modelo`, con el fin de identificar patrones temporales y estacionales en la relación entre meteorología y contaminantes.

Además de la unión de los datos de los seis años, no fue necesario reestructurar la base de datos, ya que el formato largo por observación horaria y estación es correcto para las técnicas de modelado predictivo contempladas.

Otros planes a futuro

Se contempla la posibilidad de agrupar los datos de forma estacional (invierno, verano, otoño, primavera) o mensual, con el objetivo de responder de manera más completa la pregunta de investigación 3 (si la relación meteorología-contaminante varía por estacionalidad). Esto, en caso de realizarse, crearía variables nuevas.

2 Etapa 2. Comprensión y preparación de los datos

2.1 1. Comprensión descriptiva de los datos

2.1.1 1.1 Objetivo del análisis

En esta segunda etapa, el análisis se enfocará en describir y explorar las variables disponibles antes de realizar el modelado. Se estudiarán sus principales características estadísticas, distribuciones, variabilidad, valores atípicos y diferencias entre estaciones de monitoreo. Además, se analizarán las relaciones preliminares entre las variables meteorológicas y las concentraciones de contaminantes, con el propósito de identificar cuáles variables presentan mayor relevancia para la construcción posterior de los modelos predictivos.

2.1.2 1.2 Variables de interés

Para el análisis se seleccionaron las estaciones NTE, NTE2, NO y NE. Las variables del subconjunto se clasifican en contaminantes atmosféricos, variables meteorológicas y variables temporales o espaciales. La tabla siguiente resume su función, tipo, valores posibles y proporción de datos faltantes dentro del conjunto utilizado en la Etapa 2.

Table 1: Descripción de las variables utilizadas en la Etapa 2

Grupo	Variable	Descripción	Tipo	Valores posibles / unidad	% nulos
Contami- nante	CO	Monóxido de carbono	Numérica continua	0-20 ppm*	17.94
Contami- nante	NO	Monóxido de nitrógeno	Numérica continua	0-500 ppb*	20.43
Contami- nante	NO2	Dióxido de nitrógeno	Numérica continua	0-200 ppb*	23.66
Contami- nante	NOX	Óxidos de nitrógeno	Numérica continua	0-500 ppb*	23.38
Contami- nante	O3	Ozono	Numérica continua	0-185 ppb*	24.30
Contami- nante	PM10	Partículas menores a 10 micrómetros	Numérica continua	0-999 µg/m3*	5.51
Contami- nante	PM2.5	Partículas menores a 2.5 micrómetros	Numérica continua	0-999 µg/m3*	19.68
Contami- nante	SO2	Dióxido de azufre	Numérica continua	0-405 ppb*	24.49

Grupo	Variable	Descripción	Tipo	Valores posibles / unidad	% nulos
Meteorológica	BP	Presión atmosférica	Numérica continua	687.5-750 mm Hg*	8.15
Meteorológica	RAINP	Precipitación	Numérica continua	0-80 mm/Hr*	7.47
Meteorológica	RH	Humedad relativa	Numérica continua	0-100 %*	18.87
Meteorológica	SR	Radiación solar	Numérica continua	0-1.26 kW/m2*	4.02
Meteorológica	TEMP	Temperatura	Numérica continua	-6.5-45.5 °C*	14.49
Meteorológica	WS	Velocidad del viento	Numérica continua	0-75 Km/hr*	10.26
Meteorológica	WD	Dirección del viento	Numérica circular	0-360°*	10.76
Tempo- ral/espacial	Estacion	Estación de monitoreo	Categorica nominal	NTE, NTE2, NO, NE	0.00
Tempo- ral/espacial	Año	Año de la medición	Temporal discreta	2020-2025	0.00
Tempo- ral/espacial	fecha y hora	Momento de la medición	Fecha-hora	Registros horarios 2020-2025	0.00

*Los intervalos mostrados para las variables numéricas representan la envolvente de los límites válidos utilizados durante la limpieza entre 2020 y 2025. El límite exacto puede variar según el año y se encuentra documentado en la etapa anterior.

Las variables meteorológicas se consideran principalmente como posibles predictoras y los contaminantes como posibles variables objetivo. **Estacion**, **Año** y **fecha y hora** no representan mediciones meteorológicas, pero conservan el contexto espacial y temporal de cada registro. La selección definitiva de contaminantes y predictores dependerá tanto de la disponibilidad de datos como de las asociaciones identificadas durante el análisis exploratorio.

2.1.2.1 Técnicas estadísticas utilizadas

Para responder al objetivo de esta etapa se emplean medidas de tendencia central y dispersión para caracterizar las mediciones; histogramas y diagramas de caja para estudiar la forma de las distribuciones, su asimetría y los posibles valores atípicos; tablas de frecuencia y comparaciones descriptivas por estación para evaluar diferencias espaciales; y correlaciones para identificar asociaciones preliminares entre las variables meteorológicas y los contaminantes. Debido a la asimetría y a los valores extremos observados en varias variables, el análisis de asociación

utiliza el coeficiente de Spearman en lugar de depender únicamente de una correlación lineal convencional.

La revisión de Cifuentes et al. (2021) proporciona un antecedente directo para relacionar variables meteorológicas con concentraciones de contaminantes dentro de modelos predictivos de calidad del aire. En este proyecto, las técnicas descriptivas y de correlación se utilizan como una etapa previa al modelado para identificar qué variables presentan mayor disponibilidad, variabilidad y relación estadística con los contaminantes de interés.

2.1.3 1.3 Dimensión y estructura del conjunto de datos

La Etapa 2 parte directamente de `datos_limpios`, el conjunto consolidado y depurado en la etapa anterior. A partir de este objeto se seleccionaron las estaciones NTE, NTE2, NO y NE, concentradas en el sector norte del Área Metropolitana de Monterrey y con especial interés en San Nicolás de los Garza y sus zonas colindantes. Esta selección permite conservar un contexto espacial relevante sin utilizar simultáneamente toda la red de SIMA, lo que reduciría la manejabilidad del conjunto de datos y aumentaría la complejidad del modelado posterior.

Table 2: Dimensión del conjunto de datos utilizado en la Etapa 2

Año	Registros	Columnas
2020	35107	18
2021	35036	18
2022	35040	18
2023	35032	18
2024	35131	18
2025	17377	18
Total	192723	18

Rows: 192,723

Columns: 18

```
$ `fecha y hora` <chr> "43831", "43831.041666666664", "43831.0833333333336", "4~
$ CO <dbl> NA, 0.09, 0.15, 0.15, 0.11, 0.07, 0.10, 0.08, 0.06, 0.0~
$ NO <dbl> NA, 0.5, 0.5, 0.5, 0.5, 0.5, 0.5, 0.5, 0.5, 0.5, 0.5, 0~
$ NO2 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NOX <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ O3 <dbl> NA, 1, 1, 1, NA, NA, NA, NA, NA, NA, 1, 1, NA, NA, 1, NA, N~
$ PM10 <dbl> 110, 75, 76, 46, 63, 49, 33, 20, 13, 15, 33, 53, 53, 63~
$ PM2.5 <dbl> 107.55, NA, 44.56, NA, 42.77, 29.69, 19.09, NA, NA, NA,~
$ BP <dbl> NA, 721.9, 720.9, 720.5, 720.1, 719.9, 719.8, 719.7, 71~
$ RAINF <dbl> NA, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
$ RH <dbl> NA, 96, 96, 96, 96, 96, 96, 96, 96, NA, NA, NA, NA, NA, NA,~
```

```

$ S02      <dbl> NA, 0.9, 1.5, 1.5, 1.1, 0.7, 0.9, 0.7, 0.6, 0.6, 0.9, N~
$ SR       <dbl> 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000,~
$ TEMP     <dbl> NA, 10.76, 10.82, 10.81, 10.97, 11.19, 11.34, 11.42, 11~
$ WS       <dbl> NA, 3.8, 6.7, 6.7, 4.9, 3.1, 4.2, 3.3, 2.5, 2.6, 3.8, 1~
$ WD       <dbl> NA, 1, 1, 1, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ Año      <dbl> 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2~
$ Estacion <chr> "NE", "NE", "NE", "NE", "NE", "NE", "NE", "NE", "NE", "~

```

Cada fila del conjunto representa una medición asociada a una estación de monitoreo y a un momento específico. Las columnas reúnen los contaminantes atmosféricos, las variables meteorológicas y los identificadores temporales y espaciales descritos anteriormente. La integración de los seis años permite analizar la evolución de las mediciones entre 2020 y 2025 y comparar el comportamiento de las cuatro estaciones seleccionadas.

2.1.4 1.4 Estadística descriptiva de variables cuantitativas

Para obtener una primera descripción del comportamiento de las variables cuantitativas, se calcularon medidas de tendencia central y dispersión sobre los registros de las cuatro estaciones seleccionadas. Estas medidas permiten identificar valores representativos, variabilidad y diferencias de escala entre las variables antes de estudiar sus distribuciones y relaciones.

Table 3: Estadística descriptiva de las variables cuantitativas

Vari- able	Me- dia	Medi- ana	Moda	Min	Max	Rango	Vari- anza	DE	Q1	Q3
CO	1.32	1.17	0.98	0.00	15.30	15.30	0.61	0.78	0.78	1.70
NO	13.56	5.10	0.50	0.50	500.00	499.50	551.37	23.48	3.00	12.00
NO2	16.91	13.20	6.10	0.00	188.60	188.60	158.47	12.59	8.00	22.30
NOX	30.82	19.40	10.70	0.50	500.00	499.50	1058.08	32.53	11.70	35.80
O3	27.10	23.00	14.00	1.00	173.00	172.00	360.67	18.99	13.00	37.00
PM10	59.17	50.00	46.00	1.00	998.00	997.00	1669.79	40.86	34.00	72.75
PM2.5	20.03	17.00	10.00	0.00	999.00	999.00	247.09	15.72	10.40	26.00
BP	714.95	714.60	712.90	687.50	738.90	51.40	23.75	4.87	711.50	718.10
RAINF	0.01	0.00	0.00	0.00	45.00	45.00	0.06	0.24	0.00	0.00
RH	55.92	58.00	77.00	0.00	100.00	100.00	501.36	22.39	39.00	74.00
SO2	4.81	3.90	2.70	0.50	175.40	174.90	12.78	3.57	2.90	5.50
SR	0.11	0.00	0.00	0.00	1.24	1.24	0.04	0.20	0.00	0.15
TEMP	23.45	24.13	25.41	-5.76	45.10	50.86	52.63	7.25	18.80	28.52
WS	8.16	7.50	6.60	0.10	38.00	37.90	20.20	4.49	4.90	10.80
WD	122.23	105.00	20.00	1.00	360.00	359.00	8560.18	92.52	50.00	158.00

La media, mediana y moda describen la tendencia central de las mediciones, mientras que el rango, la varianza y la desviación estándar permiten evaluar su dispersión. Los cuartiles Q1 y Q3 se conservaron como referencia para el análisis posterior de distribución y valores atípicos. Debido a que varias de las variables son continuas, la moda debe interpretarse con cautela, ya que corresponde al valor observado con mayor frecuencia y depende de la precisión con la que se registran las mediciones.

En los contaminantes atmosféricos se observa, en general, una media superior a la mediana. Esta diferencia es especialmente clara en NO (media de 13.56 frente a una mediana de 5.10), NOX (30.82 frente a 19.40), PM10 (59.17 frente a 50.00) y PM2.5 (20.03 frente a 17.00). Esto sugiere la presencia de distribuciones con asimetría hacia valores altos, donde mediciones elevadas desplazan el promedio por encima del valor central. Esta característica se verificará visualmente mediante histogramas y boxplots en la siguiente sección.

En las variables meteorológicas se presentan comportamientos distintos. La presión atmosférica (BP) muestra una media de 714.95 y una mediana de 714.60, indicando una concentración relativamente estable alrededor de sus valores centrales. La precipitación (RAINF) presenta una media de 0.01 y tanto mediana como moda iguales a cero, por lo que la mayoría de los registros horarios corresponden a periodos sin precipitación. De forma similar, la radiación solar (SR) presenta mediana y moda de cero, asociadas a los periodos del día sin radiación solar. La temperatura (TEMP) registra una media de 23.45 °C y una mediana de 24.13 °C, mientras que la humedad relativa (RH) presenta una media de 55.92 % y una mediana de 58.00 %.


La verificación posterior a la limpieza no detectó observaciones fuera de los límites definidos para cada variable y año, por lo que estas estadísticas se calcularon sobre el conjunto depurado. Los valores extremos que permanecen dentro de los rangos permitidos no se consideran automáticamente errores, ya que pueden corresponder a observaciones reales y serán evaluados como posibles valores atípicos en el análisis de distribución. Finalmente, la dirección del viento (WD) requiere una interpretación especial por tratarse de una variable circular: valores cercanos a 0° y 360° representan direcciones similares, por lo que su media aritmética no debe interpretarse de la misma manera que la del resto de las variables cuantitativas.

2.1.5 1.5 Distribución de las variables

Para complementar las medidas descriptivas obtenidas anteriormente, se analizó la distribución de las variables mediante histogramas y diagramas de caja. Los histogramas permiten observar la forma, concentración y asimetría de las mediciones, mientras que los boxplots facilitan la identificación de su dispersión y de posibles valores atípicos.

2.1.5.1 Distribución de los contaminantes atmosféricos


Distribución de los contaminantes atmosféricos



Los contaminantes presentan, en general, distribuciones asimétricas hacia la derecha. Este comportamiento es particularmente claro en NO, NOX, PM10, PM2.5 y SO2, donde la mayor parte de las observaciones se concentra en valores bajos o intermedios y una cantidad menor de mediciones elevadas forma colas largas. Este resultado coincide con las diferencias entre media y mediana observadas en la sección 1.4. En PM10 y PM2.5, algunos valores elevados amplían considerablemente el eje de la gráfica, por lo que se complementa la visualización con un acercamiento hasta el percentil 99.

2.1.5.2 Distribución de las variables meteorológicas


Distribución de las variables meteorológicas




Las variables meteorológicas muestran comportamientos más diversos. BP y TEMP presentan distribuciones relativamente concentradas alrededor de sus valores centrales, mientras que WS muestra asimetría hacia valores altos. RAINF se concentra fuertemente en cero porque la mayoría de los registros horarios corresponden a periodos sin precipitación, y SR también presenta una acumulación importante en cero asociada a las horas sin radiación solar. La distribución de WD presenta varios máximos y debe interpretarse considerando que representa una dirección circular y no una magnitud lineal convencional.

2.1.5.3 Dispersión y posibles valores atípicos

Dispersión de los contaminantes atmosféricos



Dispersión de las variables meteorológicas




Los boxplots confirman la presencia de numerosas observaciones alejadas del rango intercuartílico, especialmente en NO, NOX, PM10, PM2.5 y S02. Estos puntos no deben interpretarse automáticamente como errores. La limpieza previa eliminó las observaciones fuera de los rangos establecidos para cada variable y año, por lo que los valores extremos restantes pueden

representar episodios reales poco frecuentes y se conservan para los análisis posteriores.

2.1.5.4 Acercamiento de contaminantes al percentil 99

Para observar con mayor claridad la región donde se concentra la mayoría de las mediciones, se presenta adicionalmente una visualización de los contaminantes limitada al percentil 99 de cada variable. Este acercamiento se utiliza únicamente con fines gráficos y no modifica el conjunto de datos empleado en los análisis.

Dispersión de contaminantes – visualización hasta el percentil 99



En conjunto, los histogramas y boxplots muestran que las variables no presentan un comportamiento homogéneo: varios contaminantes poseen distribuciones fuertemente asimétricas y valores extremos, mientras que las variables meteorológicas exhiben formas distintas según el fenómeno que representan. En la siguiente sección se analizará si estas diferencias también cambian entre las cuatro estaciones de monitoreo seleccionadas.

2.1.6 1.6 Análisis por estación de monitoreo

Una vez descrito el comportamiento general de las variables, se compararon las estaciones NTE, NTE2, NO y NE para identificar posibles diferencias espaciales en las concentraciones de contaminantes y en las condiciones meteorológicas. Esta comparación permite evaluar si las cuatro estaciones presentan comportamientos similares o si la ubicación del punto de monitoreo debe considerarse explícitamente en los análisis posteriores.

2.1.6.1 Estadística descriptiva por estación

Para resumir las diferencias entre estaciones se calcularon la media, mediana y desviación estándar de cada variable de medición. La media y mediana permiten comparar los niveles centrales registrados en cada estación, mientras que la desviación estándar muestra las diferencias en variabilidad.

Table 4: Media, mediana y desviación estándar por variable y estación


Estacion	Variable	Media	Mediana	DE
NTE	CO	0.86	0.76	0.48
NTE2	CO	1.17	1.09	0.56
NO	CO	1.64	1.68	0.68
NE	CO	1.62	1.35	1.00
NTE	NO	12.78	3.50	25.03
NTE2	NO	21.54	10.00	28.39
NO	NO	9.61	4.10	18.32
NE	NO	10.20	5.20	18.80
NTE	NO2	14.33	10.70	10.67
NTE2	NO2	23.98	20.20	14.93
NO	NO2	14.24	11.00	10.52
NE	NO2	14.54	11.30	10.40
NTE	NOX	27.07	14.70	32.15
NTE2	NOX	45.50	32.50	38.44
NO	NOX	23.94	15.20	25.56
NE	NOX	25.74	17.90	26.92
NTE	O3	26.53	23.00	19.11
NTE2	O3	24.64	20.00	17.84
NO	O3	29.69	26.00	21.15
NE	O3	27.73	25.00	17.37
NTE	PM10	60.23	50.69	41.36
NTE2	PM10	66.41	57.00	42.37
NO	PM10	49.96	41.00	37.08
NE	PM10	59.91	51.00	40.71
NTE	PM2.5	18.02	15.00	12.66
NTE2	PM2.5	20.35	18.00	15.14
NO	PM2.5	20.51	17.00	16.72
NE	PM2.5	21.24	17.79	17.79
NTE	BP	715.72	715.50	4.28
NTE2	BP	712.88	712.60	3.94
NO	BP	712.43	712.10	3.84
NE	BP	719.05	718.80	4.21
NTE	RAINF	0.00	0.00	0.01

Estacion	Variable	Media	Mediana	DE
NTE2	RAINF	0.00	0.00	0.15
NO	RAINF	0.02	0.00	0.44
NE	RAINF	0.00	0.00	0.04
NTE	RH	47.92	50.00	23.80
NTE2	RH	55.21	57.00	20.37
NO	RH	54.41	56.00	22.67
NE	RH	61.88	65.00	21.92
NTE	SO2	4.04	3.20	2.81
NTE2	SO2	5.12	4.10	4.06
NO	SO2	5.49	4.30	3.84
NE	SO2	4.51	3.90	3.22
NTE	SR	0.03	0.00	0.13
NTE2	SR	0.13	0.00	0.18
NO	SR	0.17	0.01	0.24
NE	SR	0.12	0.00	0.21
NTE	TEMP	23.71	24.40	7.39
NTE2	TEMP	23.70	24.35	7.14
NO	TEMP	23.57	24.26	7.05
NE	TEMP	22.74	23.41	7.43
NTE	WS	7.68	7.00	4.44
NTE2	WS	7.80	7.50	3.33
NO	WS	8.48	7.30	5.49
NE	WS	8.68	8.20	4.41
NTE	WD	99.00	87.00	90.54
NTE2	WD	103.34	82.00	85.88
NO	WD	148.37	112.00	102.52
NE	WD	136.95	138.00	80.89

La tabla permite detectar qué variables presentan mayores diferencias en sus valores centrales o en su dispersión entre estaciones. Estas diferencias se complementan visualmente con diagramas de caja, ya que los boxplots permiten comparar simultáneamente la mediana, el rango intercuartílico y los valores extremos de cada estación.

2.1.6.2 Comparación de contaminantes por estación


Distribución de contaminantes por estación de monitoreo



La comparación entre estaciones muestra diferencias espaciales claras en varios contaminantes. La estación NTE2 presenta las mayores concentraciones típicas de los compuestos nitrogenados, con medianas de 10.00 para NO, 20.20 para NO₂ y 32.50 para NO_x, considerablemente superiores a las observadas en las otras estaciones. PM₁₀ también presenta su mayor mediana en NTE2 (57.00), mientras que la estación NO registra la menor (41.00). En contraste, O₃ alcanza su mayor mediana en NO (26.00) y la menor en NTE2 (20.00). Para PM_{2.5} y SO₂ las diferencias entre estaciones son menos pronunciadas.

2.1.6.3 Comparación de variables meteorológicas por estación

Distribución de variables meteorológicas por estación



Las condiciones meteorológicas también presentan diferencias entre ubicaciones. NE registra la mayor humedad relativa, con una mediana de 65 %, así como la mayor presión atmosférica (718.80) y velocidad del viento (8.20 km/h). La temperatura presenta un comportamiento más homogéneo, con medianas cercanas a 24 °C en las cuatro estaciones. La precipitación se concentra alrededor de cero en todos los puntos de monitoreo, mientras que la radiación solar muestra valores promedio mayores en NO y menores en NTE. La dirección del viento se interpreta únicamente de forma exploratoria en esta sección debido a su naturaleza circular.

En conjunto, los resultados indican que las estaciones no presentan un comportamiento completamente homogéneo. Las diferencias son particularmente importantes para los óxidos de nitrógeno y, en menor medida, para variables como PM₁₀, O₃, humedad, presión y velocidad del viento. Por esta razón, la estación de monitoreo debe conservarse como un componente espacial relevante durante los análisis y modelos posteriores, ya que ignorar la ubicación podría ocultar diferencias sistemáticas entre los puntos de medición.

2.1.7 1.7 Análisis de correlación

Después de estudiar las distribuciones de las variables y sus diferencias entre estaciones, se analizaron las asociaciones entre los contaminantes atmosféricos y las variables meteorológicas. El objetivo de esta sección es identificar qué condiciones meteorológicas presentan una mayor relación con las concentraciones de cada contaminante y evaluar posteriormente si estas asociaciones se mantienen de forma similar entre las estaciones seleccionadas.

Debido a la asimetría y a la presencia de valores extremos observadas en varias variables durante las secciones anteriores, se utilizó el **coeficiente de correlación de Spearman**. Esta medida se basa en los rangos de las observaciones y permite estudiar relaciones monotónicas sin requerir que sean estrictamente lineales, por lo que resulta adecuada para este análisis exploratorio.

2.1.7.1 Tratamiento de la dirección del viento

La dirección del viento (WD) requiere un tratamiento particular debido a su naturaleza circular. Por ejemplo, 1° y 359° representan direcciones muy similares, aunque numéricamente parezcan alejadas. Por esta razón, se transformó en dos componentes mediante las funciones seno y coseno.


Las variables WD_sin y WD_cos permiten incorporar la dirección del viento sin tratar los grados como una variable lineal convencional.

2.1.7.2 Correlación entre contaminantes y variables meteorológicas

Para concentrar el análisis en las relaciones relevantes para el objetivo predictivo, se calcularon únicamente las correlaciones entre los contaminantes y las variables meteorológicas.

El coeficiente de Spearman toma valores entre -1 y 1. Los valores positivos indican que ambas variables tienden a aumentar conjuntamente, mientras que los valores negativos indican que una tiende a disminuir cuando la otra aumenta. Los valores cercanos a cero representan asociaciones monotónicas débiles.

2.1.7.3 Mapa de calor de las correlaciones



El mapa de calor muestra que O3 es el contaminante con las asociaciones meteorológicas de mayor magnitud. La relación más fuerte se observa con la humedad relativa (RH), con una correlación de **-0.549**, lo que indica que valores mayores de humedad tienden a asociarse con menores concentraciones de ozono. En sentido positivo, O3 presenta asociaciones con la temperatura (TEMP, **0.515**), la velocidad del viento (WS, **0.506**) y la radiación solar (SR, **0.475**).

Los compuestos nitrogenados muestran un patrón diferente. La velocidad del viento presenta correlaciones negativas con NO2 (**-0.473**), NOX (**-0.472**) y NO (**-0.350**). La temperatura también se relaciona negativamente con NOX (**-0.335**), NO2 (**-0.307**) y NO (**-0.250**). En contraste, las asociaciones observadas para CO, SO2 y PM2.5 son en general de menor magnitud. Para PM10, la relación más destacada es con RH, con una correlación de **-0.244**.

La componente WD_sin de la dirección del viento presenta una asociación de **0.276** con O3, mientras que las demás correlaciones asociadas a WD_sin y WD_cos son relativamente pequeñas. Esto sugiere que la dirección del viento puede aportar información para algunos contaminantes, pero su importancia deberá evaluarse junto con las demás variables durante el modelado.

2.1.7.4 Relaciones de mayor magnitud

Para facilitar la identificación de las combinaciones más relevantes, se seleccionaron las doce asociaciones con mayor magnitud absoluta.

Table 5: Principales asociaciones entre contaminantes y variables meteorológicas


Contaminante	Meteorologica	Correlacion
O3	RH	-0.549
O3	TEMP	0.515
O3	WS	0.506
O3	SR	0.475
NO2	WS	-0.473
NOX	WS	-0.472
NO	WS	-0.350
NOX	TEMP	-0.335
NO2	TEMP	-0.307
O3	WD_sin	0.276
NO	TEMP	-0.250
PM10	RH	-0.244

La tabla confirma que las asociaciones de mayor magnitud se concentran principalmente en O3 y en los óxidos de nitrógeno. Esto convierte a variables como RH, TEMP, WS y SR en candidatas relevantes para los modelos predictivos de estos contaminantes. Sin embargo, estas correlaciones representan asociaciones estadísticas y no deben interpretarse como evidencia de causalidad.

2.1.7.5 Correlaciones por estación de monitoreo

Para evaluar si las relaciones anteriores cambian según la ubicación, se calculó nuevamente la correlación de Spearman de forma independiente para NTE, NTE2, NO y NE.

Correlaciones entre meteorología y contaminantes por estación



La comparación por estación muestra que varias de las asociaciones identificadas en el análisis general se mantienen en los cuatro puntos de monitoreo. El ozono (O₃) presenta de manera consistente una relación negativa con la humedad relativa (RH) y relaciones positivas con la temperatura (TEMP), la velocidad del viento (WS) y, en general, la radiación solar (SR). Aunque la magnitud de las correlaciones cambia entre NTE, NTE2, NO y NE, el signo de estas asociaciones se conserva en gran parte de los casos, lo que sugiere un patrón relativamente estable para el ozono.

Los contaminantes nitrogenados (NO, NO₂ y NO_x) también muestran un comportamiento relativamente consistente entre estaciones. Sus asociaciones con la velocidad del viento (WS) son principalmente negativas y se observan relaciones negativas adicionales con la temperatura (TEMP). En contraste, las correlaciones de CO, SO₂, PM₁₀ y PM_{2.5} son generalmente de menor magnitud y presentan mayores variaciones entre los puntos de monitoreo.

Las componentes de dirección del viento (WD_{sin} y WD_{cos}) muestran una mayor variabilidad entre estaciones. Esto indica que la relación entre la dirección del viento y las concentraciones puede depender de la ubicación del punto de monitoreo, ya que una misma dirección puede representar condiciones de transporte distintas según la estación. En conjunto, existen patrones meteorológicos comunes entre las cuatro estaciones, particularmente para O₃ y los óxidos de nitrógeno, pero también se observan diferencias espaciales que justifican conservar **Estacion** como una variable relevante durante el modelado.

En conjunto, el análisis de correlación indica que las variables meteorológicas no tienen la misma relación con todos los contaminantes. O₃ presenta las asociaciones más claras con la meteorología, especialmente con RH, TEMP, WS y SR, mientras que NO, NO₂ y NO_x destacan por sus

asociaciones negativas con la velocidad del viento y la temperatura. La presencia de patrones similares entre estaciones proporciona evidencia de relaciones generales, pero las diferencias observadas indican que el componente espacial también debe considerarse en los modelos posteriores. Estas asociaciones servirán como una primera guía para seleccionar variables predictoras, sin interpretarlas como relaciones causales.

2.1.8 1.8 Calidad de los datos posterior a la limpieza

Como cierre de la comprensión descriptiva, se realizó una verificación final de la calidad del subconjunto utilizado en la Etapa 2. El objetivo es identificar qué problemas permanecen después de la limpieza y qué aspectos deberán considerarse antes de seleccionar las variables y construir los modelos predictivos.

2.1.8.1 Valores faltantes

Primero se cuantificó la disponibilidad general de información para cada variable, considerando el número de observaciones válidas, los valores faltantes y su porcentaje respecto al total de registros seleccionados.

Table 6: Disponibilidad de datos por variable en la Etapa 2

Variable	Datos_validos	Nulos	Porcentaje
CO	158142	34581	17.94
NO	153347	39376	20.43
NO2	147119	45604	23.66
NOX	147670	45053	23.38
O3	145882	46841	24.30
PM10	182101	10622	5.51
PM2.5	154798	37925	19.68
BP	177020	15703	8.15
RAINF	178331	14392	7.47
RH	156360	36363	18.87
SO2	145521	47202	24.49
SR	184967	7756	4.02
TEMP	164788	27935	14.49
WS	172952	19771	10.26
WD	171981	20742	10.76

Los valores faltantes constituyen el principal problema de calidad que permanece en el conjunto. A nivel general, los mayores porcentajes de ausencia corresponden a SO2 (24.49 %), O3 (24.30 %), NO2 (23.66 %) y NOX (23.38 %). En contraste, SR (4.02 %) y PM10 (5.51 %) presentan

una disponibilidad considerablemente mayor. Los valores faltantes no se eliminaron de forma generalizada, ya que su tratamiento dependerá del contaminante seleccionado como variable objetivo y de los requerimientos del modelo utilizado.

2.1.8.2 Valores faltantes por estación

El porcentaje global puede ocultar problemas específicos de una estación. Por esta razón, también se calculó el porcentaje de valores faltantes de cada variable de manera independiente para NTE, NTE2, NO y NE.

Table 7: Porcentaje de valores faltantes por variable y estación

Variable	NTE	NTE2	NO	NE
CO	24.72	5.82	28.86	12.38
NO	26.80	18.26	20.91	15.75
NO2	26.43	19.22	25.45	23.56
NOX	26.46	19.22	24.65	23.18
O3	24.77	20.94	26.39	25.12
PM10	9.07	3.61	5.98	3.40
PM2.5	15.53	14.75	41.36	7.08
BP	22.82	1.22	3.29	5.27
RAINF	21.72	1.08	2.83	4.24
RH	54.76	1.47	13.59	5.65
SO2	28.90	26.28	18.76	24.02
SR	10.42	0.45	2.46	2.77
TEMP	22.37	1.15	12.94	21.52
WS	19.67	1.08	6.17	14.11
WD	22.32	1.22	11.35	8.15

La disponibilidad de información no es uniforme entre estaciones. Los casos más relevantes son RH en NTE, con 54.76 % de valores faltantes, y PM2.5 en NO, con 41.36 %. Estas combinaciones deberán analizarse con especial cuidado si se utilizan en modelos específicos por estación. En contraste, NTE2 presenta una disponibilidad alta para varias variables meteorológicas, con porcentajes de ausencia de 0.45 % en SR, 1.08 % en RAINF y WS, 1.15 % en TEMP y 1.22 % en BP y WD.

2.1.8.3 Verificación final de rangos y duplicados

La limpieza de la etapa anterior convirtió en NA los valores que se encontraban fuera de los límites establecidos para cada variable y año. Para verificar que el subconjunto utilizado en esta etapa conserva esa condición, se repitió la comprobación sobre `datos_etapa2`. También se

revisaron posibles registros duplicados definidos por una misma combinación de año, estación y fecha-hora.

Table 8: Verificación final de rangos y duplicados

Verificacion	Resultado
Observaciones fuera de rango	0
Combinaciones año-estación-fecha duplicadas	0

La verificación final obtuvo **0 observaciones fuera de rango y 0 combinaciones año-estación-fecha duplicadas**. Esto confirma que el proceso de limpieza corrigió los registros inválidos identificados anteriormente y que no existen duplicados bajo el criterio utilizado. Los valores extremos que permanecen dentro de los rangos válidos se conservan, ya que pueden representar observaciones reales y no errores de captura.

2.1.8.4 Verificación de categorías y escritura

Como parte de la revisión de calidad también se verificó que la variable categórica **Estacion** contenga únicamente las categorías esperadas y que los nombres de las variables requeridas estén presentes después del proceso de homologación.

Table 9: Verificación de categorías y nombres de variables

Verificacion	Resultado
Categorías observadas en Estacion	NE, NO, NTE, NTE2
Categorías inesperadas	Ninguna
Variables esperadas faltantes	Ninguna


La revisión confirma que las categorías observadas corresponden únicamente a **NE, NO, NTE** y **NTE2**, sin etiquetas adicionales o inconsistencias de escritura dentro del subconjunto seleccionado. Asimismo, todas las variables esperadas están presentes después de la homologación realizada en la etapa anterior, por lo que no se identifican errores de escritura pendientes en los nombres utilizados para este análisis.

2.1.8.5 Frecuencia de registros por estación

Finalmente, se revisó la distribución de registros de la variable categórica **Estacion**. Al tratarse de una variable nominal, su descripción se realiza mediante frecuencias y porcentajes; una medida ordinal como la mediana no resulta aplicable.

Table 10: Frecuencia de registros por estación de monitoreo

Estacion	Registros	Porcentaje
NTE	48181	25
NTE2	48179	25
NO	48182	25
NE	48181	25



Las cuatro estaciones aportan aproximadamente 48 mil registros cada una, por lo que no existe un desbalance importante en el número total de observaciones. Sin embargo, esta similitud en cantidad de filas no implica que todas las variables tengan la misma disponibilidad en cada estación, como muestran los porcentajes de valores faltantes anteriores.

En general, el conjunto seleccionado se encuentra depurado respecto a valores fuera de rango y duplicados, y las cuatro estaciones están representadas por cantidades de registros comparables. El principal aspecto de calidad que permanece es la presencia de datos faltantes, cuya magnitud varía entre variables y estaciones. Por esta razón, la selección de contaminantes objetivo y variables predictoras deberá considerar conjuntamente dos criterios: la relación meteorológica identificada en el análisis de correlación y la disponibilidad suficiente de observaciones. La estrategia para tratar los valores faltantes se definirá posteriormente según las necesidades del modelo seleccionado, evitando eliminar información de manera innecesaria.

2.1.9 1.9 Dificultades de medición de la calidad del aire

Además de los problemas de limpieza documentados en las secciones anteriores, es importante resaltar las limitaciones propias al proceso de medición de la calidad del aire y que no se originan en el procesamiento de los datos. La red de monitoreo de SIMA, está sujeta a interrupciones de cobertura temporal por mantenimiento, calibración periódica de los equipos o fallas técnicas puntuales, lo cual puede explicar parte de los valores faltantes observados en contaminantes como NO₂, NO_X y SO₂, además de los errores de captura o transmisión. La calibración de los sensores, que se requiere periódicamente para mantener la precisión de las mediciones conforme a las Normas Oficiales Mexicanas correspondientes, puede generar ventanas de tiempo sin registro válido durante el proceso. También la continuidad de las mediciones puede verse afectada por la ubicación física de cada estación (por ejemplo, interferencias del entorno urbano inmediato), lo que introduce más variabilidad entre estaciones que no necesariamente refleja diferencias reales en la calidad del aire. Estas consideraciones son relevantes para interpretar con más cuidado los valores faltantes y aquellos atípicos identificados en el conjunto de datos, ya que una parte de ellos podría estar asociada a estas limitaciones de medición y no exclusivamente a fenómenos atmosféricos o errores de limpieza.

2.1.10 1.10 Conclusiones y siguientes pasos

El análisis descriptivo permitió caracterizar el comportamiento de las variables utilizadas en las cuatro estaciones seleccionadas. Se identificó que varios contaminantes, especialmente NO, NO_X, PM₁₀, PM_{2.5} y SO₂, presentan distribuciones asimétricas y valores extremos. Debido a que la verificación posterior a la limpieza confirmó que estos valores se encuentran dentro de los rangos permitidos, se conservaron como observaciones potencialmente reales en lugar de eliminarlos automáticamente.

La comparación espacial mostró que las estaciones no presentan un comportamiento completamente homogéneo. NTE2 destacó por mayores concentraciones típicas de NO, NO₂ y NO_X, mientras que otros contaminantes, como O₃ y PM₁₀, presentaron patrones diferentes entre estaciones. También se observaron diferencias meteorológicas en variables como humedad relativa, presión atmosférica y velocidad del viento, lo que confirma la importancia de conservar **Estacion** como componente espacial durante los análisis posteriores.

El análisis de correlación permitió identificar asociaciones preliminares entre meteorología y contaminación. O₃ presentó las relaciones de mayor magnitud, principalmente con RH, TEMP, WS y SR. Por otra parte, NO, NO₂ y NO_X mostraron asociaciones negativas principalmente con la velocidad del viento y la temperatura. Varios de estos patrones se mantuvieron entre estaciones, aunque también se encontraron diferencias espaciales, particularmente en las componentes relacionadas con la dirección del viento. Estas asociaciones servirán como referencia para la selección posterior de variables predictoras, sin interpretarse como relaciones causales.

Finalmente, la verificación de calidad confirmó que no permanecen observaciones fuera de los rangos establecidos ni registros duplicados. El principal aspecto pendiente es la presencia de valores faltantes, cuya proporción cambia considerablemente según la variable y la estación. Por lo tanto, el siguiente paso será seleccionar los contaminantes objetivo considerando conjuntamente su relación con las variables meteorológicas y la disponibilidad de información. Posteriormente se definirá el tratamiento de los valores faltantes, se prepararán las variables necesarias para el modelado y se construirán y compararán modelos predictivos que permitan evaluar qué tan bien pueden estimarse las concentraciones de contaminantes a partir de las condiciones meteorológicas.

3 Declaratoria y referencias

3.1 Link GitHub:

<https://github.com/Reyivan777/Reto-Multivariados>

3.2 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: Claude.

Uso realizado: Apoyo en la búsqueda de referencias bibliográficas complementarias, así como en la estructuración de borradores de las secciones del informe de la Parte I. Igualmente, apoyo con sintaxis del código de la Parte 2.

Secciones donde se utilizó: Parte I. Conociendo el Negocio y Parte II. Comprensión y Preparación de los Datos.

Validación realizada por los estudiantes: Hemos revisado, editado y validado el contenido generado, verificando la veracidad de las referencias y asegurando la coherencia con el objetivo del proyecto. Como equipo asumimos la responsabilidad del contenido final entregado.

3.3 Referencias bibliográficas

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. *International Journal of Public Health*, 66, 1604465.