

Reporte del reto SIMA: predicción de ozono a corto plazo

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-09-02

Table of contents

1	Introducción y planteamiento	3
1.1	Contexto del proyecto	3
1.2	Problema de investigación	3
1.3	Pregunta de investigación	4
1.4	Objetivo general	4
1.5	Objetivos específicos	4
1.6	Justificación y antecedentes	4
1.7	Alcance del pronóstico	5
1.8	Variables consideradas	6
1.9	Estrategia general de análisis	6
1.10	Fuente de información	7
2	Datos	7
2.1	Archivos fuente	7
2.2	Carga inicial	8
2.3	Estructura y disponibilidad inicial	8
2.4	Homologación de la estructura	9
3	Preparación de los datos	10
3.1	Conversión de tipos	10

3.2	Valores faltantes y registros inválidos	11
3.2.1	Disponibilidad de O3 y selección del periodo	12
3.2.2	Continuidad y tratamiento de los faltantes de O3 desde 2021	13
3.3	Valores extremos	14
3.3.1	Construcción de la base limpia	17
3.4	Variables temporales y espaciales	17
4	Análisis exploratorio	18
4.1	Comportamiento del O3	18
4.2	Diferencias entre estaciones	19
4.2.1	Patrón horario	21
4.2.2	Estabilidad del patrón horario entre años	23
4.2.3	Concentración de valores altos de O3 por hora	24
4.2.4	Patrón mensual	27
4.2.5	Estabilidad del patrón mensual entre años	28
4.3	Relación con variables meteorológicas y contaminantes	30
4.3.1	Variables meteorológicas	30
4.3.2	Dirección del viento	33
4.3.3	Otros contaminantes	34
5	Preparación para modelado	37
5.1	Construcción de rezagos	37
5.1.1	Predictores meteorológicos y O3 futuro	40
5.1.2	Otros contaminantes y O3 futuro	42
5.2	Separación cronológica	44
5.3	Conjunto preliminar de predictores	44
5.4	Base formal de modelado	45
6	Modelado	47
6.1	Modelo base	47
6.2	Modelo estadístico	47
6.3	Modelo no lineal	47
7	Evaluación	48
7.1	Métricas	48
7.2	Error por horizonte	48
7.3	Error por estación	48
8	Conclusiones	48
9	Declaratoria y referencias	48
9.1	Link GitHub	48
9.2	Declaratoria de uso IA	48
9.3	Referencias bibliográficas	49

1 Introducción y planteamiento

1.1 Contexto del proyecto

La contaminación atmosférica representa un problema relevante para la salud pública y para la gestión ambiental de las ciudades. En la Zona Metropolitana de Monterrey (ZMM), las concentraciones de contaminantes pueden variar considerablemente a lo largo del día debido a la interacción entre emisiones, condiciones meteorológicas y características propias de cada zona. Por esta razón, además de conocer el estado actual de la calidad del aire, resulta útil estudiar si los registros históricos permiten anticipar su comportamiento en el corto plazo.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) opera una red de estaciones que registra de forma horaria contaminantes atmosféricos y variables meteorológicas. Entre los contaminantes disponibles se encuentran monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 y 2.5 micrómetros (PM₁₀ y PM_{2.5}) y dióxido de azufre (SO₂). También se registran variables como temperatura, humedad relativa, radiación solar, presión atmosférica, precipitación, velocidad del viento y dirección del viento.

El reto planteado por SIMA permite analizar estas mediciones mediante técnicas estadísticas multivariadas y de modelado predictivo. En las primeras exploraciones del conjunto de datos se observó que intentar estudiar y predecir simultáneamente todos los contaminantes producía un objetivo demasiado amplio. Por ello, el proyecto se delimita a un problema concreto: **la predicción de la concentración horaria de ozono (O₃) en el corto plazo.**

1.2 Problema de investigación

El ozono troposférico es un contaminante cuyo comportamiento está relacionado con las condiciones atmosféricas y con otros contaminantes presentes en el ambiente. La temperatura, la radiación solar, la humedad y el viento, entre otras variables, pueden aportar información relevante para entender su variación. Además, al tratarse de mediciones horarias, la concentración observada en un momento también depende de la dinámica temporal reciente.

Los registros históricos de SIMA contienen ambas fuentes de información: las condiciones meteorológicas y de contaminación observadas en distintas estaciones, así como su evolución temporal. El problema central del proyecto consiste en determinar si esta información puede utilizarse para generar pronósticos útiles de O₃ con anticipación suficiente para apoyar el seguimiento de episodios de concentración elevada.

El análisis se enfocará inicialmente en las estaciones NTE, NTE2, NO y NE, utilizando los registros disponibles entre 2020 y 2025. Esta delimitación permite trabajar con un conjunto espacial manejable y mantener continuidad con el análisis exploratorio realizado previamente, sin intentar modelar simultáneamente toda la red de monitoreo.

1.3 Pregunta de investigación

¿Con qué precisión puede predecirse la concentración horaria de O₃ con un horizonte de hasta 24 horas en las estaciones NTE, NTE2, NO y NE, utilizando los registros históricos de contaminantes, variables meteorológicas y variables temporales proporcionados por SIMA entre 2020 y 2025?

Esta pregunta transforma el reto en un problema de predicción temporal claramente evaluable: existe una variable objetivo definida, un horizonte de pronóstico específico y un conjunto delimitado de datos con el cual entrenar y evaluar los modelos.

1.4 Objetivo general

Desarrollar y evaluar modelos capaces de **predecir la concentración horaria de ozono (O₃) con un horizonte de hasta 24 horas** en las estaciones NTE, NTE2, NO y NE de la Zona Metropolitana de Monterrey, utilizando información histórica de contaminantes, variables meteorológicas y características temporales registradas por SIMA durante el periodo 2020-2025.

1.5 Objetivos específicos

1. Preparar y validar la calidad de los registros históricos necesarios para modelar O₃, conservando la estructura temporal y espacial de las mediciones.
2. Caracterizar el comportamiento del O₃ e identificar qué variables meteorológicas, contaminantes y patrones temporales aportan información relevante para su predicción.
3. Construir variables derivadas que representen la dinámica temporal del problema, incluyendo características de fecha y hora y rezagos de mediciones disponibles antes del momento de predicción.
4. Construir y comparar al menos dos enfoques de modelado, incluyendo un modelo estadístico interpretable y un modelo capaz de representar relaciones no lineales.
5. Evaluar los modelos mediante una separación cronológica de los datos y métricas de error, analizando además cómo cambia el desempeño según el horizonte de predicción y la estación de monitoreo.

1.6 Justificación y antecedentes

La relevancia del problema parte de la relación entre contaminación atmosférica y salud pública. Cerón Bretón et al. (2020) documentaron asociaciones entre contaminación atmosférica, temperatura y mortalidad diaria en el norte de México. A nivel internacional, las Guías de Calidad del Aire de la Organización Mundial de la Salud resaltan la importancia de reducir la

exposición de la población a contaminantes criterio y de contar con información confiable para su seguimiento (Hoffmann et al., 2021).

Desde la perspectiva predictiva, Cifuentes et al. (2021) analizaron la predicción horaria de O₃ y PM_{2.5} mediante variables meteorológicas y distintos modelos, mostrando que información como temperatura y radiación solar puede resultar útil para anticipar concentraciones de contaminantes. Este antecedente proporciona una base metodológica para estudiar si los registros históricos de SIMA permiten construir modelos adaptados a las condiciones de la ZMM.

La elección de O₃ como variable objetivo también responde al análisis exploratorio realizado durante el proyecto. Frente a otros contaminantes, el ozono mostró asociaciones meteorológicas más claras y consistentes, por lo que ofrece un punto de partida razonable para construir un primer sistema predictivo. Estas relaciones se volverán a cuantificar y validar en la sección de análisis exploratorio de este reporte antes de utilizarse para seleccionar predictores.

El objetivo no es atribuir causalidad a las variables ni sustituir los procedimientos oficiales de pronóstico de SIMA. El propósito es evaluar, con los datos disponibles y dentro del alcance académico del reto, qué tan bien puede anticiparse el comportamiento del O₃ y qué información resulta más útil para hacerlo.

1.7 Alcance del pronóstico

El horizonte máximo de predicción se establece en **24 horas**. Esto no significa utilizar los datos de 2020-2025 para generar una predicción fija de un día posterior al final de la base. El modelo se plantea como un esquema de pronóstico móvil.

En un momento determinado t , únicamente se utilizará información disponible hasta ese instante para estimar las concentraciones futuras de O₃ durante las horas siguientes. De forma conceptual:

$$\text{información disponible hasta } t \longrightarrow \widehat{O}_3(t+1), \dots, \widehat{O}_3(t+24)$$

Cuando exista una nueva medición, esa información podrá incorporarse para generar nuevamente el pronóstico de las siguientes 24 horas. Esta estructura evita utilizar información futura durante la predicción y permite evaluar el desempeño del modelo de forma semejante a como se utilizaría posteriormente con nuevos datos.

El horizonte de 24 horas se utilizará como máximo de evaluación. Durante el modelado se analizará si el error aumenta conforme crece la distancia entre el momento de observación y la hora pronosticada.

1.8 Variables consideradas

La variable objetivo del proyecto es la concentración horaria de **O3**. Las posibles variables predictoras se organizan en cuatro grupos:

Grupo	Variables principales	Función dentro del modelo
Variable objetivo	O3	Concentración que se desea predecir
Meteorológicas	BP, RAINF, RH, SR, TEMP, WS, WD	Describir las condiciones atmosféricas asociadas con la formación, transporte y dispersión del O3
Contaminantes	CO, NO, NO2, NOX, PM10, PM2.5, SO2 y valores previos de O3	Incorporar información del estado reciente de la contaminación atmosférica
Temporales y espaciales	Fecha, hora, día, mes, estación de monitoreo	Representar patrones horarios, estacionales y diferencias entre estaciones

Además de estas variables originales, se evaluará la creación de **rezagos temporales**. Por ejemplo, para realizar una predicción en el momento t , pueden utilizarse valores observados previamente como $O_3(t)$, $O_3(t-1)$, $O_3(t-2)$ o mediciones meteorológicas recientes. La cantidad de rezagos y variables finales se determinará durante la preparación para el modelado para evitar incorporar información redundante o futura.

La dirección del viento requiere un tratamiento particular por ser una variable circular. Por ello, se evaluará su representación mediante componentes seno y coseno en lugar de utilizar directamente los grados como si fueran una variable lineal.

1.9 Estrategia general de análisis

El proyecto seguirá una secuencia orientada directamente al problema predictivo:

1. **Comprensión y limpieza de los datos.** Integrar las bases de 2020 a 2025, homologar nombres y unidades, identificar valores faltantes, registros inválidos y duplicados, y conservar únicamente información adecuada para el análisis.
2. **Análisis exploratorio enfocado en O3.** Estudiar su distribución, comportamiento horario y estacional, diferencias entre estaciones y relación con las variables candidatas a predictoras.
3. **Preparación temporal.** Ordenar los registros cronológicamente, construir variables temporales y rezagos, y definir las observaciones disponibles para cada horizonte de predicción.

4. **Modelado.** Construir primero una referencia simple y posteriormente comparar modelos estadísticos y modelos más flexibles. Entre los candidatos se consideran la regresión lineal múltiple y métodos no lineales como Random Forest o Gradient Boosting.
5. **Evaluación.** Medir el error sobre periodos posteriores a los utilizados para el entrenamiento y analizar los resultados por estación y horizonte de predicción.

Debido a la naturaleza temporal del problema, los datos **no se dividirán aleatoriamente**. La separación de modelado se definirá después de revisar la disponibilidad real de O₃ en cada año, conservando siempre el orden temporal para evitar fuga de información del futuro hacia el entrenamiento.

Como referencia mínima se incluirá un modelo base de persistencia, que supone que el comportamiento reciente del O₃ es una aproximación de su comportamiento próximo. Los modelos desarrollados deberán superar esta referencia para demostrar que las variables adicionales aportan capacidad predictiva.

La evaluación se realizará principalmente mediante **MAE (Mean Absolute Error)** y **RMSE (Root Mean Squared Error)**, complementadas con gráficas de valores observados contra predichos y análisis del error a través del tiempo. Estas métricas permitirán comparar modelos utilizando las mismas observaciones y determinar no solo cuál obtiene menor error promedio, sino también en qué condiciones falla.

1.10 Fuente de información

Los datos utilizados provienen del Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León. Las bases disponibles para el proyecto contienen registros horarios de las estaciones de monitoreo durante el periodo 2020-2025. Cada registro combina información temporal, identificación de la estación, concentraciones de contaminantes y variables meteorológicas.

El reporte conservará los datos originales sin modificar como fuente de referencia y generará conjuntos derivados para limpieza, análisis y modelado. Las decisiones de exclusión, transformación o imputación se documentarán en las siguientes secciones y deberán responder directamente a las necesidades del problema de predicción de O₃.

2 Datos

2.1 Archivos fuente

La información original se encuentra en seis archivos de Excel proporcionados para el reto, uno por cada año entre 2020 y 2025. Cada archivo contiene varias hojas y cada hoja corresponde a una estación de monitoreo de SIMA. El archivo de 2025 contiene únicamente el periodo

disponible hasta junio, por lo que ese año tiene aproximadamente la mitad de registros que los años completos.

2.2 Carga inicial

El proyecto utiliza únicamente las estaciones NTE, NTE2, NO y NE. Por ello, estas cuatro hojas se seleccionan desde el momento de lectura de cada archivo y las demás estaciones no se cargan en memoria.

Todas las columnas provenientes de Excel se leen inicialmente como texto. Esto mantiene una lectura consistente entre años y deja las conversiones de tipo para una etapa posterior.

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
here() starts at /home/runner/work/Reto-Multivariados/Reto-Multivariados
```

`datos_brutos` contiene desde este punto únicamente las cuatro estaciones que se utilizarán en el proyecto. `Año` aparece como entero porque se agrega directamente desde el código; las columnas provenientes de Excel permanecen como `character` por la opción `col_types = "text"`.

2.3 Estructura y disponibilidad inicial

Primero se revisa cuántos registros aporta cada estación en cada año.

Table 1: Cantidad de registros por año y estación seleccionada

Año	NTE	NTE2	NO	NE
2020	8777	8776	8778	8776
2021	8759	8759	8759	8759
2022	8760	8760	8760	8760
2023	8758	8758	8758	8758
2024	8782	8782	8783	8784

Año	NTE	NTE2	NO	NE
2025	4345	4344	4344	4344

Las cuatro estaciones tienen cobertura durante los seis años. Entre 2020 y 2024 cada estación aporta aproximadamente 8,760 registros por año, consistente con mediciones horarias durante prácticamente todo el año. En 2025 se observan alrededor de 4,344 registros por estación porque la base disponible termina en junio.

También se resume la estructura resultante antes de homologar los nombres de las variables.

Table 2: Estructura inicial del conjunto de trabajo

Registros	Columnas	Años	Estaciones
192723	34	6	4

El conjunto reúne 192,723 registros de las cuatro estaciones seleccionadas. Antes de homologar, el número de columnas es mayor al esperado porque algunos archivos utilizan nombres diferentes para una misma variable.

2.4 Homologación de la estructura

Al comparar los encabezados de los seis archivos se identificaron algunas variables que cambian de nombre según el año. Estas equivalencias ya habían aparecido en el código anterior del proyecto y se conservaron porque corresponden a diferencias reales observadas en los archivos originales.

Table 3: Equivalencias utilizadas para homologar la estructura

Variable_estandar	Nombres_en_archivos
fecha_hora	fecha y hora / date
BP	BP / PRS
TEMP	TEMP / TOUT
WS	WS / WSR
WD	WD / WDR

Además, algunos encabezados contienen unidades entre paréntesis o saltos de línea. La función siguiente normaliza esas diferencias de formato y después combina las columnas equivalentes bajo un único nombre.

El resultado conserva una sola columna por variable y mantiene todavía las mediciones como texto.

Table 4: Verificación de la estructura homologada

Registros	Columnas	Variables_faltantes
192723	18	Ninguna

Después de la homologación se conservan los mismos 192,723 registros en 18 columnas y no falta ninguna de las variables esperadas para el análisis.

3 Preparación de los datos

3.1 Conversión de tipos

La estructura ya está homologada, pero las mediciones todavía se encuentran almacenadas como texto. En este paso se convierte `fecha_hora` a un formato de fecha y hora y las 15 variables de medición a tipo numérico. `Año` se mantiene como entero y `Estacion` como identificador de texto.

La columna temporal aparece en dos formatos dentro de los archivos: algunos registros se almacenan como números seriales de Excel y otros como texto con fecha y hora. La función siguiente contempla ambos casos sin modificar el orden temporal de las observaciones.

La zona horaria se fija como UTC únicamente para conservar una representación uniforme de fecha y hora; no se realiza una conversión del horario registrado por SIMA.

Antes de continuar con la limpieza se verifica que la transformación haya producido los tipos esperados y se cuantifican las fechas no vacías que no pudieron interpretarse.

Table 5: Tipos de datos después de la transformación

Elemento	Resultado
Año	integer
Estacion	character
fecha_hora	POSIXct
Variables de medición	15/15 numéricas

Table 6: Verificación de la conversión de fecha y hora

Primera_fecha	Ultima_fecha	Fechas_no_convertidas
2020-01-01	2025-06-30 23:00:00	0

La conversión produjo las 15 variables de medición en formato numérico y **fecha_hora** en formato **POSIXct**. El periodo resultante va del 1 de enero de 2020 al 30 de junio de 2025 a las 23:00, sin fechas que hayan quedado sin convertir.

3.2 Valores faltantes y registros inválidos

Antes de reemplazar o eliminar valores se cuantifican los problemas presentes en cada variable. Esta revisión distingue tres situaciones: valores que ya están ausentes (**NA**), valores no vacíos que no pudieron convertirse a número y la bandera **-9999**, utilizada en los archivos para indicar mediciones no válidas en algunas variables.

Table 7: Diagnóstico inicial de valores faltantes y banderas por variable

Variable	Faltantes	No_numericos	Bandera_menos9999	Porcentaje_faltante
CO	34579	4	0	17.94
NO	39363	4	0	20.42
NO2	45604	4	0	23.66
NOX	45037	4	0	23.37
O3	46839	4	0	24.30
PM10	10619	0	0	5.51
PM2.5	37925	0	0	19.68
SO2	47202	4	0	24.49
BP	15629	4	0	8.11
RAINF	14392	4	0	7.47
RH	36101	4	2	18.73
SR	7099	0	1	3.68
TEMP	27486	4	1	14.26
WS	19749	4	0	10.25
WD	20742	4	0	10.76

Los faltantes representan un problema importante para varias variables. **SO2** presenta 24.49 % de ausencia, **NO2** 23.66 %, **NOX** 23.37 % y **NO** 20.42 %. Si estas variables se incorporan como predictoras sin un tratamiento específico, podrían reducir considerablemente la cantidad de observaciones disponibles para entrenar los modelos.

El caso más importante para el objetivo del proyecto es O3: faltan 46,839 de los 192,723 registros, equivalentes al 24.30 %. Esto deja 145,884 mediciones observadas de la variable que se desea predecir. Los momentos donde el valor objetivo no está disponible no podrán utilizarse directamente para entrenar o evaluar una predicción de esa hora, por lo que antes de construir los horizontes de pronóstico será necesario revisar cómo se distribuyen estas ausencias entre años y estaciones.

La disponibilidad es considerablemente mayor en variables como SR (3.68 % de faltantes), PM10 (5.51 %), RAINF (7.47 %) y BP (8.11 %). Las banderas -9999 son poco frecuentes: aparecen únicamente en RH (2 casos), SR (1) y TEMP (1), por lo que no explican los porcentajes elevados de ausencia. También aparecen cuatro valores no numéricos en varias variables, una cantidad mínima respecto al tamaño total de la base, aunque deberán identificarse antes de cerrar la limpieza.

También se verifica que no existan dos registros para la misma estación y la misma fecha-hora.

Table 8: Verificación de registros duplicados

Combinaciones_duplicadas	Registros_involucrados
0	0

No se encontraron registros duplicados para una misma combinación de estación y fecha-hora, por lo que no es necesario eliminar observaciones por este motivo.

Antes de imputar o eliminar valores faltantes conviene revisar su distribución por año y estación. Un porcentaje global de 24.30 % en O3, por ejemplo, puede corresponder a ausencias relativamente uniformes o estar concentrado en periodos y estaciones específicos; ambas situaciones requieren decisiones de modelado distintas.

3.2.1 Disponibilidad de O3 y selección del periodo

Como O3 es la variable objetivo, se revisa directamente su porcentaje de ausencia por estación y año. En esta variable no se encontraron banderas -9999, por lo que sus faltantes corresponden a valores NA después de la conversión.

Table 9: Porcentaje de O3 faltante por año y estación

Año	NE	NO	NTE	NTE2
2020	99.90	98.44	99.99	93.33
2021	16.03	20.34	18.52	9.49
2022	3.80	6.18	4.28	2.45
2023	4.96	5.99	7.25	2.89

Año	NE	NO	NTE	NTE2
2024	3.73	11.02	4.02	5.86
2025	19.31	5.89	4.03	1.84

La tabla muestra que la falta de O3 está concentrada principalmente en **2020**. Ese año faltan 99.90 % de las mediciones en NE, 98.44 % en NO, 99.99 % en NTE y 93.33 % en NTE2, por lo que prácticamente no existe información de la variable objetivo para entrenar o evaluar un modelo supervisado. A partir de 2021 la cobertura mejora de manera considerable; aunque todavía existen faltantes, entre 2022 y 2024 los porcentajes son generalmente inferiores a 11 % y no se observa una estación cuya cobertura justifique eliminarla del análisis.

Con base en esta evidencia, **2020 se conserva únicamente como parte de la fuente histórica original y se excluye del periodo de modelado**. El periodo útil queda definido entre 2021 y 2025, con 2021-2023 para entrenamiento, 2024 para validación y 2025 para prueba final.

3.2.2 Continuidad y tratamiento de los faltantes de O3 desde 2021

Para decidir si los valores faltantes pueden imputarse no basta con conocer su porcentaje. En un problema temporal también importa saber si aparecen como horas aisladas o como interrupciones prolongadas. Por ello se reconstruye una secuencia horaria completa por estación desde 2021 y se identifican los bloques consecutivos sin O3.

Table 10: Diez bloques consecutivos de O3 faltante más largos desde 2021

Estacion	Año	Inicio	Fin	Horas
NO	2021	2021-01-01 00:00:00	2021-03-05 23:00:00	1536
NTE	2021	2021-01-01 00:00:00	2021-02-23 23:00:00	1296
NE	2021	2021-01-01 00:00:00	2021-02-23 11:00:00	1284
NE	2025	2025-06-01 00:00:00	2025-06-30 23:00:00	720
NTE2	2021	2021-01-01 00:00:00	2021-01-19 12:00:00	445
NTE	2023	2023-08-09 14:00:00	2023-08-18 15:00:00	218
NO	2024	2024-04-26 17:00:00	2024-05-03 11:00:00	163
NTE2	2024	2024-09-29 10:00:00	2024-10-04 11:00:00	122
NO	2025	2025-03-29 18:00:00	2025-04-02 14:00:00	93
NO	2024	2024-06-20 22:00:00	2024-06-24 14:00:00	89

Los bloques más largos confirman que algunas ausencias no son horas aisladas. Al inicio de 2021, NO permanece 1,536 horas consecutivas sin O3, NTE 1,296 horas y NE 1,284 horas. También

existen interrupciones posteriores, aunque de menor duración. Imputar estos periodos implicaría crear semanas de valores sintéticos y podría distorsionar la dinámica real del contaminante.

Por ello, **O3 no se imputará cuando funcione como variable objetivo**. Las horas sin una medición real de O3 no se utilizarán como respuesta durante el entrenamiento ni para calcular el error de evaluación. Si O3 se utiliza posteriormente como predictor mediante rezagos, sus faltantes también se conservarán como NA y se cuantificará cuántas observaciones permanecen disponibles con los rezagos seleccionados.

A partir de este punto se define una base preliminar para el modelado con los años 2021-2025. Las pocas banderas -9999 detectadas en otras variables se convierten a NA, pero todavía no se eliminan registros ni se imputan mediciones.

Table 11: Base preliminar para el modelado de O3

Registros	Desde	Hasta	Estaciones
157616	2021-01-01	2025-06-30 23:00:00	4

`datos_base_modelado` conserva la estructura original del periodo útil y mantiene explícitamente los faltantes. Todavía no se considera un conjunto limpio definitivo: faltan revisar los valores físicamente inválidos o extremos y definir el tratamiento de las variables predictoras antes de construir los rezagos.

3.3 Valores extremos

El análisis anterior cierra por ahora la revisión específica de **disponibilidad y continuidad de O3**. El comportamiento del contaminante todavía se estudiará más adelante en el análisis exploratorio, pero ya quedó definido qué periodo se utilizará y cómo se tratarán sus valores faltantes cuando funcione como variable objetivo.

Antes de considerar la base como limpia se revisan los valores extremos de todas las variables. Para ello se retoman los límites de validación por año utilizados previamente en el proyecto. Estos límites se emplean únicamente para detectar mediciones fuera del rango aceptado; un valor estadísticamente extremo que permanezca dentro de ellos no se eliminará automáticamente, ya que puede representar un episodio real.

Table 12: Diagnóstico de valores extremos en la base de modelado

Variable	Min_obser- vado	P01	Mediana	P99	Max_obser- vado	Fuera_de_rango
BP	680.10	704.40	714.70	727.30	735.7	73
CO	0.00	0.19	1.17	3.79	15.3	2

Variable	Min_obser- vado	P01	Mediana	P99	Max_obser- vado	Fuera_de_rango
NO	0.50	0.90	5.20	119.30	945.1	13
NO2	0.00	2.70	13.10	57.00	165.1	0
NOX	0.50	4.30	19.30	162.60	971.8	16
O3	-9.00	2.00	23.00	87.00	173.0	1
PM10	1.00	8.63	51.00	209.00	1001.0	3
PM2.5	0.00	3.00	17.00	67.00	999.0	0
RAINF	0.00	0.00	0.00	0.01	45.0	0
RH	0.00	5.00	57.00	95.00	714.2	260
SO2	0.50	1.50	3.90	16.10	163.6	0
SR	-0.01	0.00	0.00	0.78	2.0	656
TEMP	-8.75	4.69	24.30	37.94	785.0	22
WD	1.00	5.00	104.00	355.00	360.0	0
WS	0.10	1.00	7.60	21.50	58.5	16

Para saber en qué años se concentran las posibles mediciones inválidas se muestran únicamente las combinaciones año-variable que contienen al menos un valor fuera del rango correspondiente.

Table 13: Valores fuera de rango por año y variable

Año	Variable	Fuera_de_rango
2022	SR	617
2022	RH	151
2023	RH	82
2022	BP	29
2023	BP	25
2024	RH	24
2021	SR	21
2024	TEMP	20
2024	BP	19
2021	WS	16
2022	NOX	11
2024	SR	10
2022	NO	8
2021	NO	5
2021	NOX	5
2023	SR	4
2025	SR	4
2021	RH	3

Año	Variable	Fuera_de_rango
2023	PM10	2
2021	CO	1
2022	PM10	1
2022	TEMP	1
2023	CO	1
2023	TEMP	1
2024	O3	1

SR y RH concentran la mayor cantidad de observaciones fuera de los límites utilizados. SR presenta 656 casos, equivalentes aproximadamente al 0.42 % de la base de modelado, y 617 de ellos corresponden a 2022. RH presenta 260 casos, cerca del 0.16 % de la base, concentrados principalmente en 2022, 2023 y 2024. Aunque estas proporciones son pequeñas respecto al total de registros, conviene identificar si proceden de una estación específica antes de aplicar la limpieza.

Para ello se revisan únicamente los valores fuera de rango de SR y RH por año y estación, incluyendo el mínimo y máximo observados entre los casos inválidos.

Table 14: Valores fuera de rango de SR y RH por año y estación

Año	Estacion	Variable	Casos	Min_fuera	Max_fuera
2021	NO	RH	3	101.00	101.00
2022	NO	RH	151	101.00	714.20
2023	NO	RH	82	101.00	101.00
2024	NO	RH	20	101.00	102.00
2024	NTE	RH	4	103.00	151.00
2021	NO	SR	10	0.00	1.96
2021	NE	SR	8	-0.01	-0.01
2021	NTE	SR	3	0.00	0.00
2022	NTE	SR	604	-0.01	1.94
2022	NE	SR	13	-0.01	0.00
2023	NE	SR	4	0.00	0.00
2024	NE	SR	9	0.00	0.00
2024	NTE	SR	1	1.26	1.26
2025	NE	SR	1	2.00	2.00
2025	NO	SR	1	2.00	2.00
2025	NTE	SR	1	2.00	2.00
2025	NTE2	SR	1	2.00	2.00

Los valores fuera de rango de RH están casi totalmente concentrados en la estación NO: 256 de

los 260 casos provienen de esa estación. En 2022 aparecen 151 registros fuera del intervalo 0-100 %, incluyendo un máximo de 714.2 %, por lo que se consideran mediciones inválidas. Los cuatro casos restantes corresponden a NTE en 2024.

En SR también se observa un problema localizado. De los 656 casos fuera de rango, 604 corresponden a NTE durante 2022. El resto se distribuye en cantidades pequeñas entre otras estaciones y años. Algunos valores cercanos a cero aparecen redondeados como 0.00 en la tabla aunque son ligeramente negativos y, por lo tanto, quedan fuera del límite inferior correspondiente.

Dado que estos casos representan una proporción pequeña de la base y que varios corresponden a valores físicamente imposibles o incompatibles con los límites de validación establecidos, se conservarán las filas completas y únicamente se sustituirá por NA la medición inválida.

3.3.1 Construcción de la base limpia

Se aplican los límites específicos de cada año a todas las variables de medición. Cuando una observación cae fuera de su intervalo permitido, solo esa celda se convierte a NA; no se elimina el registro horario completo.

Después de la transformación se vuelve a comprobar que no permanezcan valores fuera de los límites utilizados.

Table 15: Verificación de la base limpia

Registros	Valores_convertidos_a_NA	Fuera_de_rango_restantes
157616	1062	0

`datos_limpios` mantiene los 157,616 registros del periodo 2021-2025. Se convirtieron 1,062 mediciones fuera de rango a NA y la verificación posterior confirmó que no quedan valores fuera de los límites establecidos. La limpieza no elimina horas completas; los valores extremos que permanecen dentro de los límites se conservan porque pueden corresponder a episodios reales y resultar relevantes para el modelado.

3.4 Variables temporales y espaciales

La concentración de O₃ presenta una dinámica horaria y estacional, por lo que la fecha y hora original se descompone en variables que permitan estudiar esos patrones sin perder el orden temporal. También se prepara la estación de monitoreo como una variable categórica para representar diferencias entre ubicaciones.

Se conservan `fecha_hora` y `Año` como referencias temporales. A partir de `fecha_hora` se crean `Fecha`, `Hora`, `Dia_semana` y `Mes`. Las variables `Hora` y `Mes` también se representan mediante

componentes seno y coseno porque son cíclicas: las 23:00 y las 00:00 son horas cercanas, igual que diciembre y enero, aunque sus valores numéricos simples se encuentren en extremos opuestos de la escala.

Fecha, **Hora**, **Dia_semana** y **Mes** se conservarán porque son fáciles de interpretar y serán útiles durante el análisis exploratorio. Las parejas **Hora_sin-Hora_cos** y **Mes_sin-Mes_cos** quedan disponibles para modelos que necesiten representar de manera continua los ciclos diario y anual.

Table 16: Variables temporales y espaciales preparadas

Variable	Resultado
Fecha	2021-01-01 a 2025-06-30
Hora	0-23
Dia_semana	Lunes, Martes, Miercoles, Jueves, Viernes, Sabado, Domingo
Mes	1-12
Estacion	NTE, NTE2, NO, NE
Hora_sin / Hora_cos	Representacion ciclica de 24 horas
Mes_sin / Mes_cos	Representacion ciclica de 12 meses

La variable **Fecha** servirá principalmente para ordenar y visualizar la serie temporal, mientras que **Año** se utilizará para mantener la separación cronológica entre entrenamiento, validación y prueba. La estación de monitoreo se conserva como factor con cuatro niveles (NTE, NTE2, NO y NE). Todavía no se decide cuáles de estas variables entrarán en cada modelo; esa selección se realizará después del análisis exploratorio y junto con la construcción de rezagos.

4 Análisis exploratorio

4.1 Comportamiento del O3

El análisis exploratorio comienza con la variable objetivo. En este primer bloque se revisa su distribución general, se compara entre las cuatro estaciones y se estudia su patrón promedio a lo largo de las 24 horas del día. Solo se utilizan mediciones válidas de O3; los valores faltantes permanecen fuera de los cálculos descriptivos.

Table 17: Resumen descriptivo de O3 entre 2021 y 2025

Observaciones	Media	Mediana	Desv_estandar	P25	P75	Minimo	Maximo
145151	27.12	23	18.97	13	37	1	173




Figure 1: Distribución de las concentraciones horarias de O3

Entre 2021 y junio de 2025 se conservan 145,151 mediciones válidas de O3. La media es 27.12 y la mediana 23, mientras que el 50 % central de las observaciones se encuentra entre 13 y 37. El histograma muestra una distribución asimétrica hacia la derecha: la mayoría de las concentraciones se agrupa en valores relativamente bajos y existe una cola prolongada hacia valores altos, con un máximo observado de 173. Por ello, la distribución marginal de O3 no presenta una forma aproximadamente normal. Esto no impide utilizar posteriormente modelos de regresión lineal; en ese caso los supuestos se revisarán sobre los residuos del modelo y no sobre la normalidad de O3 por sí sola.

4.2 Diferencias entre estaciones

Se comparan las mediciones de O3 de NTE, NTE2, N0 y NE mediante estadísticos descriptivos y su distribución por estación.

Table 18: Resumen de O3 por estación

Estacion	Observaciones	Media	Mediana	P25	P75
NTE	36244	26.53	23	12	37
NTE2	37508	24.58	20	12	34
NO	35332	29.79	26	14	42
NE	36067	27.73	25	15	37




Figure 2: Distribución de O3 por estación

Las cuatro estaciones presentan distribuciones con una forma general similar, aunque existen diferencias en el nivel de concentración. NO registra los valores centrales más altos, con media de 29.79 y mediana de 26, mientras que NTE2 presenta los más bajos, con media de 24.58 y mediana de 20. NTE y NE se ubican entre ambos casos. Estas diferencias justifican conservar la estación como información potencialmente útil para el modelo, aunque el comportamiento general de O3 es comparable entre los cuatro puntos de monitoreo.

4.2.1 Patrón horario

Finalmente se calcula la media y la mediana de O₃ para cada hora del día. Esta revisión permite identificar si existe una estructura diaria suficientemente marcada como para justificar el uso de variables horarias en el modelo.

Table 19: Concentración de O₃ por hora del día

Hora	Media	Mediana
0	19.01	18
1	18.62	18
2	18.01	17
3	17.25	16
4	16.43	15
5	15.03	13
6	12.80	11
7	11.27	9
8	12.21	11
9	15.95	15
10	22.23	21
11	30.68	30
12	39.66	39
13	46.46	45
14	49.86	48
15	50.17	48
16	48.43	46
17	44.65	43
18	38.61	37
19	31.11	30
20	24.78	24
21	21.44	21
22	20.01	19
23	19.39	19




Figure 3: Patrón horario de O3

El patrón horario es marcado. Las concentraciones disminuyen desde la medianoche hasta alcanzar el mínimo diario alrededor de las 7:00, con una media de 11.27 y una mediana de 9. A partir de las 9:00 comienza un aumento claro y entre las 11:00 y las 19:00 se concentra la parte más elevada del ciclo. El máximo medio aparece alrededor de las 15:00, con valores cercanos a 50, y después el O3 disminuye de nuevo durante la tarde y la noche. La similitud entre la media y la mediana a lo largo del día indica que este patrón no depende únicamente de unas pocas observaciones extremas.

Este comportamiento plantea una decisión importante para el modelado. Las horas nocturnas no se eliminarán de la base porque pueden aportar información histórica para construir rezagos y otros predictores. Sin embargo, sí conviene evaluar si el **objetivo del modelo** debe restringirse a las horas donde el O3 presenta su incremento y sus niveles más altos, ya que incluir muchas horas nocturnas de concentración baja podría hacer que las métricas globales aparenten un desempeño mejor sin reflejar adecuadamente la capacidad para anticipar los periodos más relevantes.

4.2.2 Estabilidad del patrón horario entre años

Antes de decidir si el modelo debe evaluar las 24 horas del día o concentrarse únicamente en un periodo diurno, se comprueba si el ciclo horario anterior se repite de forma consistente entre años. Para esta comparación se utilizan los años completos 2021-2024; 2025 se deja fuera porque termina en junio y su promedio horario podría quedar influido por la mezcla incompleta de meses.

Table 20: Concentración media de O₃ por hora y año

Hora	2021	2022	2023	2024
0	19.71	17.91	18.82	18.92
1	19.40	17.62	18.44	18.67
2	18.88	17.01	17.83	18.26
3	17.77	16.33	17.33	17.58
4	16.41	15.41	16.83	17.03
5	14.33	13.46	16.06	16.03
6	12.56	11.01	14.20	13.49
7	11.49	9.52	12.73	11.48
8	12.44	10.50	13.71	12.18
9	16.47	14.51	16.85	15.94
10	22.90	21.11	22.61	22.10
11	31.74	29.98	30.58	30.36
12	41.10	38.91	39.02	39.38
13	48.39	44.57	45.25	46.73
14	51.89	46.92	47.79	51.06
15	51.48	47.07	48.33	51.63
16	49.65	45.24	46.95	49.64
17	45.26	42.01	43.15	45.67
18	38.75	36.55	37.14	39.19
19	30.90	29.27	30.07	31.47
20	24.89	22.79	24.08	25.24
21	21.35	19.71	21.18	21.97
22	20.13	18.57	19.80	20.23
23	19.92	18.24	19.21	19.27




Figure 4: Patrón horario de O3 en los años completos 2021-2024

La comparación por año confirma que el ciclo horario es estable. Aunque cambian ligeramente los niveles medios entre 2021, 2022, 2023 y 2024, los cuatro años muestran la misma estructura general: descenso durante la madrugada, mínimo alrededor de las 7:00, aumento rápido durante la mañana, máximo durante la tarde y disminución posterior. Por lo tanto, la diferencia entre horas nocturnas y diurnas no parece ser consecuencia de un año particular, sino una característica recurrente del comportamiento del O3 en las estaciones analizadas.

4.2.3 Concentración de valores altos de O3 por hora

Para apoyar la decisión sobre el intervalo horario del objetivo se revisa en qué horas se concentran las observaciones relativamente altas de O3. Como referencia descriptiva se utiliza el tercer cuartil de la distribución completa, es decir, el valor que deja por debajo al 75 % de las mediciones válidas. En la base actual este umbral es cercano a 37.

Esta referencia no representa un límite normativo de calidad del aire; se utiliza únicamente para identificar las horas donde se concentra la parte superior de la distribución observada y comparar posibles ventanas de modelado.

Table 21: Concentraciones superiores al tercer cuartil de O3 por hora (umbral = 37)

Hora	Observaciones	O3_altos	Por- centaje_alto_en_hora	Participacion_del_total_alto
0	5866	335	5.7	0.9
1	5992	329	5.5	0.9
2	5970	285	4.8	0.8
3	5907	243	4.1	0.7
4	5836	208	3.6	0.6
5	5781	160	2.8	0.4
6	5731	106	1.8	0.3
7	5709	59	1.0	0.2
8	5808	59	1.0	0.2
9	6078	127	2.1	0.4
10	6169	538	8.7	1.5
11	6187	1806	29.2	5.0
12	6199	3257	52.5	9.0
13	6215	4147	66.7	11.5
14	6212	4510	72.6	12.5
15	6201	4527	73.0	12.6
16	6203	4344	70.0	12.1
17	6189	3877	62.6	10.8
18	6175	3060	49.6	8.5
19	6182	1839	29.7	5.1
20	6192	874	14.1	2.4
21	6165	517	8.4	1.4
22	6119	416	6.8	1.2
23	6065	403	6.6	1.1




Figure 5: Porcentaje de mediciones de O3 por encima del tercer cuartil según la hora

Además se comparan algunas ventanas horarias candidatas. Para cada una se calcula qué porcentaje de todas las observaciones altas queda incluido y qué proporción de las mediciones válidas de O3 sería utilizada como objetivo. Esto permite valorar el equilibrio entre concentrarse en las horas relevantes y conservar suficiente información para el modelado.

Table 22: Comparación de ventanas candidatas para el objetivo diurno

Ventana	Horas_incluidas	Observaciones_objetivo	Porcentaje_datos_conservados	O3_al_tos_incluidos	Cober-tura_de_O3_al_tos
09:00-20:00	12	74202	51.1	32906	91.3
10:00-20:00	11	68124	46.9	32779	91.0
10:00-19:00	10	61932	42.7	31905	88.6
11:00-19:00	9	55763	38.4	31367	87.1

La decisión final sobre la ventana horaria se tomará después de revisar estos resultados. Independientemente del intervalo seleccionado, las mediciones de las 24 horas se conservarán en la base como información histórica; la posible restricción afectaría únicamente a las horas utilizadas como **objetivo y evaluación** del pronóstico.

4.2.4 Patrón mensual

Después del ciclo diario se revisa si el O3 también presenta cambios sistemáticos a lo largo del año. Se calcula la media y la mediana para cada mes utilizando todas las mediciones válidas disponibles. Debido a que la base de 2025 termina en junio, los meses de enero a junio incluyen datos de cinco años, mientras que julio a diciembre contienen únicamente información de 2021 a 2024.

Table 23: Concentración de O3 por mes

Mes	Observaciones	Media	Mediana
1	11339	20.96	18
2	10987	24.80	20
3	14310	31.20	28
4	13928	31.44	28
5	14409	33.06	28
6	13058	30.13	25
7	11713	26.45	22
8	11474	27.26	23
9	11048	29.07	25
10	11343	26.13	22
11	10734	21.33	17
12	10808	18.78	14




Figure 6: Patrón mensual de O3

El patrón mensual también es claro. Las concentraciones son menores durante el invierno, con medias de 18.78 en diciembre y 20.96 en enero. A partir de febrero aumentan y permanecen elevadas durante la primavera, alcanzando la media mensual más alta en mayo (33.06). Posteriormente disminuyen durante junio y julio, aparece un segundo incremento hacia septiembre (29.07) y vuelven a descender durante octubre, noviembre y diciembre. La media permanece por encima de la mediana en todos los meses, consistente con la asimetría hacia valores altos observada previamente.

Este comportamiento muestra una asociación importante entre la época del año y la concentración de O3, por lo que la representación cíclica del mes puede aportar información predictiva. Sin embargo, el mes no se interpreta como una causa directa: puede estar representando cambios estacionales en temperatura, radiación solar, humedad, viento y otras condiciones atmosféricas que se analizarán posteriormente.

4.2.5 Estabilidad del patrón mensual entre años

Antes de asumir que el ciclo mensual es estable, se compara por separado entre los años completos 2021, 2022, 2023 y 2024. El año 2025 no se incluye en esta comparación porque solo

contiene datos hasta junio.

Table 24: Concentración media mensual de O3 por año

Mes	2021	2022	2023	2024
1	12.11	19.74	21.73	23.38
2	15.18	24.60	22.64	30.85
3	31.64	32.98	24.58	34.61
4	33.75	28.54	24.37	35.23
5	35.47	29.84	28.00	36.08
6	32.96	26.46	35.30	27.70
7	25.37	27.38	29.29	23.75
8	25.56	25.12	32.26	26.51
9	30.59	25.11	33.85	26.54
10	24.22	27.11	26.60	26.60
11	19.58	20.59	22.15	23.03
12	21.09	16.33	20.90	16.84




Figure 7: Patrón mensual de O3 en los años completos 2021-2024

El patrón mensual no es idéntico entre años, pero conserva una estructura general. En los cuatro años se observa un aumento entre el invierno y la primavera, concentraciones relativamente altas durante parte de la primavera y el verano, y una disminución marcada hacia noviembre y diciembre. Existen variaciones interanuales: 2021 comienza con concentraciones especialmente bajas y 2023 presenta sus niveles más altos más tarde, entre junio y septiembre. Estas diferencias no eliminan la señal estacional, por lo que `Mes_sin` y `Mes_cos` siguen siendo variables razonables para representar el ciclo anual en el modelo.

4.3 Relación con variables meteorológicas y contaminantes

4.3.1 Variables meteorológicas

El siguiente paso es cuantificar la asociación lineal entre O3 y las principales variables meteorológicas. Se consideran `TEMP`, `RH`, `SR`, `WS`, `BP` y `RAINF` y se calcula el coeficiente de correlación de Pearson utilizando, para cada par, únicamente las horas donde ambas mediciones están disponibles.

WD no se incluye directamente en esta correlación porque la dirección del viento es circular: valores cercanos a 0° y 360° representan direcciones similares aunque numéricamente se encuentren en extremos opuestos. Su tratamiento se realizará por separado.

Table 25: Correlación de Pearson entre O3 y variables meteorológicas

Variable	Observaciones	Correlacion
SR	140963	0.571
RH	123784	-0.525
TEMP	132520	0.501
WS	142359	0.378
BP	143839	-0.161
RAINF	142757	0.000

La magnitud y el signo de las correlaciones se visualizan para identificar rápidamente qué variables presentan una asociación lineal más clara con O3.




Figure 8: Correlación de O3 con variables meteorológicas

Para revisar la forma de las relaciones se muestran además las tres variables con mayor correlación absoluta. Debido al tamaño de la base, la gráfica utiliza una muestra aleatoria de 10,000 observaciones únicamente para facilitar la visualización; las correlaciones de la tabla anterior se calculan con todos los pares disponibles.

```
`geom_smooth()` using formula = 'y ~ x'
```




Figure 9: Relación de O3 con las variables meteorológicas de mayor correlación

Las asociaciones más claras se observan con SR, RH y TEMP. La radiación solar presenta la mayor correlación positiva con O3 ($r = 0.571$), seguida de la temperatura ($r = 0.501$). En sentido contrario, la humedad relativa muestra una correlación negativa de magnitud similar ($r = -0.525$): las concentraciones de O3 tienden a ser menores cuando aumenta la humedad. La velocidad del viento presenta una asociación positiva moderada ($r = 0.378$), mientras que la presión atmosférica tiene una relación lineal débil y negativa ($r = -0.161$). La precipitación prácticamente no presenta asociación lineal contemporánea con O3 ($r \approx 0$).

Los diagramas de dispersión confirman las tendencias generales de SR, RH y TEMP, aunque también muestran una dispersión considerable alrededor de las rectas. Por ello, estas variables aportan información relevante, pero ninguna explica por sí sola el comportamiento del O3 y es razonable esperar que el modelo necesite combinar meteorología, patrones temporales y antecedentes del propio contaminante.

Estas correlaciones describen mediciones tomadas en la misma hora. Para el pronóstico no se utilizarán valores meteorológicos futuros que no estén disponibles al momento de generar la predicción; durante la construcción de rezagos se conservará únicamente información conocida hasta el instante t .

4.3.2 Dirección del viento

La dirección del viento se analiza por separado porque una correlación lineal directa con los grados no representa correctamente su naturaleza circular. Para facilitar la interpretación, los grados se agrupan en ocho sectores cardinales. Además, se crean las componentes `WD_sin` y `WD_cos`, que permitirán conservar la dirección como variable continua y circular durante el modelado.

Se compara la concentración de O₃ entre los ocho sectores utilizando la media y la mediana de las horas con información válida de O₃ y dirección del viento.

Table 26: Concentración de O₃ según la dirección del viento

Sector_viento	Observaciones	Media	Mediana
N	23360	22.25	19
NE	28699	26.32	22
E	32335	31.42	27
SE	32044	32.42	28
S	8706	29.75	27
SO	4637	17.40	12
O	5628	13.79	9
NO	7315	15.92	11




Figure 10: Concentración media de O3 según la dirección del viento

La dirección del viento muestra diferencias claras en la concentración de O3. Los valores medios más altos aparecen cuando el viento proviene del sureste (SE, 32.42), este (E, 31.42) y sur (S, 29.75). En contraste, las concentraciones son considerablemente menores con viento del oeste (O, 13.79), noroeste (NO, 15.92) y suroeste (SO, 17.40). Las medianas siguen el mismo patrón, por lo que la diferencia no parece depender únicamente de observaciones extremas.

Este resultado indica que la dirección del viento contiene información potencialmente útil para la predicción. Sin embargo, la comparación es descriptiva y no implica que la dirección por sí sola cause las diferencias de O3; parte del patrón puede estar asociada con la estación, la hora del día, la temporada u otras condiciones meteorológicas. Para el modelado se conservarán `WD_sin` y `WD_cos`, que representan la dirección sin romper su naturaleza circular.

4.3.3 Otros contaminantes

Después de la meteorología se revisa la asociación contemporánea entre O3 y los demás contaminantes disponibles: CO, NO, NO2, NOX, PM10, PM2.5 y S02. Igual que en el bloque meteorológico, se calcula Pearson utilizando únicamente los pares de horas donde ambas variables están disponibles.

Table 27: Correlación de Pearson entre O3 y otros contaminantes

Variable	Observaciones	Correlacion
NOX	139621	-0.363
NO	138511	-0.337
NO2	139463	-0.306
SO2	134161	0.193
CO	140600	-0.089
PM10	142116	-0.036
PM2.5	119455	-0.028

La magnitud y el signo de las asociaciones se muestran también de forma gráfica.




Figure 11: Correlación de O3 con otros contaminantes

Para las tres asociaciones de mayor magnitud se revisa además la forma de la relación mediante una muestra de 10,000 registros. La tabla de correlaciones anterior continúa utilizando todos los pares válidos disponibles.

```
`geom_smooth()` using formula = 'y ~ x'
```




Figure 12: Relación de O3 con los contaminantes de mayor correlación

Las asociaciones contemporáneas con los demás contaminantes son más débiles que las observadas con las principales variables meteorológicas. NOX presenta la mayor magnitud ($r = -0.363$), seguido de NO ($r = -0.337$) y NO2 ($r = -0.306$); en los tres casos la relación es negativa. SO2 muestra una asociación positiva débil ($r = 0.193$), mientras que CO ($r = -0.089$), PM10 ($r = -0.036$) y PM2.5 ($r = -0.028$) presentan relaciones lineales muy pequeñas.

Los diagramas de dispersión de NO, NO2 y NOX muestran una tendencia descendente, pero con una dispersión considerable. La recta de ajuste incluso puede extrapolar valores negativos de O3 para concentraciones muy altas de NO o NOX; esto no representa una concentración física posible y confirma que la línea se utiliza únicamente como resumen de la tendencia lineal, no como modelo definitivo de la relación.

Estas correlaciones describen contaminantes medidos en la misma hora y no son suficientes para descartar variables de cara al pronóstico. Un contaminante con asociación contemporánea débil podría aportar información cuando se utilicen sus valores previos. Además, la selección final deberá considerar los faltantes y la redundancia entre NO, NO2 y NOX, que representan procesos relacionados y no necesariamente conviene incorporar simultáneamente en una regresión lineal.

5 Preparación para modelado

5.1 Construcción de rezagos

El análisis anterior estudió relaciones entre variables observadas en la misma hora. Para un pronóstico real, sin embargo, el modelo solo podrá utilizar información disponible hasta el momento en que se genera la predicción. Por ello, el siguiente paso es estudiar cuánto aporta el comportamiento reciente del propio O3.

Un rezago de h horas representa la concentración observada h horas antes:

$$O_3(t - h)$$

Primero se calcula la relación entre $O_3(t)$ y los valores observados entre 1 y 24 horas antes. Esta separación temporal es equivalente a estudiar cuánto puede aportar $O_3(t)$ para anticipar $O_3(t + h)$ a la misma distancia de tiempo.

Para evitar que la selección de rezagos dependa de los periodos reservados para validación y prueba, este diagnóstico utiliza únicamente **2021-2023**, que corresponde al conjunto de entrenamiento. Además, se reconstruye una secuencia horaria completa por estación antes de aplicar `lag()`. De esta forma, si falta por completo una hora en la base, un rezago de 1 hora sigue representando exactamente una hora anterior y no simplemente la fila previa disponible.

A continuación se calcula, para cada separación de 1 a 24 horas, la correlación entre el O3 actual y su valor rezagado. Los pares con alguna de las dos mediciones ausentes no participan en el cálculo.

Table 28: Correlación de O3 con sus valores de 1 a 24 horas anteriores

Rezago_h	Observaciones	Correlacion
1	94670	0.916
2	94013	0.762
3	93578	0.579
4	93311	0.388
5	93099	0.211
6	92953	0.063
7	92847	-0.050
8	92737	-0.127
9	92651	-0.173
10	92580	-0.195
11	92531	-0.205
12	92488	-0.208
13	92448	-0.206

Rezago_h	Observaciones	Correlacion
14	92439	-0.198
15	92435	-0.176
16	92424	-0.133
17	92425	-0.062
18	92427	0.041
19	92452	0.171
20	92487	0.321
21	92540	0.475
22	92604	0.612
23	92680	0.708
24	92734	0.741





Figure 13: Persistencia temporal del O3 entre 1 y 24 horas

También se calcula el mismo patrón por estación. Esto permite comprobar si la persistencia temporal es semejante en NTE, NTE2, NO y NE o si algún punto de monitoreo presenta una dinámica distinta.



El O3 presenta una dependencia temporal muy marcada. La correlación con la hora inmediatamente anterior es de 0.916 y continúa siendo alta a dos horas (0.762) y tres horas (0.579), lo que muestra una fuerte persistencia de corto plazo. A medida que aumenta el rezago, la relación disminuye y se vuelve negativa entre aproximadamente 7 y 17 horas, alcanzando su valor más bajo cerca de 12 horas ($r = -0.208$). Este cambio de signo es consistente con el ciclo diario observado previamente: un intervalo cercano a 12 horas suele comparar momentos opuestos del patrón diario, por ejemplo la madrugada con las horas de mayor concentración de la tarde.

Después de ese punto la correlación vuelve a aumentar y alcanza 0.741 a las 24 horas. Esto indica una segunda señal temporal importante: la concentración observada a una hora determinada suele parecerse a la registrada a la misma hora del día anterior. Las cuatro estaciones presentan prácticamente la misma forma de curva, por lo que la persistencia de corto plazo y la periodicidad diaria no parecen depender de una estación específica.

Estos resultados no implican que deban incorporarse los 24 rezagos al modelo. Los rezagos consecutivos contienen información muy similar entre sí y podrían introducir redundancia, especialmente en una regresión lineal. Como punto de partida, los rezagos de 1 a 3 horas y el de 24 horas son candidatos naturales, aunque la selección definitiva se realizará mediante validación.

5.1.1 Predictores meteorológicos y O3 futuro

Después de estudiar el propio O3, se analiza directamente si las condiciones meteorológicas conocidas en el momento t contienen información sobre el O3 que se observará después. Para cada variable se calcula:

$$\text{Corr}(X(t), O_3(t+h)), \quad h = 1, \dots, 24$$

De esta forma, un horizonte de 6 horas indica qué tan relacionada está una medición meteorológica disponible ahora con el O3 observado seis horas después. Igual que en el análisis anterior, solo se utiliza 2021-2023 y se conserva una secuencia horaria completa por estación.

Se incluyen TEMP, RH, SR, WS, BP y RAINF. Para la dirección del viento se utilizan WD_sin y WD_cos, ya que los grados no deben tratarse como una variable lineal.

Para mantener el reporte compacto, la tabla muestra cuatro horizontes representativos y la figura conserva las 24 horas completas.

Table 29: Correlación de variables meteorológicas actuales con O3 futuro

Variable	h_1	h_6	h_12	h_24
TEMP	0.472	0.065	-0.107	0.462
RH	-0.470	0.041	0.242	-0.451
SR	0.624	0.229	-0.220	0.521
WS	0.293	-0.147	-0.123	0.302
BP	-0.118	-0.017	-0.063	-0.156
RAINF	0.002	-0.001	-0.006	-0.002
WD_sin	0.232	-0.148	-0.125	0.198
WD_cos	-0.115	0.126	0.072	-0.133




Figure 14: Relación de variables meteorológicas actuales con O3 a distintos horizontes

Las condiciones meteorológicas actuales aportan información principalmente en horizontes cortos. SR presenta la asociación más fuerte con el O3 de una hora después ($r = 0.624$), seguida de TEMP ($r = 0.472$) y RH ($r = -0.470$). WS también muestra una relación positiva, aunque menor ($r = 0.293$). A seis horas estas asociaciones se debilitan de manera importante y alrededor de 12 horas varias cambian de signo.

La forma de las curvas vuelve a reflejar el ciclo diario observado previamente. Cerca de 12 horas se comparan condiciones actuales con una fase aproximadamente opuesta del día, mientras que a 24 horas se recuperan correlaciones relativamente altas: SR alcanza 0.521, TEMP 0.462 y RH -0.451. Esta recuperación no debe interpretarse como que la meteorología actual determina por sí sola el O3 del día siguiente; parte de la asociación puede deberse a que ambas variables

comparten una periodicidad de 24 horas.

BP mantiene asociaciones débiles en todos los horizontes y RAINF permanece prácticamente en cero. Las componentes de dirección del viento y WS presentan señales menores pero no despreciables. En conjunto, SR, TEMP y RH quedan como las variables meteorológicas más prometedoras, con WS como candidata adicional. Su aporte real deberá comprobarse mediante validación junto con las variables temporales y los rezagos del propio O3.

5.1.2 Otros contaminantes y O3 futuro

Se repite el mismo análisis con los demás contaminantes. Para cada variable medida en el momento t se calcula su correlación con el O3 observado entre 1 y 24 horas después:

$$\text{Corr}(X(t), O_3(t+h)), \quad h = 1, \dots, 24$$

Se utilizan CO, NO, NO2, NOX, PM10, PM2.5 y SO2. El cálculo se mantiene restringido a 2021-2023 y conserva la secuencia horaria completa de cada estación.

La tabla resume los mismos cuatro horizontes representativos utilizados en meteorología.

Table 30: Correlación de contaminantes actuales con O3 futuro

Variable	h_1	h_6	h_12	h_24
CO	-0.070	0.067	-0.007	-0.054
NO	-0.272	0.071	-0.031	-0.230
NO2	-0.252	-0.016	-0.061	-0.204
NOX	-0.297	0.046	-0.048	-0.246
PM10	0.014	0.081	-0.044	-0.012
PM2.5	-0.013	0.043	0.013	-0.014
SO2	0.179	0.033	-0.070	0.132




Figure 15: Relación de contaminantes actuales con O3 a distintos horizontes

Los contaminantes actuales aportan una señal predictiva más débil que las principales variables meteorológicas y que los rezagos del propio O3. A una hora, las asociaciones de mayor magnitud son negativas y corresponden a NOX ($r = -0.297$), NO ($r = -0.272$) y NO2 ($r = -0.252$). SO2 presenta una asociación positiva débil ($r = 0.179$), mientras que CO, PM10 y PM2.5 se mantienen cerca de cero.

A seis y doce horas, prácticamente todas las correlaciones se acercan a cero. Hacia las 24 horas, NOX, NO y NO2 recuperan una asociación negativa moderada, con valores de -0.246, -0.230 y -0.204, respectivamente. Al igual que en el análisis meteorológico, esta recuperación puede reflejar en parte la periodicidad diaria compartida y no debe interpretarse como un efecto directo del contaminante actual sobre el O3 del día siguiente.

En términos de selección de variables, NO_x , NO y NO_2 son los únicos contaminantes que muestran una señal suficientemente consistente para justificar una evaluación posterior. Sin embargo, sus porcentajes elevados de valores faltantes y la redundancia entre ellos hacen poco conveniente incorporarlos automáticamente a los tres. Como punto de partida, se evaluará al menos uno de estos indicadores, probablemente NO_x , y se comprobará mediante validación si mejora el modelo lo suficiente para compensar la pérdida de observaciones. CO , PM_{10} y $\text{PM}_{2.5}$ quedan como candidatos de baja prioridad por su escasa asociación lineal con el O_3 futuro.

5.2 Separación cronológica

La disponibilidad de O_3 en 2020 es insuficiente para utilizar ese año en un modelo supervisado. Por ello, la separación temporal de referencia será:

- **2021-2023:** entrenamiento.
- **2024:** validación y selección de modelos.
- **2025:** prueba final sobre datos no utilizados durante la construcción del modelo.

El año 2020 se conserva en las bases de trabajo como parte del registro histórico, pero no formará parte del conjunto utilizado para ajustar o evaluar los modelos de O_3 .

5.3 Conjunto preliminar de predictores

Con los resultados anteriores ya es posible definir un primer conjunto de variables para construir los modelos. Esta selección es **preliminar**: su objetivo es reducir el número de variables a candidatas con una justificación clara y después comprobar su utilidad real durante la validación de 2024. Una correlación alta no garantiza que una variable mejore el modelo cuando se combina con las demás, y una variable con señal moderada puede dejar de aportar información si es redundante.

La regla central será utilizar únicamente información disponible en el momento de emitir el pronóstico. Si el origen del pronóstico es t , ninguna medición posterior a t podrá entrar como predictor.

Table 31: Selección preliminar de variables para el modelado

Grupo	Variables	Decision	Justificacion
Temporal	Hora_sin, Hora_cos, Mes_sin, Mes_cos	Incluir	O_3 presenta ciclos diario y anual marcados
Espacial	Estacion	Incluir	Existen diferencias sistematicas entre estaciones

Grupo	Variables	Decision	Justificacion
Historia de O3	O3(t), O3(t-1), O3(t-2), O3(t-3), O3(t-24)	Incluir y validar	Fuerte persistencia de corto plazo y señal diaria a 24 h
Meteorologia	SR, TEMP, RH, WS	Incluir	Son las asociaciones meteorologicas mas fuertes con O3 actual y futuro
Direccion del viento	WD_sin, WD_cos	Incluir y validar	La concentracion de O3 cambia segun la direccion del viento
Contaminantes	NOX	Comparar con y sin	Es el contaminante con mayor señal, pero tiene muchos faltantes
Baja prioridad	BP, RAINF, CO, PM10, PM2.5, SO2	No incluir inicialmente	Presentan asociaciones lineales debiles con O3 futuro
Redundantes con NOX	NO, NO2	No incluir inicialmente junto con NOX	Tienen señal similar y representan procesos relacionados

El conjunto principal queda formado por información temporal y espacial, el estado reciente del propio O3 y las variables meteorológicas con mayor señal. NOX se tratará de manera distinta: en lugar de hacerlo obligatorio en todos los modelos, se comparará una versión sin contaminantes con otra que lo incluya. De esta forma será posible medir si la mejora predictiva compensa la pérdida de observaciones asociada con sus valores faltantes.

Los rezagos del propio O3 tampoco se consideran definitivos. Aunque los valores recientes aportan mucha información, los rezagos consecutivos están fuertemente relacionados entre sí y pueden introducir multicolinealidad en una regresión lineal. La validación determinará si conviene conservar todos los candidatos o simplificar la historia reciente.

Para las variables cíclicas de hora y mes se hará una precisión al construir el conjunto de modelado: cuando se prediga $O_3(t+h)$, la hora y el mes del instante objetivo $t+h$ son conocidos de antemano y pueden representarse mediante seno y coseno sin utilizar información futura de mediciones. En cambio, las variables meteorológicas y de contaminación serán siempre las disponibles hasta el origen t .

5.4 Base formal de modelado

La base de modelado se construye con una fila por estación y hora de origen del pronóstico. Para garantizar que los rezagos representen diferencias horarias reales, se vuelve a utilizar una cuadrícula horaria completa entre 2021 y junio de 2025. Las horas que no aparezcan en los archivos originales se conservan en la cuadrícula con mediciones faltantes.

Para evitar multiplicar innecesariamente el tamaño del objeto en memoria, no se crea una tabla con 24 copias de cada registro. En su lugar se prepara una única base de origen con

los predictores disponibles en t y se utiliza una función para generar el objetivo $O_3(t + h)$ únicamente para el horizonte que se vaya a modelar.

Table 32: Estructura de la base de origen para el modelado

Registros	Estaciones	Desde	Hasta
157632	4	2021-01-01	2025-06-30 23:00:00

Los predictores principales se definen de forma explícita. La hora y el mes que se incorporarán al modelo corresponden al instante objetivo $t + h$, no al origen t , porque esas características del calendario son conocidas de antemano.

La separación entre entrenamiento, validación y prueba se asigna con el **año de la hora objetivo**. De esta manera, por ejemplo, una predicción emitida al final de 2023 cuyo objetivo cae en 2024 pertenece a validación y no se filtra accidentalmente dentro del entrenamiento.

Antes de decidir cómo tratar los faltantes se cuantifica cuánta información quedaría disponible si se exigieran casos completos. Se comparan dos versiones: el conjunto principal sin otros contaminantes y la misma estructura agregando NOX.

Para mantener el reporte legible se muestran los horizontes de 1, 6, 12 y 24 horas. El objeto anterior conserva los resultados para las 24 horas y podrá utilizarse posteriormente para revisar cualquier horizonte específico.

Table 33: Disponibilidad de casos completos en la base formal de modelado

Periodo	Hori- zonte_h	Objeto- tivos_disponibles	Casos_com- pletos_Princi- pal	Casos_com- ple- tos_Con_NOX	Cober- tura_pct_Prin- cipal	Cober- tura_pct_Con_NOX
Entre- namiento	1	96158	77897	74681	81.0	77.7
Entre- namiento	6	96158	76593	73419	79.7	76.4
Entre- namiento	12	96158	76117	72996	79.2	75.9
Entre- namiento	24	96158	76573	73443	79.6	76.4
Prueba	1	16027	7196	7005	44.9	43.7
Prueba	6	16027	7106	6927	44.3	43.2
Prueba	12	16027	7075	6901	44.1	43.1
Prueba	24	16027	7075	6889	44.1	43.0
Valida- cion	1	32966	17392	17125	52.8	51.9

Periodo	Hori- zonte_h	Objeto- tivos_disponibles	Casos_com- pletos_Princi- pal	Casos_com- pletos_Con_NOX	Cober- tura_pct_Prin- cipal	Cober- tura_pct_Con_NOX
Valida- cion	6	32966	17010	16757	51.6	50.8
Valida- cion	12	32966	16824	16589	51.0	50.3
Valida- cion	24	32966	16869	16640	51.2	50.5

En este punto todavía **no se imputan predictores ni se eliminan filas de forma definitiva**. La tabla permitirá medir primero cuánto se pierde por exigir información completa y, en particular, cuánto reduce la muestra la incorporación de NOX. Con esos resultados se decidirá si el conjunto principal puede trabajarse mediante casos completos o si conviene aplicar un tratamiento específico de faltantes antes del modelado.

6 Modelado

6.1 Modelo base

Pendiente de implementar un modelo de persistencia que sirva como referencia mínima de desempeño.

6.2 Modelo estadístico

Pendiente de construir y validar un modelo interpretable, inicialmente regresión lineal múltiple con variables temporales y rezagos.

6.3 Modelo no lineal

Pendiente de comparar el modelo estadístico con al menos un método capaz de capturar relaciones no lineales, como Random Forest o Gradient Boosting.

7 Evaluación

7.1 Métricas

Se utilizarán principalmente MAE y RMSE sobre periodos no utilizados durante el entrenamiento.

7.2 Error por horizonte

Pendiente de evaluar cómo cambia el error desde las predicciones más cercanas hasta el horizonte máximo de 24 horas.

7.3 Error por estación

Pendiente de determinar si el desempeño del modelo cambia entre los puntos de monitoreo seleccionados.

8 Conclusiones

Pendiente de redactar una vez completado el modelado y su evaluación.

9 Declaratoria y referencias

9.1 Link GitHub

<https://github.com/Reyivan777/Reto-Multivariados>

9.2 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: ChatGPT y otras herramientas de IA utilizadas por el equipo durante el desarrollo.

Uso realizado: Apoyo en la estructuración del reporte, revisión de redacción, discusión metodológica y apoyo con sintaxis de código.

Secciones donde se utilizó: Se documentarán de manera específica conforme avance la versión final del reporte.

Validación realizada por los estudiantes: El equipo revisa, verifica y edita los contenidos y resultados obtenidos, y asume la responsabilidad del contenido final entregado.

9.3 Referencias bibliográficas

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.