

Reporte del reto SIMA: predicción de ozono a corto plazo

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-08-31

Table of contents

1	Introducción y planteamiento	3
1.1	Contexto del proyecto	3
1.2	Problema de investigación	3
1.3	Pregunta de investigación	4
1.4	Objetivo general	4
1.5	Objetivos específicos	4
1.6	Justificación y antecedentes	4
1.7	Alcance del pronóstico	5
1.8	Variables consideradas	6
1.9	Estrategia general de análisis	6
1.10	Fuente de información	7
2	Datos	7
2.1	Archivos fuente	7
2.2	Carga inicial	8
2.3	Estructura y disponibilidad inicial	8
2.4	Homologación de la estructura	9
3	Preparación de los datos	10
3.1	Conversión de tipos	10

3.2	Valores faltantes y registros inválidos	11
3.2.1	Distribución de faltantes de O3	12
3.2.2	Continuidad de los faltantes de O3 desde 2021	14
3.2.3	Tratamiento de O3 faltante	15
3.3	Valores extremos	16
3.3.1	Construcción de la base limpia	19
3.4	Variables temporales y espaciales	19
4	Análisis exploratorio	20
4.1	Comportamiento del O3	20
4.2	Diferencias entre estaciones	21
4.2.1	Patrón horario	23
4.2.2	Patrón mensual	24
4.3	Relación con variables meteorológicas y contaminantes	26
5	Preparación para modelado	26
5.1	Construcción de rezagos	26
5.2	Separación cronológica	26
5.3	Conjunto final de predictores	26
6	Modelado	26
6.1	Modelo base	26
6.2	Modelo estadístico	27
6.3	Modelo no lineal	27
7	Evaluación	27
7.1	Métricas	27
7.2	Error por horizonte	27
7.3	Error por estación	27
8	Conclusiones	27
9	Declaratoria y referencias	27
9.1	Link GitHub	27
9.2	Declaratoria de uso IA	28
9.3	Referencias bibliográficas	28

1 Introducción y planteamiento

1.1 Contexto del proyecto

La contaminación atmosférica representa un problema relevante para la salud pública y para la gestión ambiental de las ciudades. En la Zona Metropolitana de Monterrey (ZMM), las concentraciones de contaminantes pueden variar considerablemente a lo largo del día debido a la interacción entre emisiones, condiciones meteorológicas y características propias de cada zona. Por esta razón, además de conocer el estado actual de la calidad del aire, resulta útil estudiar si los registros históricos permiten anticipar su comportamiento en el corto plazo.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) opera una red de estaciones que registra de forma horaria contaminantes atmosféricos y variables meteorológicas. Entre los contaminantes disponibles se encuentran monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 y 2.5 micrómetros (PM₁₀ y PM_{2.5}) y dióxido de azufre (SO₂). También se registran variables como temperatura, humedad relativa, radiación solar, presión atmosférica, precipitación, velocidad del viento y dirección del viento.

El reto planteado por SIMA permite analizar estas mediciones mediante técnicas estadísticas multivariadas y de modelado predictivo. En las primeras exploraciones del conjunto de datos se observó que intentar estudiar y predecir simultáneamente todos los contaminantes producía un objetivo demasiado amplio. Por ello, el proyecto se delimita a un problema concreto: **la predicción de la concentración horaria de ozono (O₃) en el corto plazo.**

1.2 Problema de investigación

El ozono troposférico es un contaminante cuyo comportamiento está relacionado con las condiciones atmosféricas y con otros contaminantes presentes en el ambiente. La temperatura, la radiación solar, la humedad y el viento, entre otras variables, pueden aportar información relevante para entender su variación. Además, al tratarse de mediciones horarias, la concentración observada en un momento también depende de la dinámica temporal reciente.

Los registros históricos de SIMA contienen ambas fuentes de información: las condiciones meteorológicas y de contaminación observadas en distintas estaciones, así como su evolución temporal. El problema central del proyecto consiste en determinar si esta información puede utilizarse para generar pronósticos útiles de O₃ con anticipación suficiente para apoyar el seguimiento de episodios de concentración elevada.

El análisis se enfocará inicialmente en las estaciones NTE, NTE2, NO y NE, utilizando los registros disponibles entre 2020 y 2025. Esta delimitación permite trabajar con un conjunto espacial manejable y mantener continuidad con el análisis exploratorio realizado previamente, sin intentar modelar simultáneamente toda la red de monitoreo.

1.3 Pregunta de investigación

¿Con qué precisión puede predecirse la concentración horaria de O₃ con un horizonte de hasta 24 horas en las estaciones NTE, NTE2, NO y NE, utilizando los registros históricos de contaminantes, variables meteorológicas y variables temporales proporcionados por SIMA entre 2020 y 2025?

Esta pregunta transforma el reto en un problema de predicción temporal claramente evaluable: existe una variable objetivo definida, un horizonte de pronóstico específico y un conjunto delimitado de datos con el cual entrenar y evaluar los modelos.

1.4 Objetivo general

Desarrollar y evaluar modelos capaces de **predecir la concentración horaria de ozono (O₃) con un horizonte de hasta 24 horas** en las estaciones NTE, NTE2, NO y NE de la Zona Metropolitana de Monterrey, utilizando información histórica de contaminantes, variables meteorológicas y características temporales registradas por SIMA durante el periodo 2020-2025.

1.5 Objetivos específicos

1. Preparar y validar la calidad de los registros históricos necesarios para modelar O₃, conservando la estructura temporal y espacial de las mediciones.
2. Caracterizar el comportamiento del O₃ e identificar qué variables meteorológicas, contaminantes y patrones temporales aportan información relevante para su predicción.
3. Construir variables derivadas que representen la dinámica temporal del problema, incluyendo características de fecha y hora y rezagos de mediciones disponibles antes del momento de predicción.
4. Construir y comparar al menos dos enfoques de modelado, incluyendo un modelo estadístico interpretable y un modelo capaz de representar relaciones no lineales.
5. Evaluar los modelos mediante una separación cronológica de los datos y métricas de error, analizando además cómo cambia el desempeño según el horizonte de predicción y la estación de monitoreo.

1.6 Justificación y antecedentes

La relevancia del problema parte de la relación entre contaminación atmosférica y salud pública. Cerón Bretón et al. (2020) documentaron asociaciones entre contaminación atmosférica, temperatura y mortalidad diaria en el norte de México. A nivel internacional, las Guías de Calidad del Aire de la Organización Mundial de la Salud resaltan la importancia de reducir la

exposición de la población a contaminantes criterio y de contar con información confiable para su seguimiento (Hoffmann et al., 2021).

Desde la perspectiva predictiva, Cifuentes et al. (2021) analizaron la predicción horaria de O₃ y PM_{2.5} mediante variables meteorológicas y distintos modelos, mostrando que información como temperatura y radiación solar puede resultar útil para anticipar concentraciones de contaminantes. Este antecedente proporciona una base metodológica para estudiar si los registros históricos de SIMA permiten construir modelos adaptados a las condiciones de la ZMM.

La elección de O₃ como variable objetivo también responde al análisis exploratorio realizado durante el proyecto. Frente a otros contaminantes, el ozono mostró asociaciones meteorológicas más claras y consistentes, por lo que ofrece un punto de partida razonable para construir un primer sistema predictivo. Estas relaciones se volverán a cuantificar y validar en la sección de análisis exploratorio de este reporte antes de utilizarse para seleccionar predictores.

El objetivo no es atribuir causalidad a las variables ni sustituir los procedimientos oficiales de pronóstico de SIMA. El propósito es evaluar, con los datos disponibles y dentro del alcance académico del reto, qué tan bien puede anticiparse el comportamiento del O₃ y qué información resulta más útil para hacerlo.

1.7 Alcance del pronóstico

El horizonte máximo de predicción se establece en **24 horas**. Esto no significa utilizar los datos de 2020-2025 para generar una predicción fija de un día posterior al final de la base. El modelo se plantea como un esquema de pronóstico móvil.

En un momento determinado t , únicamente se utilizará información disponible hasta ese instante para estimar las concentraciones futuras de O₃ durante las horas siguientes. De forma conceptual:

$$\text{información disponible hasta } t \longrightarrow \widehat{O}_3(t+1), \dots, \widehat{O}_3(t+24)$$

Cuando exista una nueva medición, esa información podrá incorporarse para generar nuevamente el pronóstico de las siguientes 24 horas. Esta estructura evita utilizar información futura durante la predicción y permite evaluar el desempeño del modelo de forma semejante a como se utilizaría posteriormente con nuevos datos.

El horizonte de 24 horas se utilizará como máximo de evaluación. Durante el modelado se analizará si el error aumenta conforme crece la distancia entre el momento de observación y la hora pronosticada.

1.8 Variables consideradas

La variable objetivo del proyecto es la concentración horaria de **O3**. Las posibles variables predictoras se organizan en cuatro grupos:

Grupo	Variables principales	Función dentro del modelo
Variable objetivo	O3	Concentración que se desea predecir
Meteorológicas	BP, RAINF, RH, SR, TEMP, WS, WD	Describir las condiciones atmosféricas asociadas con la formación, transporte y dispersión del O3
Contaminantes	CO, NO, NO2, NOX, PM10, PM2.5, SO2 y valores previos de O3	Incorporar información del estado reciente de la contaminación atmosférica
Temporales y espaciales	Fecha, hora, día, mes, estación de monitoreo	Representar patrones horarios, estacionales y diferencias entre estaciones

Además de estas variables originales, se evaluará la creación de **rezagos temporales**. Por ejemplo, para realizar una predicción en el momento t , pueden utilizarse valores observados previamente como $O_3(t)$, $O_3(t-1)$, $O_3(t-2)$ o mediciones meteorológicas recientes. La cantidad de rezagos y variables finales se determinará durante la preparación para el modelado para evitar incorporar información redundante o futura.

La dirección del viento requiere un tratamiento particular por ser una variable circular. Por ello, se evaluará su representación mediante componentes seno y coseno en lugar de utilizar directamente los grados como si fueran una variable lineal.

1.9 Estrategia general de análisis

El proyecto seguirá una secuencia orientada directamente al problema predictivo:

1. **Comprensión y limpieza de los datos.** Integrar las bases de 2020 a 2025, homologar nombres y unidades, identificar valores faltantes, registros inválidos y duplicados, y conservar únicamente información adecuada para el análisis.
2. **Análisis exploratorio enfocado en O3.** Estudiar su distribución, comportamiento horario y estacional, diferencias entre estaciones y relación con las variables candidatas a predictoras.
3. **Preparación temporal.** Ordenar los registros cronológicamente, construir variables temporales y rezagos, y definir las observaciones disponibles para cada horizonte de predicción.

4. **Modelado.** Construir primero una referencia simple y posteriormente comparar modelos estadísticos y modelos más flexibles. Entre los candidatos se consideran la regresión lineal múltiple y métodos no lineales como Random Forest o Gradient Boosting.
5. **Evaluación.** Medir el error sobre periodos posteriores a los utilizados para el entrenamiento y analizar los resultados por estación y horizonte de predicción.

Debido a la naturaleza temporal del problema, los datos **no se dividirán aleatoriamente**. La separación de modelado se definirá después de revisar la disponibilidad real de O₃ en cada año, conservando siempre el orden temporal para evitar fuga de información del futuro hacia el entrenamiento.

Como referencia mínima se incluirá un modelo base de persistencia, que supone que el comportamiento reciente del O₃ es una aproximación de su comportamiento próximo. Los modelos desarrollados deberán superar esta referencia para demostrar que las variables adicionales aportan capacidad predictiva.

La evaluación se realizará principalmente mediante **MAE (Mean Absolute Error)** y **RMSE (Root Mean Squared Error)**, complementadas con gráficas de valores observados contra predichos y análisis del error a través del tiempo. Estas métricas permitirán comparar modelos utilizando las mismas observaciones y determinar no solo cuál obtiene menor error promedio, sino también en qué condiciones falla.

1.10 Fuente de información

Los datos utilizados provienen del Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León. Las bases disponibles para el proyecto contienen registros horarios de las estaciones de monitoreo durante el periodo 2020-2025. Cada registro combina información temporal, identificación de la estación, concentraciones de contaminantes y variables meteorológicas.

El reporte conservará los datos originales sin modificar como fuente de referencia y generará conjuntos derivados para limpieza, análisis y modelado. Las decisiones de exclusión, transformación o imputación se documentarán en las siguientes secciones y deberán responder directamente a las necesidades del problema de predicción de O₃.

2 Datos

2.1 Archivos fuente

La información original se encuentra en seis archivos de Excel proporcionados para el reto, uno por cada año entre 2020 y 2025. Cada archivo contiene varias hojas y cada hoja corresponde a una estación de monitoreo de SIMA. El archivo de 2025 contiene únicamente el periodo

disponible hasta junio, por lo que ese año tiene aproximadamente la mitad de registros que los años completos.

2.2 Carga inicial

El proyecto utiliza únicamente las estaciones NTE, NTE2, NO y NE. Por ello, estas cuatro hojas se seleccionan desde el momento de lectura de cada archivo y las demás estaciones no se cargan en memoria.

Todas las columnas provenientes de Excel se leen inicialmente como texto. Esto mantiene una lectura consistente entre años y deja las conversiones de tipo para una etapa posterior.

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
here() starts at /home/runner/work/Reto-Multivariados/Reto-Multivariados
```

`datos_brutos` contiene desde este punto únicamente las cuatro estaciones que se utilizarán en el proyecto. `Año` aparece como entero porque se agrega directamente desde el código; las columnas provenientes de Excel permanecen como `character` por la opción `col_types = "text"`.

2.3 Estructura y disponibilidad inicial

Primero se revisa cuántos registros aporta cada estación en cada año.

Table 1: Cantidad de registros por año y estación seleccionada

Año	NTE	NTE2	NO	NE
2020	8777	8776	8778	8776
2021	8759	8759	8759	8759
2022	8760	8760	8760	8760
2023	8758	8758	8758	8758
2024	8782	8782	8783	8784

Año	NTE	NTE2	NO	NE
2025	4345	4344	4344	4344

Las cuatro estaciones tienen cobertura durante los seis años. Entre 2020 y 2024 cada estación aporta aproximadamente 8,760 registros por año, consistente con mediciones horarias durante prácticamente todo el año. En 2025 se observan alrededor de 4,344 registros por estación porque la base disponible termina en junio.

También se resume la estructura resultante antes de homologar los nombres de las variables.

Table 2: Estructura inicial del conjunto de trabajo

Registros	Columnas	Años	Estaciones
192723	34	6	4

El conjunto reúne 192,723 registros de las cuatro estaciones seleccionadas. Antes de homologar, el número de columnas es mayor al esperado porque algunos archivos utilizan nombres diferentes para una misma variable.

2.4 Homologación de la estructura

Al comparar los encabezados de los seis archivos se identificaron algunas variables que cambian de nombre según el año. Estas equivalencias ya habían aparecido en el código anterior del proyecto y se conservaron porque corresponden a diferencias reales observadas en los archivos originales.

Table 3: Equivalencias utilizadas para homologar la estructura

Variable_estandar	Nombres_en_archivos
fecha_hora	fecha y hora / date
BP	BP / PRS
TEMP	TEMP / TOUT
WS	WS / WSR
WD	WD / WDR

Además, algunos encabezados contienen unidades entre paréntesis o saltos de línea. La función siguiente normaliza esas diferencias de formato y después combina las columnas equivalentes bajo un único nombre.

El resultado conserva una sola columna por variable y mantiene todavía las mediciones como texto.

Table 4: Verificación de la estructura homologada

Registros	Columnas	Variables_faltantes
192723	18	Ninguna

Después de la homologación se conservan los mismos 192,723 registros en 18 columnas y no falta ninguna de las variables esperadas para el análisis.

3 Preparación de los datos

3.1 Conversión de tipos

La estructura ya está homologada, pero las mediciones todavía se encuentran almacenadas como texto. En este paso se convierte `fecha_hora` a un formato de fecha y hora y las 15 variables de medición a tipo numérico. `Año` se mantiene como entero y `Estacion` como identificador de texto.

La columna temporal aparece en dos formatos dentro de los archivos: algunos registros se almacenan como números seriales de Excel y otros como texto con fecha y hora. La función siguiente contempla ambos casos sin modificar el orden temporal de las observaciones.

La zona horaria se fija como UTC únicamente para conservar una representación uniforme de fecha y hora; no se realiza una conversión del horario registrado por SIMA.

Antes de continuar con la limpieza se verifica que la transformación haya producido los tipos esperados y se cuantifican las fechas no vacías que no pudieron interpretarse.

Table 5: Tipos de datos después de la transformación

Elemento	Resultado
Año	integer
Estacion	character
fecha_hora	POSIXct
Variables de medición	15/15 numéricas

Table 6: Verificación de la conversión de fecha y hora

Primera_fecha	Ultima_fecha	Fechas_no_convertidas
2020-01-01	2025-06-30 23:00:00	0

La conversión produjo las 15 variables de medición en formato numérico y **fecha_hora** en formato **POSIXct**. El periodo resultante va del 1 de enero de 2020 al 30 de junio de 2025 a las 23:00, sin fechas que hayan quedado sin convertir.

3.2 Valores faltantes y registros inválidos

Antes de reemplazar o eliminar valores se cuantifican los problemas presentes en cada variable. Esta revisión distingue tres situaciones: valores que ya están ausentes (**NA**), valores no vacíos que no pudieron convertirse a número y la bandera **-9999**, utilizada en los archivos para indicar mediciones no válidas en algunas variables.

Table 7: Diagnóstico inicial de valores faltantes y banderas por variable

Variable	Faltantes	No_numericos	Bandera_menos9999	Porcentaje_faltante
CO	34579	4	0	17.94
NO	39363	4	0	20.42
NO2	45604	4	0	23.66
NOX	45037	4	0	23.37
O3	46839	4	0	24.30
PM10	10619	0	0	5.51
PM2.5	37925	0	0	19.68
SO2	47202	4	0	24.49
BP	15629	4	0	8.11
RAINF	14392	4	0	7.47
RH	36101	4	2	18.73
SR	7099	0	1	3.68
TEMP	27486	4	1	14.26
WS	19749	4	0	10.25
WD	20742	4	0	10.76

Los faltantes representan un problema importante para varias variables. **SO2** presenta 24.49 % de ausencia, **NO2** 23.66 %, **NOX** 23.37 % y **NO** 20.42 %. Si estas variables se incorporan como predictoras sin un tratamiento específico, podrían reducir considerablemente la cantidad de observaciones disponibles para entrenar los modelos.

El caso más importante para el objetivo del proyecto es O3: faltan 46,839 de los 192,723 registros, equivalentes al 24.30 %. Esto deja 145,884 mediciones observadas de la variable que se desea predecir. Los momentos donde el valor objetivo no está disponible no podrán utilizarse directamente para entrenar o evaluar una predicción de esa hora, por lo que antes de construir los horizontes de pronóstico será necesario revisar cómo se distribuyen estas ausencias entre años y estaciones.

La disponibilidad es considerablemente mayor en variables como SR (3.68 % de faltantes), PM10 (5.51 %), RAINF (7.47 %) y BP (8.11 %). Las banderas -9999 son poco frecuentes: aparecen únicamente en RH (2 casos), SR (1) y TEMP (1), por lo que no explican los porcentajes elevados de ausencia. También aparecen cuatro valores no numéricos en varias variables, una cantidad mínima respecto al tamaño total de la base, aunque deberán identificarse antes de cerrar la limpieza.

También se verifica que no existan dos registros para la misma estación y la misma fecha-hora.

Table 8: Verificación de registros duplicados

Combinaciones_duplicadas	Registros_involucrados
0	0

No se encontraron registros duplicados para una misma combinación de estación y fecha-hora, por lo que no es necesario eliminar observaciones por este motivo.

Antes de imputar o eliminar valores faltantes conviene revisar su distribución por año y estación. Un porcentaje global de 24.30 % en O3, por ejemplo, puede corresponder a ausencias relativamente uniformes o estar concentrado en periodos y estaciones específicos; ambas situaciones requieren decisiones de modelado distintas.

3.2.1 Distribución de faltantes de O3

Como O3 es la variable objetivo, primero se revisa su disponibilidad por estación y año. En esta variable no se encontraron banderas -9999, por lo que sus ausencias corresponden directamente a valores NA después de la conversión.

Table 9: Porcentaje de O3 faltante por año y estación

Año	NE	NO	NTE	NTE2
2020	99.90	98.44	99.99	93.33
2021	16.03	20.34	18.52	9.49
2022	3.80	6.18	4.28	2.45
2023	4.96	5.99	7.25	2.89

Año	NE	NO	NTE	NTE2
2024	3.73	11.02	4.02	5.86
2025	19.31	5.89	4.03	1.84

Además del comportamiento anual, se resume la cobertura total de O3 de cada estación durante todo el periodo.

Table 10: Disponibilidad total de O3 por estación

Estacion	Registros	O3_disponibles	O3_faltantes	Porcentaje_faltante
NE	48181	36076	12105	25.12
NO	48182	35469	12713	26.39
NTE	48181	36245	11936	24.77
NTE2	48179	38094	10085	20.93

Los resultados muestran que el problema de disponibilidad de O3 está concentrado principalmente en el **año 2020**, no en una estación específica. Durante 2020 faltan 99.90 % de las mediciones de NE, 98.44 % de NO, 99.99 % de NTE y 93.33 % de NTE2. Con esta cobertura, 2020 aporta muy pocas observaciones de la variable objetivo y no resulta útil para entrenar ni evaluar un modelo supervisado de O3.

A partir de 2021 la situación mejora de forma considerable. Ese año todavía presenta porcentajes relevantes de ausencia, especialmente en NO (20.34 %), NTE (18.52 %) y NE (16.03 %), mientras que NTE2 presenta 9.49 %. Entre 2022 y 2024 la disponibilidad es mucho más estable, con porcentajes generalmente inferiores a 11 %. En 2025 destaca NE, con 19.31 % de faltantes, mientras que las otras tres estaciones mantienen una cobertura mayor.

Los porcentajes acumulados por estación son similares: varían entre 20.93 % en NTE2 y 26.39 % en NO. Esta similitud se debe en gran medida a que las cuatro estaciones comparten la falta casi total de O3 en 2020. Por ello, **no hay evidencia en esta revisión para eliminar alguna de las cuatro estaciones por falta de cobertura.**

Para cuantificar la disponibilidad del periodo que sí puede utilizarse para el modelado, se calcula nuevamente el porcentaje de faltantes por estación excluyendo 2020.

Table 11: Disponibilidad de O3 por estación desde 2021

Estacion	Registros	O3_disponibles	O3_faltantes	Porcentaje_faltante
NE	39405	36067	3338	8.47
NO	39404	35332	4072	10.33
NTE	39404	36244	3160	8.02

Estacion	Registros	O3_disponibles	O3_faltantes	Porcentaje_faltante
NTE2	39403	37509	1894	4.81

Al excluir 2020, la proporción de O3 faltante disminuye de forma importante: NTE2 queda en 4.81 %, NTE en 8.02 %, NE en 8.47 % y NO en 10.33 %. Esto confirma que la mayor parte del 24.30 % global estaba concentrada en 2020 y que las cuatro estaciones conservan una cantidad considerable de O3 observado durante el periodo útil para modelado.

Con base en estos resultados, **2020 se conservará en los objetos de datos como parte de la fuente original, pero se excluirá del periodo destinado al modelado de O3.** La separación temporal de referencia pasa a ser 2021-2023 para entrenamiento, 2024 para validación y 2025 para prueba final. Antes de cerrar el tratamiento de los faltantes todavía falta revisar si las ausencias de O3 desde 2021 aparecen aisladas o forman bloques consecutivos largos.

3.2.2 Continuidad de los faltantes de O3 desde 2021

Para un modelo con rezagos y horizonte de 24 horas no basta con conocer el porcentaje de O3 faltante. También importa saber si las ausencias aparecen como horas aisladas o como interrupciones prolongadas. Por ello se reconstruye una secuencia horaria completa para cada estación desde 2021; si alguna hora completa no aparece en la base, también se considera como una hora sin O3.

Table 12: Continuidad de los faltantes de O3 desde 2021

Esta- cion	Nu- mero_blo- ques	Bloque_mas_largo_h	Mediana_du- racion_h	Bloques_may- ores_24h	Horas_en_blo- ques_largos
NE	453	1284	1	4	2059
NO	616	1536	2	13	2189
NTE	636	1296	1	5	1600
NTE2	433	445	1	9	822

La mayoría de las interrupciones son cortas: la mediana es de 1 hora en NE, NTE y NTE2, y de 2 horas en NO. Sin embargo, existen algunos periodos prolongados sin mediciones. NO presenta 13 bloques de al menos 24 horas y el bloque más largo alcanza 1,536 horas; NTE alcanza 1,296 horas y NE 1,284 horas. En NTE2 el bloque máximo es menor, con 445 horas.

También se muestran los diez bloques faltantes más largos para identificar en qué estaciones y periodos ocurrieron las interrupciones principales.

Table 13: Diez bloques consecutivos de O3 faltante más largos desde 2021

Estacion	Año	Inicio	Fin	Horas
NO	2021	2021-01-01 00:00:00	2021-03-05 23:00:00	1536
NTE	2021	2021-01-01 00:00:00	2021-02-23 23:00:00	1296
NE	2021	2021-01-01 00:00:00	2021-02-23 11:00:00	1284
NE	2025	2025-06-01 00:00:00	2025-06-30 23:00:00	720
NTE2	2021	2021-01-01 00:00:00	2021-01-19 12:00:00	445
NTE	2023	2023-08-09 14:00:00	2023-08-18 15:00:00	218
NO	2024	2024-04-26 17:00:00	2024-05-03 11:00:00	163
NTE2	2024	2024-09-29 10:00:00	2024-10-04 11:00:00	122
NO	2025	2025-03-29 18:00:00	2025-04-02 14:00:00	93
NO	2024	2024-06-20 22:00:00	2024-06-24 14:00:00	89

Los tres bloques más largos ocurren al inicio de 2021: NO no registra O3 durante 1,536 horas, NTE durante 1,296 y NE durante 1,284. Esto explica una parte importante de los porcentajes elevados de faltantes observados en 2021. Después de ese periodo todavía aparecen interrupciones largas, pero son menos extensas; por ejemplo, se observan bloques de 218 horas en NTE durante 2023 y de 163 horas en NO durante 2024.

3.2.3 Tratamiento de O3 faltante

Como O3 es la variable que el modelo debe aprender a predecir, **sus valores faltantes no se imputarán para crear artificialmente la variable objetivo**. Una hora cuyo O3 real no fue observado no puede utilizarse como respuesta durante el entrenamiento ni para calcular el error durante la evaluación.

Esta decisión también evita interpolar los bloques largos identificados anteriormente, ya que completar semanas de mediciones ausentes produciría valores sintéticos que podrían distorsionar la dinámica real del contaminante. Las ausencias cortas se conservarán igualmente como NA mientras O3 actúe como variable objetivo.

Cuando se construyan los horizontes de pronóstico, cada observación se utilizará únicamente si existe el O3 real correspondiente a la hora que se pretende predecir. Por ejemplo, para evaluar una predicción a 24 horas realizada en el momento t , será necesario disponer de $O_3(t + 24)$.

El O3 histórico también podrá utilizarse como predictor mediante rezagos. En ese caso, si un rezago requerido cae dentro de una hora faltante, esa entrada permanecerá ausente; no se rellenarán automáticamente bloques largos. Más adelante se cuantificará cuántas observaciones quedan disponibles con los rezagos seleccionados antes de decidir si conviene tratar algunos faltantes de las variables predictoras.

A partir de este punto se define una base preliminar para el modelado con los años 2021-2025. Las pocas banderas -9999 detectadas en otras variables se convierten a NA, pero todavía no se eliminan registros ni se imputan mediciones.

Table 14: Base preliminar para el modelado de O3

Registros	Desde	Hasta	Estaciones
157616	2021-01-01	2025-06-30 23:00:00	4

`datos_base_modelado` conserva la estructura original del periodo útil y mantiene explícitamente los faltantes. Todavía no se considera un conjunto limpio definitivo: faltan revisar los valores físicamente inválidos o extremos y definir el tratamiento de las variables predictoras antes de construir los rezagos.

3.3 Valores extremos

El análisis anterior cierra por ahora la revisión específica de **disponibilidad y continuidad de O3**. El comportamiento del contaminante todavía se estudiará más adelante en el análisis exploratorio, pero ya quedó definido qué periodo se utilizará y cómo se tratarán sus valores faltantes cuando funcione como variable objetivo.

Antes de considerar la base como limpia se revisan los valores extremos de todas las variables. Para ello se retoman los límites de validación por año utilizados previamente en el proyecto. Estos límites se emplean únicamente para detectar mediciones fuera del rango aceptado; un valor estadísticamente extremo que permanezca dentro de ellos no se eliminará automáticamente, ya que puede representar un episodio real.

Table 15: Diagnóstico de valores extremos en la base de modelado

Variable	Min_obser- vado	P01	Mediana	P99	Max_obser- vado	Fuera_de_rango
BP	680.10	704.40	714.70	727.30	735.7	73
CO	0.00	0.19	1.17	3.79	15.3	2
NO	0.50	0.90	5.20	119.30	945.1	13
NO2	0.00	2.70	13.10	57.00	165.1	0
NOX	0.50	4.30	19.30	162.60	971.8	16
O3	-9.00	2.00	23.00	87.00	173.0	1
PM10	1.00	8.63	51.00	209.00	1001.0	3
PM2.5	0.00	3.00	17.00	67.00	999.0	0
RAINF	0.00	0.00	0.00	0.01	45.0	0
RH	0.00	5.00	57.00	95.00	714.2	260

Variable	Min_obser- vado	P01	Mediana	P99	Max_obser- vado	Fuera_de_rango
SO2	0.50	1.50	3.90	16.10	163.6	0
SR	-0.01	0.00	0.00	0.78	2.0	656
TEMP	-8.75	4.69	24.30	37.94	785.0	22
WD	1.00	5.00	104.00	355.00	360.0	0
WS	0.10	1.00	7.60	21.50	58.5	16

Para saber en qué años se concentran las posibles mediciones inválidas se muestran únicamente las combinaciones año-variable que contienen al menos un valor fuera del rango correspondiente.

Table 16: Valores fuera de rango por año y variable

Año	Variable	Fuera_de_rango
2022	SR	617
2022	RH	151
2023	RH	82
2022	BP	29
2023	BP	25
2024	RH	24
2021	SR	21
2024	TEMP	20
2024	BP	19
2021	WS	16
2022	NOX	11
2024	SR	10
2022	NO	8
2021	NO	5
2021	NOX	5
2023	SR	4
2025	SR	4
2021	RH	3
2023	PM10	2
2021	CO	1
2022	PM10	1
2022	TEMP	1
2023	CO	1
2023	TEMP	1
2024	O3	1

SR y RH concentran la mayor cantidad de observaciones fuera de los límites utilizados. SR presenta 656 casos, equivalentes aproximadamente al 0.42 % de la base de modelado, y 617 de ellos corresponden a 2022. RH presenta 260 casos, cerca del 0.16 % de la base, concentrados principalmente en 2022, 2023 y 2024. Aunque estas proporciones son pequeñas respecto al total de registros, conviene identificar si proceden de una estación específica antes de aplicar la limpieza.

Para ello se revisan únicamente los valores fuera de rango de SR y RH por año y estación, incluyendo el mínimo y máximo observados entre los casos inválidos.

Table 17: Valores fuera de rango de SR y RH por año y estación

Año	Estacion	Variable	Casos	Min_fuera	Max_fuera
2021	NO	RH	3	101.00	101.00
2022	NO	RH	151	101.00	714.20
2023	NO	RH	82	101.00	101.00
2024	NO	RH	20	101.00	102.00
2024	NTE	RH	4	103.00	151.00
2021	NO	SR	10	0.00	1.96
2021	NE	SR	8	-0.01	-0.01
2021	NTE	SR	3	0.00	0.00
2022	NTE	SR	604	-0.01	1.94
2022	NE	SR	13	-0.01	0.00
2023	NE	SR	4	0.00	0.00
2024	NE	SR	9	0.00	0.00
2024	NTE	SR	1	1.26	1.26
2025	NE	SR	1	2.00	2.00
2025	NO	SR	1	2.00	2.00
2025	NTE	SR	1	2.00	2.00
2025	NTE2	SR	1	2.00	2.00

Los valores fuera de rango de RH están casi totalmente concentrados en la estación NO: 256 de los 260 casos provienen de esa estación. En 2022 aparecen 151 registros fuera del intervalo 0-100 %, incluyendo un máximo de 714.2 %, por lo que se consideran mediciones inválidas. Los cuatro casos restantes corresponden a NTE en 2024.

En SR también se observa un problema localizado. De los 656 casos fuera de rango, 604 corresponden a NTE durante 2022. El resto se distribuye en cantidades pequeñas entre otras estaciones y años. Algunos valores cercanos a cero aparecen redondeados como 0.00 en la tabla aunque son ligeramente negativos y, por lo tanto, quedan fuera del límite inferior correspondiente.

Dado que estos casos representan una proporción pequeña de la base y que varios corresponden a valores físicamente imposibles o incompatibles con los límites de validación establecidos, se conservarán las filas completas y únicamente se sustituirá por NA la medición inválida.

3.3.1 Construcción de la base limpia

Se aplican los límites específicos de cada año a todas las variables de medición. Cuando una observación cae fuera de su intervalo permitido, solo esa celda se convierte a NA; no se elimina el registro horario completo.

Después de la transformación se vuelve a comprobar que no permanezcan valores fuera de los límites utilizados.

Table 18: Verificación de la base limpia

Registros	Valores_convertidos_a_NA	Fuera_de_rango_restantes
157616	1062	0

`datos_limpios` mantiene los 157,616 registros del periodo 2021-2025. Se convirtieron 1,062 mediciones fuera de rango a NA y la verificación posterior confirmó que no quedan valores fuera de los límites establecidos. La limpieza no elimina horas completas; los valores extremos que permanecen dentro de los límites se conservan porque pueden corresponder a episodios reales y resultar relevantes para el modelado.

3.4 Variables temporales y espaciales

La concentración de O₃ presenta una dinámica horaria y estacional, por lo que la fecha y hora original se descompone en variables que permitan estudiar esos patrones sin perder el orden temporal. También se prepara la estación de monitoreo como una variable categórica para representar diferencias entre ubicaciones.

Se conservan `fecha_hora` y `Año` como referencias temporales. A partir de `fecha_hora` se crean `Fecha`, `Hora`, `Dia_semana` y `Mes`. Las variables `Hora` y `Mes` también se representan mediante componentes seno y coseno porque son cíclicas: las 23:00 y las 00:00 son horas cercanas, igual que diciembre y enero, aunque sus valores numéricos simples se encuentren en extremos opuestos de la escala.

`Fecha`, `Hora`, `Dia_semana` y `Mes` se conservarán porque son fáciles de interpretar y serán útiles durante el análisis exploratorio. Las parejas `Hora_sin-Hora_cos` y `Mes_sin-Mes_cos` quedan disponibles para modelos que necesiten representar de manera continua los ciclos diario y anual.

Table 19: Variables temporales y espaciales preparadas

Variable	Resultado
Fecha	2021-01-01 a 2025-06-30
Hora	0-23
Dia_semana	Lunes, Martes, Miercoles, Jueves, Viernes, Sabado, Domingo
Mes	1-12
Estacion	NTE, NTE2, NO, NE
Hora_sin / Hora_cos	Representacion ciclica de 24 horas
Mes_sin / Mes_cos	Representacion ciclica de 12 meses

La variable **Fecha** servirá principalmente para ordenar y visualizar la serie temporal, mientras que **Año** se utilizará para mantener la separación cronológica entre entrenamiento, validación y prueba. La estación de monitoreo se conserva como factor con cuatro niveles (NTE, NTE2, NO y NE). Todavía no se decide cuáles de estas variables entrarán en cada modelo; esa selección se realizará después del análisis exploratorio y junto con la construcción de rezagos.

4 Análisis exploratorio

4.1 Comportamiento del O3

El análisis exploratorio comienza con la variable objetivo. En este primer bloque se revisa su distribución general, se compara entre las cuatro estaciones y se estudia su patrón promedio a lo largo de las 24 horas del día. Solo se utilizan mediciones válidas de O3; los valores faltantes permanecen fuera de los cálculos descriptivos.

Table 20: Resumen descriptivo de O3 entre 2021 y 2025

Observaciones	Media	Mediana	Desv_estandar	P25	P75	Minimo	Maximo
145151	27.12	23	18.97	13	37	1	173




Figure 1: Distribución de las concentraciones horarias de O3

Entre 2021 y junio de 2025 se conservan 145,151 mediciones válidas de O3. La media es 27.12 y la mediana 23, mientras que el 50 % central de las observaciones se encuentra entre 13 y 37. El histograma muestra una distribución asimétrica hacia la derecha: la mayoría de las concentraciones se agrupa en valores relativamente bajos y existe una cola prolongada hacia valores altos, con un máximo observado de 173. Por ello, la distribución marginal de O3 no presenta una forma aproximadamente normal. Esto no impide utilizar posteriormente modelos de regresión lineal; en ese caso los supuestos se revisarán sobre los residuos del modelo y no sobre la normalidad de O3 por sí sola.

4.2 Diferencias entre estaciones

Se comparan las mediciones de O3 de NTE, NTE2, N0 y NE mediante estadísticos descriptivos y su distribución por estación.

Table 21: Resumen de O3 por estación

Estacion	Observaciones	Media	Mediana	P25	P75
NTE	36244	26.53	23	12	37
NTE2	37508	24.58	20	12	34
NO	35332	29.79	26	14	42
NE	36067	27.73	25	15	37




Figure 2: Distribución de O3 por estación

Las cuatro estaciones presentan distribuciones con una forma general similar, aunque existen diferencias en el nivel de concentración. NO registra los valores centrales más altos, con media de 29.79 y mediana de 26, mientras que NTE2 presenta los más bajos, con media de 24.58 y mediana de 20. NTE y NE se ubican entre ambos casos. Estas diferencias justifican conservar la estación como información potencialmente útil para el modelo, aunque el comportamiento general de O3 es comparable entre los cuatro puntos de monitoreo.

4.2.1 Patrón horario

Finalmente se calcula la media y la mediana de O₃ para cada hora del día. Esta revisión permite identificar si existe una estructura diaria suficientemente marcada como para justificar el uso de variables horarias en el modelo.

Table 22: Concentración de O₃ por hora del día

Hora	Media	Mediana
0	19.01	18
1	18.62	18
2	18.01	17
3	17.25	16
4	16.43	15
5	15.03	13
6	12.80	11
7	11.27	9
8	12.21	11
9	15.95	15
10	22.23	21
11	30.68	30
12	39.66	39
13	46.46	45
14	49.86	48
15	50.17	48
16	48.43	46
17	44.65	43
18	38.61	37
19	31.11	30
20	24.78	24
21	21.44	21
22	20.01	19
23	19.39	19




Figure 3: Patrón horario de O3

El patrón horario es marcado. Las concentraciones disminuyen durante la madrugada y alcanzan su nivel más bajo alrededor de las 7:00. A partir de la mañana aumentan rápidamente y alcanzan sus valores medios más altos aproximadamente entre las 14:00 y 16:00, cercanos a 50, para después disminuir durante la tarde y la noche. La similitud entre la media y la mediana a lo largo del día indica que este patrón no depende únicamente de unas pocas observaciones extremas. La hora del día, por tanto, contiene una señal clara que conviene incorporar al modelado mediante `Hora_sin` y `Hora_cos`.

4.2.2 Patrón mensual

Después del ciclo diario se revisa si el O3 también presenta cambios sistemáticos a lo largo del año. Se calcula la media y la mediana para cada mes utilizando todas las mediciones válidas disponibles. Debido a que la base de 2025 termina en junio, los meses de enero a junio incluyen datos de cinco años, mientras que julio a diciembre contienen únicamente información de 2021 a 2024.

Table 23: Concentración de O3 por mes

Mes	Observaciones	Media	Mediana
1	11339	20.96	18
2	10987	24.80	20
3	14310	31.20	28
4	13928	31.44	28
5	14409	33.06	28
6	13058	30.13	25
7	11713	26.45	22
8	11474	27.26	23
9	11048	29.07	25
10	11343	26.13	22
11	10734	21.33	17
12	10808	18.78	14




Figure 4: Patrón mensual de O3

La interpretación del patrón mensual se realizará después de ejecutar estas tablas y figuras, antes

de continuar con la relación de O₃ con las variables meteorológicas y otros contaminantes.

4.3 Relación con variables meteorológicas y contaminantes

Pendiente de reconstruir el análisis de asociación concentrándolo únicamente en las variables relevantes para la predicción de O₃.

5 Preparación para modelado

5.1 Construcción de rezagos

Pendiente de definir qué información histórica estará disponible para cada pronóstico.

5.2 Separación cronológica

La disponibilidad de O₃ en 2020 es insuficiente para utilizar ese año en un modelo supervisado. Por ello, la separación temporal de referencia será:

- **2021-2023:** entrenamiento.
- **2024:** validación y selección de modelos.
- **2025:** prueba final sobre datos no utilizados durante la construcción del modelo.

El año 2020 se conserva en las bases de trabajo como parte del registro histórico, pero no formará parte del conjunto utilizado para ajustar o evaluar los modelos de O₃.

5.3 Conjunto final de predictores

Pendiente de seleccionar variables según disponibilidad, fundamento físico, análisis exploratorio y desempeño durante la validación.

6 Modelado

6.1 Modelo base

Pendiente de implementar un modelo de persistencia que sirva como referencia mínima de desempeño.

6.2 Modelo estadístico

Pendiente de construir y validar un modelo interpretable, inicialmente regresión lineal múltiple con variables temporales y rezagos.

6.3 Modelo no lineal

Pendiente de comparar el modelo estadístico con al menos un método capaz de capturar relaciones no lineales, como Random Forest o Gradient Boosting.

7 Evaluación

7.1 Métricas

Se utilizarán principalmente MAE y RMSE sobre periodos no utilizados durante el entrenamiento.

7.2 Error por horizonte

Pendiente de evaluar cómo cambia el error desde las predicciones más cercanas hasta el horizonte máximo de 24 horas.

7.3 Error por estación

Pendiente de determinar si el desempeño del modelo cambia entre los puntos de monitoreo seleccionados.

8 Conclusiones

Pendiente de redactar una vez completado el modelado y su evaluación.

9 Declaratoria y referencias

9.1 Link GitHub

<https://github.com/Reyivan777/Reto-Multivariados>

9.2 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: ChatGPT y otras herramientas de IA utilizadas por el equipo durante el desarrollo.

Uso realizado: Apoyo en la estructuración del reporte, revisión de redacción, discusión metodológica y apoyo con sintaxis de código.

Secciones donde se utilizó: Se documentarán de manera específica conforme avance la versión final del reporte.

Validación realizada por los estudiantes: El equipo revisa, verifica y edita los contenidos y resultados obtenidos, y asume la responsabilidad del contenido final entregado.

9.3 Referencias bibliográficas

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.