

Reporte del reto SIMA: predicción de ozono a corto plazo

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-08-29

Table of contents

1	Introducción y planteamiento	2
1.1	Contexto del proyecto	2
1.2	Problema de investigación	3
1.3	Pregunta de investigación	3
1.4	Objetivo general	4
1.5	Objetivos específicos	4
1.6	Justificación y antecedentes	4
1.7	Alcance del pronóstico	5
1.8	Variables consideradas	5
1.9	Estrategia general de análisis	6
1.10	Fuente de información	7
2	Datos	7
2.1	Archivos fuente	7
2.2	Carga inicial	8
2.3	Estructura y disponibilidad inicial	8
2.4	Homologación de la estructura	9
3	Preparación de los datos	10
3.1	Conversión de tipos	10
3.2	Valores faltantes y registros inválidos	11

3.3	Valores extremos	12
3.4	Variables temporales y espaciales	12
4	Análisis exploratorio	12
4.1	Comportamiento del O ₃	12
4.2	Diferencias entre estaciones	12
4.3	Relación con variables meteorológicas y contaminantes	12
5	Preparación para modelado	12
5.1	Construcción de rezagos	12
5.2	Separación cronológica	13
5.3	Conjunto final de predictores	13
6	Modelado	13
6.1	Modelo base	13
6.2	Modelo estadístico	13
6.3	Modelo no lineal	13
7	Evaluación	13
7.1	Métricas	13
7.2	Error por horizonte	14
7.3	Error por estación	14
8	Conclusiones	14
9	Declaratoria y referencias	14
9.1	Link GitHub	14
9.2	Declaratoria de uso IA	14
9.3	Referencias bibliográficas	15

1 Introducción y planteamiento

1.1 Contexto del proyecto

La contaminación atmosférica representa un problema relevante para la salud pública y para la gestión ambiental de las ciudades. En la Zona Metropolitana de Monterrey (ZMM), las concentraciones de contaminantes pueden variar considerablemente a lo largo del día debido a la interacción entre emisiones, condiciones meteorológicas y características propias de cada zona. Por esta razón, además de conocer el estado actual de la calidad del aire, resulta útil estudiar si los registros históricos permiten anticipar su comportamiento en el corto plazo.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) opera una red de estaciones que registra de forma horaria contaminantes atmosféricos y variables meteorológicas.

Entre los contaminantes disponibles se encuentran monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 y 2.5 micrómetros (PM₁₀ y PM_{2.5}) y dióxido de azufre (SO₂). También se registran variables como temperatura, humedad relativa, radiación solar, presión atmosférica, precipitación, velocidad del viento y dirección del viento.

El reto planteado por SIMA permite analizar estas mediciones mediante técnicas estadísticas multivariadas y de modelado predictivo. En las primeras exploraciones del conjunto de datos se observó que intentar estudiar y predecir simultáneamente todos los contaminantes producía un objetivo demasiado amplio. Por ello, el proyecto se delimita a un problema concreto: **la predicción de la concentración horaria de ozono (O₃) en el corto plazo.**

1.2 Problema de investigación

El ozono troposférico es un contaminante cuyo comportamiento está relacionado con las condiciones atmosféricas y con otros contaminantes presentes en el ambiente. La temperatura, la radiación solar, la humedad y el viento, entre otras variables, pueden aportar información relevante para entender su variación. Además, al tratarse de mediciones horarias, la concentración observada en un momento también depende de la dinámica temporal reciente.

Los registros históricos de SIMA contienen ambas fuentes de información: las condiciones meteorológicas y de contaminación observadas en distintas estaciones, así como su evolución temporal. El problema central del proyecto consiste en determinar si esta información puede utilizarse para generar pronósticos útiles de O₃ con anticipación suficiente para apoyar el seguimiento de episodios de concentración elevada.

El análisis se enfocará inicialmente en las estaciones NTE, NTE2, NO y NE, utilizando los registros disponibles entre 2020 y 2025. Esta delimitación permite trabajar con un conjunto espacial manejable y mantener continuidad con el análisis exploratorio realizado previamente, sin intentar modelar simultáneamente toda la red de monitoreo.

1.3 Pregunta de investigación

¿Con qué precisión puede predecirse la concentración horaria de O₃ con un horizonte de hasta 24 horas en las estaciones NTE, NTE2, NO y NE, utilizando los registros históricos de contaminantes, variables meteorológicas y variables temporales proporcionados por SIMA entre 2020 y 2025?

Esta pregunta transforma el reto en un problema de predicción temporal claramente evaluable: existe una variable objetivo definida, un horizonte de pronóstico específico y un conjunto delimitado de datos con el cual entrenar y evaluar los modelos.

1.4 Objetivo general

Desarrollar y evaluar modelos capaces de **predecir la concentración horaria de ozono (O₃) con un horizonte de hasta 24 horas** en las estaciones NTE, NTE2, NO y NE de la Zona Metropolitana de Monterrey, utilizando información histórica de contaminantes, variables meteorológicas y características temporales registradas por SIMA durante el periodo 2020-2025.

1.5 Objetivos específicos

1. Preparar y validar la calidad de los registros históricos necesarios para modelar O₃, conservando la estructura temporal y espacial de las mediciones.
2. Caracterizar el comportamiento del O₃ e identificar qué variables meteorológicas, contaminantes y patrones temporales aportan información relevante para su predicción.
3. Construir variables derivadas que representen la dinámica temporal del problema, incluyendo características de fecha y hora y rezagos de mediciones disponibles antes del momento de predicción.
4. Construir y comparar al menos dos enfoques de modelado, incluyendo un modelo estadístico interpretable y un modelo capaz de representar relaciones no lineales.
5. Evaluar los modelos mediante una separación cronológica de los datos y métricas de error, analizando además cómo cambia el desempeño según el horizonte de predicción y la estación de monitoreo.

1.6 Justificación y antecedentes

La relevancia del problema parte de la relación entre contaminación atmosférica y salud pública. Cerón Bretón et al. (2020) documentaron asociaciones entre contaminación atmosférica, temperatura y mortalidad diaria en el norte de México. A nivel internacional, las Guías de Calidad del Aire de la Organización Mundial de la Salud resaltan la importancia de reducir la exposición de la población a contaminantes criterio y de contar con información confiable para su seguimiento (Hoffmann et al., 2021).

Desde la perspectiva predictiva, Cifuentes et al. (2021) analizaron la predicción horaria de O₃ y PM_{2.5} mediante variables meteorológicas y distintos modelos, mostrando que información como temperatura y radiación solar puede resultar útil para anticipar concentraciones de contaminantes. Este antecedente proporciona una base metodológica para estudiar si los registros históricos de SIMA permiten construir modelos adaptados a las condiciones de la ZMM.

La elección de O₃ como variable objetivo también responde al análisis exploratorio realizado durante el proyecto. Frente a otros contaminantes, el ozono mostró asociaciones meteorológicas más claras y consistentes, por lo que ofrece un punto de partida razonable para construir un

primer sistema predictivo. Estas relaciones se volverán a cuantificar y validar en la sección de análisis exploratorio de este reporte antes de utilizarse para seleccionar predictores.

El objetivo no es atribuir causalidad a las variables ni sustituir los procedimientos oficiales de pronóstico de SIMA. El propósito es evaluar, con los datos disponibles y dentro del alcance académico del reto, qué tan bien puede anticiparse el comportamiento del O3 y qué información resulta más útil para hacerlo.

1.7 Alcance del pronóstico

El horizonte máximo de predicción se establece en **24 horas**. Esto no significa utilizar los datos de 2020-2025 para generar una predicción fija de un día posterior al final de la base. El modelo se plantea como un esquema de pronóstico móvil.

En un momento determinado t , únicamente se utilizará información disponible hasta ese instante para estimar las concentraciones futuras de O3 durante las horas siguientes. De forma conceptual:

$$\text{información disponible hasta } t \longrightarrow \widehat{O}_3(t+1), \dots, \widehat{O}_3(t+24)$$

Cuando exista una nueva medición, esa información podrá incorporarse para generar nuevamente el pronóstico de las siguientes 24 horas. Esta estructura evita utilizar información futura durante la predicción y permite evaluar el desempeño del modelo de forma semejante a como se utilizaría posteriormente con nuevos datos.

El horizonte de 24 horas se utilizará como máximo de evaluación. Durante el modelado se analizará si el error aumenta conforme crece la distancia entre el momento de observación y la hora pronosticada.

1.8 Variables consideradas

La variable objetivo del proyecto es la concentración horaria de **O3**. Las posibles variables predictoras se organizan en cuatro grupos:

Grupo	Variables principales	Función dentro del modelo
Variable objetivo	O3	Concentración que se desea predecir
Meteorológicas	BP, RAINF, RH, SR, TEMP, WS, WD	Describir las condiciones atmosféricas asociadas con la formación, transporte y dispersión del O3

Grupo	Variables principales	Función dentro del modelo
Contaminantes	CO, NO, NO ₂ , NO _x , PM ₁₀ , PM _{2.5} , SO ₂ y valores previos de O ₃	Incorporar información del estado reciente de la contaminación atmosférica
Temporales y espaciales	Fecha, hora, día, mes, estación de monitoreo	Representar patrones horarios, estacionales y diferencias entre estaciones

Además de estas variables originales, se evaluará la creación de **rezagos temporales**. Por ejemplo, para realizar una predicción en el momento t , pueden utilizarse valores observados previamente como $O_3(t)$, $O_3(t-1)$, $O_3(t-2)$ o mediciones meteorológicas recientes. La cantidad de rezagos y variables finales se determinará durante la preparación para el modelado para evitar incorporar información redundante o futura.

La dirección del viento requiere un tratamiento particular por ser una variable circular. Por ello, se evaluará su representación mediante componentes seno y coseno en lugar de utilizar directamente los grados como si fueran una variable lineal.

1.9 Estrategia general de análisis

El proyecto seguirá una secuencia orientada directamente al problema predictivo:

1. **Comprensión y limpieza de los datos.** Integrar las bases de 2020 a 2025, homologar nombres y unidades, identificar valores faltantes, registros inválidos y duplicados, y conservar únicamente información adecuada para el análisis.
2. **Análisis exploratorio enfocado en O₃.** Estudiar su distribución, comportamiento horario y estacional, diferencias entre estaciones y relación con las variables candidatas a predictoras.
3. **Preparación temporal.** Ordenar los registros cronológicamente, construir variables temporales y rezagos, y definir las observaciones disponibles para cada horizonte de predicción.
4. **Modelado.** Construir primero una referencia simple y posteriormente comparar modelos estadísticos y modelos más flexibles. Entre los candidatos se consideran la regresión lineal múltiple y métodos no lineales como Random Forest o Gradient Boosting.
5. **Evaluación.** Medir el error sobre periodos posteriores a los utilizados para el entrenamiento y analizar los resultados por estación y horizonte de predicción.

Debido a la naturaleza temporal del problema, los datos **no se dividirán aleatoriamente**. La separación inicial propuesta es:

- **2020-2023:** entrenamiento.
- **2024:** validación y selección de modelos.

- **2025:** prueba final sobre datos no utilizados durante la construcción del modelo.

Esta separación podrá ajustarse si la disponibilidad de O3 o de alguna variable predictora genera periodos con cobertura insuficiente, pero siempre se conservará el orden temporal para evitar fuga de información del futuro hacia el entrenamiento.

Como referencia mínima se incluirá un modelo base de persistencia, que supone que el comportamiento reciente del O3 es una aproximación de su comportamiento próximo. Los modelos desarrollados deberán superar esta referencia para demostrar que las variables adicionales aportan capacidad predictiva.

La evaluación se realizará principalmente mediante **MAE (Mean Absolute Error)** y **RMSE (Root Mean Squared Error)**, complementadas con gráficas de valores observados contra predichos y análisis del error a través del tiempo. Estas métricas permitirán comparar modelos utilizando las mismas observaciones y determinar no solo cuál obtiene menor error promedio, sino también en qué condiciones falla.

1.10 Fuente de información

Los datos utilizados provienen del Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León. Las bases disponibles para el proyecto contienen registros horarios de las estaciones de monitoreo durante el periodo 2020-2025. Cada registro combina información temporal, identificación de la estación, concentraciones de contaminantes y variables meteorológicas.

El reporte conservará los datos originales sin modificar como fuente de referencia y generará conjuntos derivados para limpieza, análisis y modelado. Las decisiones de exclusión, transformación o imputación se documentarán en las siguientes secciones y deberán responder directamente a las necesidades del problema de predicción de O3.

2 Datos

2.1 Archivos fuente

La información original se encuentra en seis archivos de Excel proporcionados para el reto, uno por cada año entre 2020 y 2025. Cada archivo contiene varias hojas y cada hoja corresponde a una estación de monitoreo de SIMA. El archivo de 2025 contiene únicamente el periodo disponible hasta junio, por lo que ese año tiene aproximadamente la mitad de registros que los años completos.

2.2 Carga inicial

El proyecto utiliza únicamente las estaciones NTE, NTE2, NO y NE. Por ello, estas cuatro hojas se seleccionan desde el momento de lectura de cada archivo y las demás estaciones no se cargan en memoria.

Todas las columnas provenientes de Excel se leen inicialmente como texto. Esto mantiene una lectura consistente entre años y deja las conversiones de tipo para una etapa posterior.

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
here() starts at /home/runner/work/Reto-Multivariados/Reto-Multivariados
```

`datos_brutos` contiene desde este punto únicamente las cuatro estaciones que se utilizarán en el proyecto. `Año` aparece como entero porque se agrega directamente desde el código; las columnas provenientes de Excel permanecen como `character` por la opción `col_types = "text"`.

2.3 Estructura y disponibilidad inicial

Primero se revisa cuántos registros aporta cada estación en cada año.

Table 1: Cantidad de registros por año y estación seleccionada

Año	NTE	NTE2	NO	NE
2020	8777	8776	8778	8776
2021	8759	8759	8759	8759
2022	8760	8760	8760	8760
2023	8758	8758	8758	8758
2024	8782	8782	8783	8784
2025	4345	4344	4344	4344

Las cuatro estaciones tienen cobertura durante los seis años. Entre 2020 y 2024 cada estación aporta aproximadamente 8,760 registros por año, consistente con mediciones horarias durante prácticamente todo el año. En 2025 se observan alrededor de 4,344 registros por estación porque la base disponible termina en junio.

También se resume la estructura resultante antes de homologar los nombres de las variables.

Table 2: Estructura inicial del conjunto de trabajo

Registros	Columnas	Años	Estaciones
192723	34	6	4

El conjunto reúne 192,723 registros de las cuatro estaciones seleccionadas. Antes de homologar, el número de columnas es mayor al esperado porque algunos archivos utilizan nombres diferentes para una misma variable.

2.4 Homologación de la estructura

Al comparar los encabezados de los seis archivos se identificaron algunas variables que cambian de nombre según el año. Estas equivalencias ya habían aparecido en el código anterior del proyecto y se conservaron porque corresponden a diferencias reales observadas en los archivos originales.

Table 3: Equivalencias utilizadas para homologar la estructura

Variable_estandar	Nombres_en_archivos
fecha_hora	fecha y hora / date
BP	BP / PRS
TEMP	TEMP / TOUT
WS	WS / WSR
WD	WD / WDR

Además, algunos encabezados contienen unidades entre paréntesis o saltos de línea. La función siguiente normaliza esas diferencias de formato y después combina las columnas equivalentes bajo un único nombre.

El resultado conserva una sola columna por variable y mantiene todavía las mediciones como texto.

Table 4: Verificación de la estructura homologada

Registros	Columnas	Variables_faltantes
192723	18	Ninguna

Después de la homologación se conservan los mismos 192,723 registros en 18 columnas y no falta ninguna de las variables esperadas para el análisis.

3 Preparación de los datos

3.1 Conversión de tipos

La estructura ya está homologada, pero las mediciones todavía se encuentran almacenadas como texto. En este paso se convierte `fecha_hora` a un formato de fecha y hora y las 15 variables de medición a tipo numérico. `Año` se mantiene como entero y `Estacion` como identificador de texto.

La columna temporal aparece en dos formatos dentro de los archivos: algunos registros se almacenan como números seriales de Excel y otros como texto con fecha y hora. La función siguiente contempla ambos casos sin modificar el orden temporal de las observaciones.

La zona horaria se fija como UTC únicamente para conservar una representación uniforme de fecha y hora; no se realiza una conversión del horario registrado por SIMA.

Antes de continuar con la limpieza se verifica que la transformación haya producido los tipos esperados y se cuantifican las fechas no vacías que no pudieron interpretarse.

Table 5: Tipos de datos después de la transformación

Elemento	Resultado
Año	integer
Estacion	character
fecha_hora	POSIXct
Variables de medición	15/15 numéricas

Table 6: Verificación de la conversión de fecha y hora

Primera_fecha	Ultima_fecha	Fechas_no_convertidas
2020-01-01	2025-06-30 23:00:00	0

La conversión produjo las 15 variables de medición en formato numérico y `fecha_hora` en formato `POSIXct`. El periodo resultante va del 1 de enero de 2020 al 30 de junio de 2025 a las 23:00, sin fechas que hayan quedado sin convertir.

3.2 Valores faltantes y registros inválidos

Antes de reemplazar o eliminar valores se cuantifican los problemas presentes en cada variable. Esta revisión distingue tres situaciones: valores que ya están ausentes (`NA`), valores no vacíos que no pudieron convertirse a número y la bandera `-9999`, utilizada en los archivos para indicar mediciones no válidas en algunas variables.

Table 7: Diagnóstico inicial de valores faltantes y banderas por variable

Variable	Faltantes	No_numericos	Bandera_menos9999	Porcentaje_faltante
CO	34579	4	0	17.94
NO	39363	4	0	20.42
NO2	45604	4	0	23.66
NOX	45037	4	0	23.37
O3	46839	4	0	24.30
PM10	10619	0	0	5.51
PM2.5	37925	0	0	19.68
SO2	47202	4	0	24.49
BP	15629	4	0	8.11
RAINF	14392	4	0	7.47
RH	36101	4	2	18.73
SR	7099	0	1	3.68
TEMP	27486	4	1	14.26
WS	19749	4	0	10.25
WD	20742	4	0	10.76

`Porcentaje_faltante` considera tanto los `NA` actuales como las observaciones con `-9999`, ya que estas últimas no representan una medición real. La tabla permite identificar qué variables tienen suficiente cobertura antes de decidir cómo tratar las ausencias.

También se verifica que no existan dos registros para la misma estación y la misma fecha-hora.

Table 8: Verificación de registros duplicados

Combinaciones_duplicadas	Registros_involucrados
0	0

En este punto todavía no se modifica ningún valor. El siguiente paso será decidir el tratamiento de -9999 y de cualquier otra observación inválida a partir de los resultados de estas verificaciones.

3.3 Valores extremos

Pendiente de diferenciar entre errores de medición y episodios reales de concentraciones elevadas antes de decidir cualquier eliminación.

3.4 Variables temporales y espaciales

Pendiente de construir la representación definitiva de fecha, hora, estacionalidad y estación de monitoreo.

4 Análisis exploratorio

4.1 Comportamiento del O3

Pendiente de describir su distribución, tendencia temporal y patrones horarios y estacionales.

4.2 Diferencias entre estaciones

Pendiente de comparar el comportamiento del O3 entre NTE, NTE2, NO y NE.

4.3 Relación con variables meteorológicas y contaminantes

Pendiente de reconstruir el análisis de asociación concentrándolo únicamente en las variables relevantes para la predicción de O3.

5 Preparación para modelado

5.1 Construcción de rezagos

Pendiente de definir qué información histórica estará disponible para cada pronóstico.

5.2 Separación cronológica

Se utilizará como punto de partida 2020-2023 para entrenamiento, 2024 para validación y 2025 para prueba final.

5.3 Conjunto final de predictores

Pendiente de seleccionar variables según disponibilidad, fundamento físico, análisis exploratorio y desempeño durante la validación.

6 Modelado

6.1 Modelo base

Pendiente de implementar un modelo de persistencia que sirva como referencia mínima de desempeño.

6.2 Modelo estadístico

Pendiente de construir y validar un modelo interpretable, inicialmente regresión lineal múltiple con variables temporales y rezagos.

6.3 Modelo no lineal

Pendiente de comparar el modelo estadístico con al menos un método capaz de capturar relaciones no lineales, como Random Forest o Gradient Boosting.

7 Evaluación

7.1 Métricas

Se utilizarán principalmente MAE y RMSE sobre periodos no utilizados durante el entrenamiento.

7.2 Error por horizonte

Pendiente de evaluar cómo cambia el error desde las predicciones más cercanas hasta el horizonte máximo de 24 horas.

7.3 Error por estación

Pendiente de determinar si el desempeño del modelo cambia entre los puntos de monitoreo seleccionados.

8 Conclusiones

Pendiente de redactar una vez completado el modelado y su evaluación.

9 Declaratoria y referencias

9.1 Link GitHub

<https://github.com/Reyivan777/Reto-Multivariados>

9.2 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: ChatGPT y otras herramientas de IA utilizadas por el equipo durante el desarrollo.

Uso realizado: Apoyo en la estructuración del reporte, revisión de redacción, discusión metodológica y apoyo con sintaxis de código.

Secciones donde se utilizó: Se documentarán de manera específica conforme avance la versión final del reporte.

Validación realizada por los estudiantes: El equipo revisa, verifica y edita los contenidos y resultados obtenidos, y asume la responsabilidad del contenido final entregado.

9.3 Referencias bibliográficas

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. International Journal of Public Health, 66, 1604465.