

Reporte del reto SIMA: predicción de ozono a corto plazo

Equipo 4: Rey Iván de la Fuente Chávez, A01709445
 Jannette Cristina Flores Rodríguez, A01255711
 Matías Romero Mariné, A01708802
 Emilio Alonso Sánchez, A00841853
 Dulce Alejandra Sánchez López, A01412307

2026-08-29

Table of contents

1	Introducción y planteamiento	2
1.1	Contexto del proyecto	2
1.2	Problema de investigación	3
1.3	Pregunta de investigación	3
1.4	Objetivo general	4
1.5	Objetivos específicos	4
1.6	Justificación y antecedentes	4
1.7	Alcance del pronóstico	5
1.8	Variables consideradas	5
1.9	Estrategia general de análisis	6
1.10	Fuente de información	7
2	Datos	7
2.1	Archivos fuente	7
2.2	Carga inicial	8
2.3	Selección del subconjunto de trabajo	8
2.4	Estructura y disponibilidad inicial	9
2.5	Homologación de la estructura	10
3	Preparación de los datos	11
3.1	Valores faltantes y registros inválidos	11

3.2	Valores extremos	12
3.3	Variables temporales y espaciales	12
4	Análisis exploratorio	12
4.1	Comportamiento del O ₃	12
4.2	Diferencias entre estaciones	12
4.3	Relación con variables meteorológicas y contaminantes	12
5	Preparación para modelado	12
5.1	Construcción de rezagos	12
5.2	Separación cronológica	12
5.3	Conjunto final de predictores	13
6	Modelado	13
6.1	Modelo base	13
6.2	Modelo estadístico	13
6.3	Modelo no lineal	13
7	Evaluación	13
7.1	Métricas	13
7.2	Error por horizonte	13
7.3	Error por estación	14
8	Conclusiones	14
9	Declaratoria y referencias	14
9.1	Link GitHub	14
9.2	Declaratoria de uso IA	14
9.3	Referencias bibliográficas	14

1 Introducción y planteamiento

1.1 Contexto del proyecto

La contaminación atmosférica representa un problema relevante para la salud pública y para la gestión ambiental de las ciudades. En la Zona Metropolitana de Monterrey (ZMM), las concentraciones de contaminantes pueden variar considerablemente a lo largo del día debido a la interacción entre emisiones, condiciones meteorológicas y características propias de cada zona. Por esta razón, además de conocer el estado actual de la calidad del aire, resulta útil estudiar si los registros históricos permiten anticipar su comportamiento en el corto plazo.

En Nuevo León, el Sistema Integral de Monitoreo Ambiental (SIMA) opera una red de estaciones que registra de forma horaria contaminantes atmosféricos y variables meteorológicas.

Entre los contaminantes disponibles se encuentran monóxido de carbono (CO), monóxido de nitrógeno (NO), dióxido de nitrógeno (NO₂), óxidos de nitrógeno (NO_x), ozono (O₃), partículas menores a 10 y 2.5 micrómetros (PM₁₀ y PM_{2.5}) y dióxido de azufre (SO₂). También se registran variables como temperatura, humedad relativa, radiación solar, presión atmosférica, precipitación, velocidad del viento y dirección del viento.

El reto planteado por SIMA permite analizar estas mediciones mediante técnicas estadísticas multivariadas y de modelado predictivo. En las primeras exploraciones del conjunto de datos se observó que intentar estudiar y predecir simultáneamente todos los contaminantes producía un objetivo demasiado amplio. Por ello, el proyecto se delimita a un problema concreto: **la predicción de la concentración horaria de ozono (O₃) en el corto plazo.**

1.2 Problema de investigación

El ozono troposférico es un contaminante cuyo comportamiento está relacionado con las condiciones atmosféricas y con otros contaminantes presentes en el ambiente. La temperatura, la radiación solar, la humedad y el viento, entre otras variables, pueden aportar información relevante para entender su variación. Además, al tratarse de mediciones horarias, la concentración observada en un momento también depende de la dinámica temporal reciente.

Los registros históricos de SIMA contienen ambas fuentes de información: las condiciones meteorológicas y de contaminación observadas en distintas estaciones, así como su evolución temporal. El problema central del proyecto consiste en determinar si esta información puede utilizarse para generar pronósticos útiles de O₃ con anticipación suficiente para apoyar el seguimiento de episodios de concentración elevada.

El análisis se enfocará inicialmente en las estaciones NTE, NTE2, NO y NE, utilizando los registros disponibles entre 2020 y 2025. Esta delimitación permite trabajar con un conjunto espacial manejable y mantener continuidad con el análisis exploratorio realizado previamente, sin intentar modelar simultáneamente toda la red de monitoreo.

1.3 Pregunta de investigación

¿Con qué precisión puede predecirse la concentración horaria de O₃ con un horizonte de hasta 24 horas en las estaciones NTE, NTE2, NO y NE, utilizando los registros históricos de contaminantes, variables meteorológicas y variables temporales proporcionados por SIMA entre 2020 y 2025?

Esta pregunta transforma el reto en un problema de predicción temporal claramente evaluable: existe una variable objetivo definida, un horizonte de pronóstico específico y un conjunto delimitado de datos con el cual entrenar y evaluar los modelos.

1.4 Objetivo general

Desarrollar y evaluar modelos capaces de **predecir la concentración horaria de ozono (O₃) con un horizonte de hasta 24 horas** en las estaciones NTE, NTE2, NO y NE de la Zona Metropolitana de Monterrey, utilizando información histórica de contaminantes, variables meteorológicas y características temporales registradas por SIMA durante el periodo 2020-2025.

1.5 Objetivos específicos

1. Preparar y validar la calidad de los registros históricos necesarios para modelar O₃, conservando la estructura temporal y espacial de las mediciones.
2. Caracterizar el comportamiento del O₃ e identificar qué variables meteorológicas, contaminantes y patrones temporales aportan información relevante para su predicción.
3. Construir variables derivadas que representen la dinámica temporal del problema, incluyendo características de fecha y hora y rezagos de mediciones disponibles antes del momento de predicción.
4. Construir y comparar al menos dos enfoques de modelado, incluyendo un modelo estadístico interpretable y un modelo capaz de representar relaciones no lineales.
5. Evaluar los modelos mediante una separación cronológica de los datos y métricas de error, analizando además cómo cambia el desempeño según el horizonte de predicción y la estación de monitoreo.

1.6 Justificación y antecedentes

La relevancia del problema parte de la relación entre contaminación atmosférica y salud pública. Cerón Bretón et al. (2020) documentaron asociaciones entre contaminación atmosférica, temperatura y mortalidad diaria en el norte de México. A nivel internacional, las Guías de Calidad del Aire de la Organización Mundial de la Salud resaltan la importancia de reducir la exposición de la población a contaminantes criterio y de contar con información confiable para su seguimiento (Hoffmann et al., 2021).

Desde la perspectiva predictiva, Cifuentes et al. (2021) analizaron la predicción horaria de O₃ y PM_{2.5} mediante variables meteorológicas y distintos modelos, mostrando que información como temperatura y radiación solar puede resultar útil para anticipar concentraciones de contaminantes. Este antecedente proporciona una base metodológica para estudiar si los registros históricos de SIMA permiten construir modelos adaptados a las condiciones de la ZMM.

La elección de O₃ como variable objetivo también responde al análisis exploratorio realizado durante el proyecto. Frente a otros contaminantes, el ozono mostró asociaciones meteorológicas más claras y consistentes, por lo que ofrece un punto de partida razonable para construir un

primer sistema predictivo. Estas relaciones se volverán a cuantificar y validar en la sección de análisis exploratorio de este reporte antes de utilizarse para seleccionar predictores.

El objetivo no es atribuir causalidad a las variables ni sustituir los procedimientos oficiales de pronóstico de SIMA. El propósito es evaluar, con los datos disponibles y dentro del alcance académico del reto, qué tan bien puede anticiparse el comportamiento del O3 y qué información resulta más útil para hacerlo.

1.7 Alcance del pronóstico

El horizonte máximo de predicción se establece en **24 horas**. Esto no significa utilizar los datos de 2020-2025 para generar una predicción fija de un día posterior al final de la base. El modelo se plantea como un esquema de pronóstico móvil.

En un momento determinado t , únicamente se utilizará información disponible hasta ese instante para estimar las concentraciones futuras de O3 durante las horas siguientes. De forma conceptual:

$$\text{información disponible hasta } t \longrightarrow \widehat{O_3}(t+1), \dots, \widehat{O_3}(t+24)$$

Cuando exista una nueva medición, esa información podrá incorporarse para generar nuevamente el pronóstico de las siguientes 24 horas. Esta estructura evita utilizar información futura durante la predicción y permite evaluar el desempeño del modelo de forma semejante a como se utilizaría posteriormente con nuevos datos.

El horizonte de 24 horas se utilizará como máximo de evaluación. Durante el modelado se analizará si el error aumenta conforme crece la distancia entre el momento de observación y la hora pronosticada.

1.8 Variables consideradas

La variable objetivo del proyecto es la concentración horaria de **O3**. Las posibles variables predictoras se organizan en cuatro grupos:

Grupo	Variables principales	Función dentro del modelo
Variable objetivo	O3	Concentración que se desea predecir
Meteorológicas	BP, RAINF, RH, SR, TEMP, WS, WD	Describir las condiciones atmosféricas asociadas con la formación, transporte y dispersión del O3

Grupo	Variables principales	Función dentro del modelo
Contaminantes	CO, NO, NO ₂ , NO _x , PM ₁₀ , PM _{2.5} , SO ₂ y valores previos de O ₃	Incorporar información del estado reciente de la contaminación atmosférica
Temporales y espaciales	Fecha, hora, día, mes, estación de monitoreo	Representar patrones horarios, estacionales y diferencias entre estaciones

Además de estas variables originales, se evaluará la creación de **rezagos temporales**. Por ejemplo, para realizar una predicción en el momento t , pueden utilizarse valores observados previamente como $O_3(t)$, $O_3(t-1)$, $O_3(t-2)$ o mediciones meteorológicas recientes. La cantidad de rezagos y variables finales se determinará durante la preparación para el modelado para evitar incorporar información redundante o futura.

La dirección del viento requiere un tratamiento particular por ser una variable circular. Por ello, se evaluará su representación mediante componentes seno y coseno en lugar de utilizar directamente los grados como si fueran una variable lineal.

1.9 Estrategia general de análisis

El proyecto seguirá una secuencia orientada directamente al problema predictivo:

1. **Comprensión y limpieza de los datos.** Integrar las bases de 2020 a 2025, homologar nombres y unidades, identificar valores faltantes, registros inválidos y duplicados, y conservar únicamente información adecuada para el análisis.
2. **Análisis exploratorio enfocado en O₃.** Estudiar su distribución, comportamiento horario y estacional, diferencias entre estaciones y relación con las variables candidatas a predictoras.
3. **Preparación temporal.** Ordenar los registros cronológicamente, construir variables temporales y rezagos, y definir las observaciones disponibles para cada horizonte de predicción.
4. **Modelado.** Construir primero una referencia simple y posteriormente comparar modelos estadísticos y modelos más flexibles. Entre los candidatos se consideran la regresión lineal múltiple y métodos no lineales como Random Forest o Gradient Boosting.
5. **Evaluación.** Medir el error sobre periodos posteriores a los utilizados para el entrenamiento y analizar los resultados por estación y horizonte de predicción.

Debido a la naturaleza temporal del problema, los datos **no se dividirán aleatoriamente**. La separación inicial propuesta es:

- **2020-2023:** entrenamiento.
- **2024:** validación y selección de modelos.

- **2025:** prueba final sobre datos no utilizados durante la construcción del modelo.

Esta separación podrá ajustarse si la disponibilidad de O₃ o de alguna variable predictora genera periodos con cobertura insuficiente, pero siempre se conservará el orden temporal para evitar fuga de información del futuro hacia el entrenamiento.

Como referencia mínima se incluirá un modelo base de persistencia, que supone que el comportamiento reciente del O₃ es una aproximación de su comportamiento próximo. Los modelos desarrollados deberán superar esta referencia para demostrar que las variables adicionales aportan capacidad predictiva.

La evaluación se realizará principalmente mediante **MAE (Mean Absolute Error)** y **RMSE (Root Mean Squared Error)**, complementadas con gráficas de valores observados contra predichos y análisis del error a través del tiempo. Estas métricas permitirán comparar modelos utilizando las mismas observaciones y determinar no solo cuál obtiene menor error promedio, sino también en qué condiciones falla.

1.10 Fuente de información

Los datos utilizados provienen del Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León. Las bases disponibles para el proyecto contienen registros horarios de las estaciones de monitoreo durante el periodo 2020-2025. Cada registro combina información temporal, identificación de la estación, concentraciones de contaminantes y variables meteorológicas.

El reporte conservará los datos originales sin modificar como fuente de referencia y generará conjuntos derivados para limpieza, análisis y modelado. Las decisiones de exclusión, transformación o imputación se documentarán en las siguientes secciones y deberán responder directamente a las necesidades del problema de predicción de O₃.

2 Datos

2.1 Archivos fuente

La información original se encuentra en seis archivos de Excel proporcionados para el reto, uno por cada año entre 2020 y 2025. Cada archivo contiene varias hojas y cada hoja corresponde a una estación de monitoreo de SIMA. El archivo de 2025 contiene únicamente el periodo disponible hasta el momento de descarga, por lo que ese año tiene menos registros que los anteriores.

2.2 Carga inicial

La primera lectura se realiza sin modificar los nombres de las columnas ni interpretar todavía las mediciones. Todas las columnas provenientes de Excel se leen inicialmente como texto. Esto evita que R realice conversiones automáticas diferentes entre años y permite detectar explícitamente las inconsistencias antes de corregirlas.

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr       1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
here() starts at /home/runner/work/Reto-Multivariados/Reto-Multivariados
```

El objeto `datos_brutos` reúne la información de los seis archivos y conserva dos identificadores añadidos durante la lectura: `Año`, que indica el archivo de origen, y `Estacion`, obtenida directamente del nombre de la hoja. En este punto todavía no se eliminan registros, no se corrigen valores y no se filtran estaciones o variables.

Esta separación entre **carga** y **preparación** es deliberada. `datos_brutos` funcionará como una representación de trabajo de los archivos originales, mientras que las transformaciones necesarias para obtener el conjunto de modelado se realizarán de manera explícita en las siguientes secciones.

2.3 Selección del subconjunto de trabajo

Como el objetivo del proyecto ya está delimitado a las estaciones NTE, NTE2, NO y NE, no es necesario realizar el análisis detallado de estructura y disponibilidad sobre toda la red de SIMA. Las demás estaciones permanecen en `datos_brutos` como respaldo de la fuente original, pero a partir de este punto el flujo de trabajo utiliza únicamente las cuatro estaciones de interés.

Esta selección se realiza antes de la homologación y limpieza para evitar procesar información que no será utilizada posteriormente. Al mismo tiempo, se conserva `datos_brutos` sin filtrar, de modo que el subconjunto puede reconstruirse desde la fuente original si fuera necesario.

2.4 Estructura y disponibilidad inicial

Antes de modificar las variables se verifica que las cuatro estaciones seleccionadas estén presentes en los seis años y se revisa cuántos registros aporta cada combinación de año y estación. En esta sección, **disponibilidad** se refiere únicamente a la existencia y cantidad de registros; el porcentaje de valores faltantes de cada variable se calculará después de homologar las columnas, para no confundir diferencias estructurales entre archivos con datos realmente ausentes.

Table 1: Cantidad de registros por año y estación seleccionada

Año	NTE	NTE2	NO	NE
2020	8777	8776	8778	8776
2021	8759	8759	8759	8759
2022	8760	8760	8760	8760
2023	8758	8758	8758	8758
2024	8782	8782	8783	8784
2025	4345	4344	4344	4344

Un valor igual a cero en esta tabla indicaría que una de las estaciones no está disponible en un año determinado y obligaría a reconsiderar la cobertura temporal utilizada para el modelado. Si las cuatro estaciones presentan registros durante todo el periodo, se conserva la selección planteada.

También se revisa la estructura general del subconjunto antes de realizar cualquier transformación.

Table 2: Estructura inicial del subconjunto de trabajo

Registros	Columnas	Años	Estaciones
192723	35	6	4

Table 3: Columnas resultantes de la carga inicial

Columna	Tipo_lectura
Año	integer
Estacion	character
Fecha y hora	character
CO	character
NO	character
NO2	character
NOX	character

Columna	Tipo_lectura
O3	character
PM10	character
PM2.5	character
PRS	character
RAINF	character
RH	character
SO2	character
SR	character
TOUT	character
WSR	character
WDR	character
CO (ppm)	character
NO (ppb)	character
NO2 (ppb)	character
NOX (ppb)	character
O3 (ppb)	character
PM10 (ug/m3)	character
PM2.5 (ug/m3)	character
PRS (mmHg)	character
RAINF (mm/h)	character
RH (%)	character
SO2 (ppb)	character
SR (kW/m2)	character
TOUT (°C)	character
WSR (km/h)	character
WDR (azimutal)	character
date	character
fecha y hora	character

En este punto la cantidad de columnas representa la **unión de los encabezados encontrados en los seis archivos**. Por ello, si una misma variable cambió de nombre entre años, puede aparecer temporalmente como dos columnas distintas. Además, las mediciones continúan almacenadas como texto.

2.5 Homologación de la estructura

Antes de evaluar valores faltantes o convertir las mediciones a formato numérico, se unifican los nombres que representan la misma variable. Esta homologación corrige diferencias de escritura entre los archivos anuales, pero todavía **no modifica los valores registrados**.

Las principales equivalencias identificadas son las siguientes:

Table 4: Equivalencias utilizadas para homologar la estructura

Variable_estandar	Nombres_en_archivos
fecha_hora	fecha y hora / date
BP	BP / PRS
TEMP	TEMP / TOUT
WS	WS / WSR
WD	WD / WDR

Además de estas equivalencias, algunos encabezados incluyen unidades entre paréntesis o saltos de línea. Para identificar correctamente las columnas, primero se crea una versión auxiliar de cada nombre sin estas diferencias de formato. Después se combinan las columnas equivalentes en una sola variable estándar.

El resultado es `datos_homologados`, que conserva únicamente las variables relevantes para el proyecto bajo una estructura común para los seis años. En este punto las mediciones siguen siendo texto; la conversión de tipos y la revisión de valores se realizarán después, dentro de la preparación de los datos.

Como verificación, se comprueba que la estructura obtenida contenga exactamente los identificadores, la variable temporal y las variables de medición que se espera utilizar.

Table 5: Verificación de la estructura homologada

Registros	Columnas	Variables_faltantes
192723	18	Ninguna

Con esto se obtiene una estructura consistente antes de comenzar la limpieza. La siguiente revisión se enfocará en convertir las variables a sus tipos correctos y cuantificar la disponibilidad real de O3 y de sus posibles predictores.

3 Preparación de los datos

3.1 Valores faltantes y registros inválidos

Pendiente de reconstruir el proceso de limpieza manteniendo únicamente las decisiones necesarias para el modelado.

3.2 Valores extremos

Pendiente de diferenciar entre errores de medición y episodios reales de concentraciones elevadas antes de decidir cualquier eliminación.

3.3 Variables temporales y espaciales

Pendiente de construir la representación definitiva de fecha, hora, estacionalidad y estación de monitoreo.

4 Análisis exploratorio

4.1 Comportamiento del O3

Pendiente de describir su distribución, tendencia temporal y patrones horarios y estacionales.

4.2 Diferencias entre estaciones

Pendiente de comparar el comportamiento del O3 entre NTE, NTE2, NO y NE.

4.3 Relación con variables meteorológicas y contaminantes

Pendiente de reconstruir el análisis de asociación concentrándolo únicamente en las variables relevantes para la predicción de O3.

5 Preparación para modelado

5.1 Construcción de rezagos

Pendiente de definir qué información histórica estará disponible para cada pronóstico.

5.2 Separación cronológica

Se utilizará como punto de partida 2020-2023 para entrenamiento, 2024 para validación y 2025 para prueba final.

5.3 Conjunto final de predictores

Pendiente de seleccionar variables según disponibilidad, fundamento físico, análisis exploratorio y desempeño durante la validación.

6 Modelado

6.1 Modelo base

Pendiente de implementar un modelo de persistencia que sirva como referencia mínima de desempeño.

6.2 Modelo estadístico

Pendiente de construir y validar un modelo interpretable, inicialmente regresión lineal múltiple con variables temporales y rezagos.

6.3 Modelo no lineal

Pendiente de comparar el modelo estadístico con al menos un método capaz de capturar relaciones no lineales, como Random Forest o Gradient Boosting.

7 Evaluación

7.1 Métricas

Se utilizarán principalmente MAE y RMSE sobre periodos no utilizados durante el entrenamiento.

7.2 Error por horizonte

Pendiente de evaluar cómo cambia el error desde las predicciones más cercanas hasta el horizonte máximo de 24 horas.

7.3 Error por estación

Pendiente de determinar si el desempeño del modelo cambia entre los puntos de monitoreo seleccionados.

8 Conclusiones

Pendiente de redactar una vez completado el modelado y su evaluación.

9 Declaratoria y referencias

9.1 Link GitHub

<https://github.com/Reyivan777/Reto-Multivariados>

9.2 Declaratoria de uso IA

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: ChatGPT y otras herramientas de IA utilizadas por el equipo durante el desarrollo.

Uso realizado: Apoyo en la estructuración del reporte, revisión de redacción, discusión metodológica y apoyo con sintaxis de código.

Secciones donde se utilizó: Se documentarán de manera específica conforme avance la versión final del reporte.

Validación realizada por los estudiantes: El equipo revisa, verifica y edita los contenidos y resultados obtenidos, y asume la responsabilidad del contenido final entregado.

9.3 Referencias bibliográficas

Cerón Bretón, R. M., et al. (2020). *Short-Term Effects of Atmospheric Pollution on Daily Mortality and Their Modification by Increased Temperatures Associated with a Climatic Change Scenario in Northern Mexico*. International Journal of Environmental Research and Public Health, 17(24), 9219.

Cifuentes, F., Gálvez, A., González, C. M., Orozco-Alzate, M., et al. (2021). *Hourly Ozone and PM_{2.5} Prediction Using Meteorological Data – Alternatives for Cities with Limited Pollutant Information*. Aerosol and Air Quality Research, 21, 200471.

Hoffmann, B., Boogaard, H., de Nazelle, A., Andersen, Z. J., Abramson, M., Brauer, M., et al. (2021). *WHO Air Quality Guidelines 2021–Aiming for Healthier Air for all: A Joint Statement by Medical, Public Health, Scientific Societies and Patient Representative Organisations*. *International Journal of Public Health*, 66, 1604465.